

Conjuntos

Teoría de Conjuntos	
$x \in A$:	x es un elemento de A
$A \subseteq B$:	todos los elementos de A están en B
$ A = \#(A)$:	número de elementos de A (cardinal)
$\mathcal{P}(A)$:	conjunto de todos los subconjuntos de A
$ \mathcal{P}(A) = 2^{ A }$:	cardinal del conjunto de potencia

Operaciones Básicas	
Intersección:	$A \cap B = \{x \in \Omega \mid x \in A \wedge x \in B\}$
Unión:	$A \cup B = \{x \in \Omega \mid x \in A \vee x \in B\}$
Diferencia:	$A - B = \{x \in \Omega \mid x \in A \wedge x \notin B\}$
Complemento:	$A^c = \Omega - A = \{x \in \Omega \mid x \notin A\}$

Función Característica	
Asigna 1 si el elemento está en A , 0 en caso contrario. Útil para operaciones booleanas.	
$\chi_A(\omega)$	$= \begin{cases} 1 & \text{si } \omega \in A \\ 0 & \text{si } \omega \notin A \end{cases}$

Leyes de De Morgan	
$(A \cup B)^c$	$= A^c \cap B^c$
$(A \cap B)^c$	$= A^c \cup B^c$

Propiedades adicionales	
Dos conjuntos son disjuntos si $A \cap B = \emptyset$	
$\emptyset^c$	$= \Omega, \Omega^c = \emptyset$

Combinatoria

Número Binomial (Combinaciones sin Repetición)	
Número de subconjuntos de tamaño k en un conjunto de n elementos (orden no importa, sin repetición).	
$\binom{n}{k} = C_k^n = \frac{n!}{k! \cdot (n-k)!}$	
Ejemplo: $\binom{7}{5} = 21$ (equipos de 5 con 7 posibles jugadores).	

Número Binomial (Combinaciones sin Repetición)	
Número de formas de elegir k elementos de n tipos permitiendo repeticiones (multiconjuntos).	
$CR_k^n = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k! \cdot (n-1)!}$	
Ejemplo: Repartir 12 caramelos en 4 personas: $\binom{4+12-1}{12} = 455$.	

Variaciones sin Repetición	
Número de formas de elegir y ordenar k elementos de n sin repetir (permutaciones parciales).	
$V_k^n = \frac{n!}{(n-k)!} = (n-k+1) \cdot (n-k+2) \cdots n$	
Ejemplo: Números de 2 cifras de {1,2,3}: $V_2^3 = 6$.	

Variaciones con Repetición	
Similar a variaciones, pero permitiendo repeticiones.	
$VR_k^n = n^k$	
Ejemplo: Números de 2 cifras de {1,2,3} con repetición: $3^2 = 9$.	

Permutaciones sin Repetición	
Número de formas de ordenar todos los n elementos de un conjunto.	
$P_n = n!$	
Ejemplo: Permutaciones de {1,2,3}: $3! = 6$.	

Permutaciones con Repetición	
Número de permutaciones cuando hay elementos repetidos.	
$PR_{n_1, n_2, \dots, n_k}^n = \binom{n}{n_1 n_2 \dots n_k} = \frac{n!}{n_1! \cdot n_2! \cdots n_k!},$ donde $n = n_1 + \dots + n_k$	
Ejemplo: Palabras con letras de “PROBABILIDAD” (12 letras, repeticiones específicas): $\frac{12!}{2!4!1!4} = 29,937,600$.	

Principio de la Suma	
Suma los cardinales de conjuntos mutuamente exclusivos.	
Si $A_1, \dots, A_n$ son disjuntos: $\#(\cup_{i=1}^n A_i) = \sum_{i=1}^n \#(A_i)$.	

Principio del Producto	
Corrige el solapamiento al contar uniones de conjuntos no disjuntos.	
$\#(A_1 \cup A_2) = \#(A_1) + \#(A_2) - \#(A_1 \cap A_2)$.	

Problema de las estrellas y barras

Queremos encontrar el número de soluciones no negativas de $x_1 + x_2 + \cdots + x_k = n$, $x_i \geq 0$

Imaginamos que tenemos n objetos idénticos que queremos repartir en k cajones. Alineamos los n objetos ★ en fila:

★★★★⋯★

para separar estos objetos en k cajones colocamos $k - 1$ barras que marcan dónde termina cada grupo y empieza el siguiente. Por ejemplo, $n = 7$ y $k = 3$:

★★★★★ | ★★ | ★

Esto representa cada cajón $x_1 = 4, x_2 = 2, x_3 = 1$.

Cada solución corresponde a una secuencia de n estrellas y $k - 1$ barras en fila.

- Número total de estrellas: n
- Número total de barras: $k - 1$
- Número total de símbolos: $n + k - 1$

Así que el problema se reduce a: ¿de cuántas formas podemos elegir las posiciones de las $k - 1$ barras entre $n + k - 1$ lugares posibles?

$$\binom{n + k - 1}{k - 1}$$

Sucesos

Definiciones	
Experimento aleatorio:	Experimento que, repetido en las mismas condiciones, puede dar resultados diferentes, pero predecibles a largo plazo.
Suceso elemental:	Cada posible resultado del experimento.
Espacio muestral Ω:	Conjunto de todos los sucesos elementales.
Suceso:	Cualquier subconjunto de Ω .
Suceso seguro:	Ω , $P(\Omega) = 1$.
Suceso imposible:	$\emptyset$, $P(\emptyset) = 0$.

Operaciones	
Unión:	$A \cup B$ (si sucede A o B)
Intersección:	$A \cap B$ (si sucede A y B)
Complementario:	A^c (si no sucede A)
Diferencia:	$A - B = A \cap B^c$ (sucede A y no B)
Incompatibles:	$A \cap B = \emptyset$

Propiedades Operaciones	
Conmutativas:	$A \cup B = B \cup A$, $A \cap B = B \cap A$
Asociativas:	$A \cup (B \cup C) = (A \cup B) \cup C$ $A \cap (B \cap C) = (A \cap B) \cap C$
Distributivas:	$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$ $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
Complementario:	$(A^c)^c = A$
De Morgan:	$(A \cup B)^c = A^c \cap B^c$ $(A \cap B)^c = A^c \cup B^c$

Probabilidad

Definición
Para un espacio muestral finito Ω , una probabilidad $P : \mathcal{P}(\Omega) \rightarrow [0, 1]$ satisface:
1. $0 \leq P(A) \leq 1$ para todo suceso A 2. $P(\Omega) = 1$ 3. Si $A_1, \dots, A_n$ disjuntos, $P(A_1 \cup \dots \cup A_n) = P(A_1) + \dots + P(A_n)$
Si todos los elementales son equiprobables, $P(A) = \frac{ A }{ \Omega }$.

Propiedades
• $P(\emptyset) = 0$ • $P(A^c) = 1 - P(A)$ • Si $B \subseteq A$, entonces $0 \leq P(B) \leq P(A)$ • $P(A - B) = P(A) - P(A \cap B)$ • $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ • Para tres conjuntos: $P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$

Probabilidad Condicionada
Dado A, B con $P(A) > 0$:
$P(B \mid A) = \frac{P(A \cap B)}{P(A)}.$
Propiedades (similar a probabilidad estándar):
• $P(B^c \mid A) = 1 - P(B \mid A)$. • $P(B_1 \cup B_2 \mid A) = P(B_1 \mid A) + P(B_2 \mid A) - P(B_1 \cap B_2 \mid A)$.

Independencia
A y B son independientes si:
$P(A \cap B) = P(A) \cdot P(B)$
Equivalentes (si $P(A), P(B) > 0$):
• $P(A \mid B) = P(A)$ • $P(B \mid A) = P(B)$
Para familia $\{A_1, \dots, A_n\}$: Para toda subfamilia, el producto de probabilidades individuales iguala la probabilidad de la intersección. También: Independencia se preserva con complementarios (e.g., A^c y B independientes si A y B lo son).

Probabilidad Total

Para A, B :

$$P(B) = P(B \cap A) + P(B \cap A^c) = P(A) \cdot P(B \mid A) + P(A^c) \cdot P(B \mid A^c).$$

Para partición $\{A_1, \dots, A_n\}$ de Ω :

$$P(B) = \sum_{i=1}^n P(A_i) \cdot P(B \mid A_i).$$

Teorema de Bayes

Para A, B con $P(B) > 0$:

$$P(A \mid B) = \frac{P(A) \cdot P(B \mid A)}{P(B)} = \frac{P(A) \cdot P(B \mid A)}{P(A) \cdot P(B \mid A) + P(A^c) \cdot P(B \mid A^c)}.$$

Para partición $\{A_1, \dots, A_n\}$:

$$P(A_i \mid B) = \frac{P(A_i) \cdot P(B \mid A_i)}{\sum_{j=1}^n P(A_j) \cdot P(B \mid A_j)}.$$

Variables Aleatorias

Definiciones

Variable aleatoria (v.a.): Aplicación que asigna a cada elemento ω del espacio muestral Ω un número real $X(\omega) \in \mathbb{R}$.

- Se denota con letras mayúsculas: X, Y, Z .
- Sus valores se denotan en minúscula: x, y, z .

Tipos de v.a.

- **Discreta:** Toma valores numerables con probabilidad positiva.
- **Continua:** Sus valores están en intervalos y se describen con funciones de densidad.

Variables Aleatorias Discretas

Función de Probabilidad

$$P_X(x) = P(X = x)$$

Propiedades:

- $\sum_{x \in D_X} P_X(x) = 1$
- $0 \leq P_X(x) \leq 1$

Dominio:

$$D_X(x) = \{x \in \mathbb{R} \mid P_X(x) > 0\}$$

Ejemplo: dado justo

$$P_X(x) = \begin{cases} \frac{1}{6}, & x = 1, 2, 3, 4, 5, 6 \\ 0, & \text{en otro caso} \end{cases}$$

Función de Distribución Acumulada (CDF)

$$F_X(x) = P(X \leq x).$$

Ejemplo: dado

$$F_X(x) = \begin{cases} 0, & x < 1 \\ \frac{k}{6}, & k \leq x < k + 1, \quad k = 1, \dots, 5 \\ 1, & x \geq 6 \end{cases}$$

Propiedades:

- $0 \leq F_X(x) \leq 1$
- $P(X > x) = 1 - P(X \leq x) = 1 - F_X(x)$
- Sean a y b tales que $a < b$:
 $P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a)$
- $\lim_{x \rightarrow -\infty} F_X(x) = 0, \lim_{x \rightarrow \infty} F_X(x) = 1$
- Continua por la derecha: $\lim_{x \rightarrow x_0^+} F_X(x) = F_X(x_0)$

Valor Esperado

El valor esperado, esperanza o media $E(X)$ de una v.a. discreta X se define como:

$$\bar{x} = \mu = \mu_X = E(X) = \sum_{x \in X(\Omega)} x \cdot P_X(x)$$

Ejemplo: lanzamos un dado n veces y obtenemos unas frecuencias n_i para $i = 1, \dots, 6$:

$$\bar{x} = \frac{1 \cdot n_1 + 2 \cdot n_2 + 3 \cdot n_3 + 4 \cdot n_4 + 5 \cdot n_5 + 6 \cdot n_6}{n} = \sum_{i=1}^6 x \cdot P_X(x)$$

Propiedades:

- $E(k) = k$ para cualquier constante k
- Si $a \leq X \leq b$ entonces $a \leq E(X) \leq b$
- Si X es una v.a. discreta que toma valores enteros no negativos entonces $E(X) = \sum_{x=0}^{+\infty} (1 - F_X(x))$
- $E(g(X)) = \sum_x g(x) \cdot P_X(x)$

Series Geométricas

Progresión de razón r : $r^0, r^1, \dots, r^n$

Serie: $\sum_{k=0}^{+\infty} r^k$

Sumas paricales: $\sum_{k=n_0}^n r^k = \frac{r^{n_0} - r^{n+1}}{1-r}$

Momento de orden m : $E((X - C)^m)$

Propiedades:

- Si se empieza en n_0 se tiene que $\sum_{k=n_0}^{+\infty} r^k = \frac{r^{n_0}}{1-r}$

- Si $|r| < 1$ la serie es convergente y $\sum_{k=0}^{+\infty} r^k = \frac{1}{1-r}$ y sus derivadas también son convergentes:

$$\left(\sum_{k=0}^{+\infty} r^k\right)' = \sum_{k=1}^{+\infty} k r^{k-1}; \left(\frac{1}{1-r}\right)' = \frac{1}{(1-r)^2}$$
$$\left(\sum_{k=0}^{+\infty} r^k\right)'' = \sum_{k=2}^{+\infty} k(k-1) r^{k-2}; \left(\frac{1}{1-r}\right)'' = \frac{2}{(1-r)^3}$$

Varianza

Varianza: $\text{Var}(X) = E((X - E(X))^2) = \sum (x - E(X))^2 P_X(x)$

$$\text{Var}(X) = E(X^2) - (E(X))^2 = \sum_x x^2 P_X(x) - (E(X))^2$$

Desviación típica o estándar: $\sigma = \sigma_X = +\sqrt{\text{Var}(X)}$

Propiedades:

- $\text{Var}(X) \geq 0$

- $\text{Var}(cte) = E(cte^2) - (E(cte))^2 = cte^2 - cte^2 = 0$
- Si $Y = a + bX$:
 - $E(Y) = E(a + bX) = a + bE(X) = a + b\mu_X$
 - $\text{Var}(Y) = \text{Var}(a + bX) = b^2 \text{Var}(x) = b^2 \sigma_X^2$
 - $\sigma_Y = \sqrt{\text{Var}(Y)} = \sqrt{b^2 \text{Var}(X)} = |b| \sigma_X$

Variables Aleatorias Continuas

Variables Aleatorias Continuas

Propiedades

- $P_X(X = x_0) = F_X(x_0) - F_X(x_0^-) = 0$
- $P(X \leq b) = P(X < b)$
- $P(X < b) = P(X < a) + P(a < X < b)$
- $F_X(b) = F_X(a) + P(a < X < b)$
- $P(a < X < b) = F_X(b) - F_X(a) = P(a \leq X \leq b)$

Función de densidad

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1, f_X(x) \geq 0 \forall x \in \mathbb{R}$$

Función de distribución

$$F_X(x) = \int_{-\infty}^x f_X(t) dt, \forall x \in \mathbb{R}$$

Esperanza y Varianza

Esperanza

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx$$

Varianza

$$\text{Var}(X) = E((X - \mu_X)^2) = \int_{-\infty}^{+\infty} (x - \mu_X)^2 \cdot f_X(x) dx$$

Propiedades

- $E(Y) = E(a + bX) = a + bE(X)$
- $\text{Var}(Y) = \text{Var}(a + bX) = b^2 E(X)$
- $\sigma_Y = |b| \sigma_X$
- $Z = \frac{X - \mu_X}{\sigma_X} \implies E(Z) = 0, \text{Var}(Z) = 1$

Distribuciones notables

Bernoulli

Tirar una moneda y observar si sale cara o cruz (éxito o fracaso).

$X \sim \text{Ber}(p)$

$D_X = \{0, 1\}$

$$P_X(x) = P(X = x) = \begin{cases} 1 - p = q & \text{si } x = 0 \\ p & \text{si } x = 1 \\ 0 & \text{en otro caso} \end{cases}$$
$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - p & \text{si } 0 \leq x < 1 \\ 1 & \text{si } x \leq 1 \end{cases}$$

$E(X) = p, \text{Var}(X) = p(1 - p)$

Binomial

Probabilidad de obtener x caras al lanzar una moneda n veces.

$X \sim B(n, p)$

$D_X = \{0, 1, \dots, n\}$

$$P_X(x) = \begin{cases} \binom{n}{x} p^x (1 - p)^{n-x} & \text{si } x \in [0, n] \\ 0 & \text{en otro caso} \end{cases}$$
$$F_X(x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k \binom{n}{i} p^i (1 - p)^{n-i} & \text{si } k \leq x < k + 1, \text{ para } k \in [0, n] \\ 1 & \text{si } x \geq n \end{cases}$$

$E(X) = np, \text{Var}(X) = np(1 - p)$

Geométrica	
Tirar una moneda hasta que obtenemos la primera cara.	
$X \sim Ge(p)$ X = número de fracasos para conseguir primer éxito $D_X = \{0, 1, \dots, n, \dots\}$ $P_X(x) = P(X = x) = \begin{cases} (1-p)^x p & \text{si } x \geq 0 \\ 0 & \text{en otro caso} \end{cases}$ $F_X(x) = F(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - (1-p)^{k+1} & \text{si } \begin{cases} k \leq x < k+1 \\ \text{para } k \geq 0 \end{cases} \end{cases}$ $E(X) = \frac{1-p}{p}, Var(X) = \frac{1-p}{p^2}$	$Y \sim Ge(p)$ Y = número de intentos para conseguir primer éxito $D_Y = \{0, 1, \dots, n, \dots\}$ $P_Y(y) = P(Y = y) = \begin{cases} (1-p)^{y-1} & \text{si } y \geq 1 \\ 0 & \text{en otro caso} \end{cases}$ $F_Y(y) = F(Y \leq y) = \begin{cases} 0 & \text{si } y < 1 \\ 1 - (1-p)^k & \text{si } \begin{cases} k \leq y < k+1 \\ \text{para } k \geq 1 \end{cases} \end{cases}$ $E(Y) = \frac{1}{p}, Var(Y) = \frac{1-p}{p^2}$

Binomial Negativa
Abrir dos puertas consecutivas con un conjunto de llaves sin memoria. $X \sim BN(n, p)$ X = número de fracasos hasta conseguir el n -ésimo éxito $D_X = \{0, 1, 2, 3, \dots\}$ $P_X(x) = P(X = x) = \begin{cases} \binom{x+n-1}{n-1} (1-p)^x p^n & \text{si } k \geq 0 \\ 0 & \text{en otro caso} \end{cases}$ $F_X(x) = P(X \leq x) = \begin{cases} \sum_{i=0}^x P(X = i) & \text{si } \begin{cases} k \leq x < k+1, \\ k \geq 0 \end{cases} \end{cases}$ $E(X) = n \frac{1-p}{p}, Var(X) = n \frac{1-p}{p^2}$

Hipergeométrica
Sacar bolas de una urna con reposición. $X \sim H(m, n, k)$ X = $\begin{cases} \text{número de bolas blancas en } k \text{ extracciones} \\ \text{sin reposición de una urna con} \\ m \text{ bolas blancas y } n \text{ negras} \end{cases}$ $D_X = \{x \in \mathbb{N} \mid \max\{0, k-n\} \leq x \leq \min\{m, k\}\}$ $P_X(x) = \begin{cases} \frac{\binom{m}{x} \binom{n}{k-x}}{\binom{m+n}{k}} & \text{si } \max\{0, k-n\} \leq x \leq \min\{m, k\} \\ 0 & \text{en otro caso} \end{cases}$ $F_X(x) = P(X \leq x)$ $E(X) = \frac{km}{m+n}, Var(X) = k \frac{m}{m+n} (1 - \frac{m}{m+n}) \frac{m+n-k}{m+n-1}$

Poisson	
X con distribución Poisson de media o promedio λ $X \sim Po(\lambda)$ $D_X = \{0, 1, \dots\}$ $P_X(x) = P(X = x) = \begin{cases} \frac{\lambda^x}{x!} e^{-\lambda} & \text{si } x \geq 0 \\ 0 & \text{en otro caso} \end{cases}$ $F_X(x) = F(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^x P(X = i) & \text{si } \begin{cases} k \leq x < k + 1, \\ k \geq 0 \end{cases} \end{cases}$ $E(X) = \lambda, Var(X) = \lambda$	X_t = número de eventos en el intervalo $(0, t] Po(\lambda \ t)$ donde t promedio pro u.t. $X \sim Po(\lambda \ t)$ $D_X = \{0, 1, \dots\}$ $P_X(x) = P(X = x) = \begin{cases} \frac{(\lambda \ t)^x}{x!} e^{-\lambda \ t} & \text{si } x \geq 0 \\ 0 & \text{en otro caso} \end{cases}$ $F_X(x) = F(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^x P(X = i) & \text{si } \begin{cases} k \leq x < k + 1, \\ k \geq 0 \end{cases} \end{cases}$ $E(X) = \lambda t, Var(X) = \lambda t$

Uniforme
$X \sim U(a, b)$ $D_X = (a, b)$ $f_X(x) = \begin{cases} \frac{1}{b-a} & \text{si } a < x < b \\ 0 & \text{en otro caso} \end{cases}$ $F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x \leq a \\ \frac{x-a}{b-a} & \text{si } a \leq x \leq b \\ 1 & \text{si } x \leq b \end{cases}$ $E(X) = \frac{a+b}{2}, Var(X) = \frac{(b-a)^2}{12}$

Exponencial
$X \sim Exp(\lambda)$ $D_X = (0, +\infty)$ $f_X(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ \lambda e^{-\lambda x} & \text{si } x > 0 \end{cases}$ $F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 - e^{-\lambda x} & \text{si } x > 0 \end{cases}$ $E(X) = \frac{1}{\lambda}, Var(X) = \frac{1}{\lambda^2}$

Normal o Gaussian
$X \sim N(\mu, \sigma)$ $D_X = \mathbb{R} = (-\infty, +\infty)$ $f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}, \forall x \in \mathbb{R}$ $F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t) dt$ $E(X) = \mu, Var(X) = \sigma^2$

Variables Aleatorias Multidimensionales

Variables Aleatorias Bidimensionales

Definiciones

- **Discreta:** su conjunto de valores es $\mathbb{R}^2, (X, Y)(\Omega)$ es un conjunto finito o numerable.
- **Continua:** su conjunto de valores es $\mathbb{R}^2, (X, Y)(\Omega)$ es un conjunto es un producto de intervalos.
- **Heterogénea:** X e Y no comportan ser continuas o discretas.

Dominio

$$D_{XY} = \{(x, y) \in \mathbb{R}^2 \mid P_{XY}(x, y) > 0\}$$

Función de probabilidad

$$P_{XY}(x, y) = P(X = x, Y = y)$$

$$\sum_i \sum_j P_{XY}(x_i, y_j) = 1$$

$$P((X, Y) \in B) = \sum_{(x_i, y_j) \in B} P_{XY}(x_i, y_j), B \subset D_{XY}$$

Función de distribución acumulada

$$F_{XY} = P(X \leq x, Y \leq y) = \sum_{x_i \leq x, y_j \leq y} P_{XY}(x_i, y_j)$$

Función de densidad

$$f_{XY} : \mathbb{R} \times \mathbb{R} \rightarrow [0, +\infty)$$

- $f_{XY}(x, y) > 0, \forall (x, y) \in D_{XY}$
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{XY}(t_x, t_y) dt_x dt_y = 1$
- $F_{XY}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{XY}(t_x, t_y) dt_x dt_y$

Distribuciones Marginales

Probabilidad Marginal

$$P_X(x_i) = \sum_j P_{XY}(x_i, y_j)$$

$$P_Y(y_j) = \sum_i P_{XY}(x_i, y_j)$$

Densidad Marginal

$$f_X(x) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dx$$

Discretas

Independencia

X e Y son independientes si se cumple alguna de las condiciones:

- $P_{XY}(x_i, y_j) = P_X(x_i) \cdot P_Y(y_j)$
- $P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j)$
- $F_{XY}(x, y) = F_X(x) \cdot F_Y(y)$

Esperanza y varianza

- $E(X) = \sum_{x \in D_X} x \cdot P_X(x)$
- $E(Y) = \sum_{y \in D_Y} y \cdot P_Y(y)$
- $\sigma_X^2 = Var(X) = E(X - E(X))^2 = E(X^2) - E(X)^2$
- $\sigma_Y^2 = Var(Y) = E(Y - E(Y))^2 = E(Y^2) - E(Y)^2$

Distribuciones condicionales

Dado un valor fijo $y \in D_Y$:

$$P(X = x \mid Y = y) = \frac{P_{XY}(x, y)}{P_Y(y)}$$

Dado un valor fijo $x \in D_X$:

$$P(Y = y \mid X = x) = \frac{P_{XY}(x, y)}{P_X(x)}$$

Independientes si y sólo si:

- $P(X = x \mid Y = y) = P(X = x)$
- $P(Y = y \mid X = x) = P(Y = y)$

Esperanza:

$$E(X \mid Y = y) = \sum_{x \in D_X} x \cdot P(X = x \mid Y = y)$$

X e Y independientes si:

- $E(X \mid Y = y) = E(X)$
- $E(Y \mid X = x) = E(Y)$

Continuas

Independencia

X e Y son independientes si se cumple alguna de las condiciones:

- $f_{XY}(x, y) = f_X(x) \cdot f_Y(y), \forall (x, y) \in D_{XY}$
- $F_{XY}(x, y) = F_X(x) \cdot F_Y(y), \forall (x, y) \in D_{XY}$

Esperanza y varianza

- $E(X) = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx$
- $E(Y) = \int_{-\infty}^{+\infty} y \cdot f_Y(y) dy$
- $\sigma_X^2 = Var(X) = E((X - E(X))^2) = E(X^2) - E(X)^2$
- $\sigma_Y^2 = Var(Y) = E((Y - E(Y))^2) = E(Y^2) - E(Y)^2$

Distribuciones condicionales

Dado un valor fijo $y \in D_Y$:

$$f_{X|Y=y}(x) = \frac{f_{XY}(x, y)}{f_Y(y)}$$

Dado un valor fijo $x \in D_X$:

$$f_{Y|X=x}(y) = \frac{f_{XY}(x, y)}{f_X(x)}$$

Independientes si y sólo si:

- $f_{X|Y=y}(x) = f_X(x)$
- $f_{Y|X=x}(y) = f_Y(y)$

Esperanza:

$$E(X \mid Y = y) = \int_{-\infty}^{+\infty} x \cdot f_{X|Y=y}(x) dx$$

Estimación Puntual

Estadística Inferencial

Problema: Queremos conocer una característica de una población, pero no podemos medirla en todos los individuos. Extraemos una muestra aleatoria e inferimos el valor para toda la población.

Muestra Aleatoria Simple (m.a.s.)

Definición intuitiva: De una población de N individuos, repetimos n veces el proceso de escoger equiprobablemente un individuo (con reposición).

Definición formal: Un conjunto de n variables aleatorias independientes $X_1, \dots, X_n$, todas con la distribución de X .

Realización: Los n valores $x_1, \dots, x_n$ que toman las v.a. $X_1, \dots, X_n$.

Estadístico (Estimador Puntual)

Definición: Una función aplicada a la muestra $X_1, \dots, X_n$:

$$T = f(X_1, \dots, X_n)$$

Propiedades:

- Es una variable aleatoria con distribución, esperanza, etc.
- La distribución muestral de T es la distribución de esta v.a.
- Error estándar de T : desviación típica de T (σ_T)

Convenio: Estadísticos en mayúsculas ($\bar{X}$), realizaciones en minúsculas ($\bar{x}$).

Media Muestral

Definición: Sea $X_1, \dots, X_n$ una m.a.s. de tamaño n de una v.a. X con esperanza μ_X y desviación típica σ_X :

$$\bar{X} = \frac{X_1 + \dots + X_n}{n}$$

Propiedades:

- $E(\bar{X}) = \mu_X$ (estimador insesgado)
- $\sigma_{\bar{X}} = \frac{\sigma_X}{\sqrt{n}}$ (error estándar)
- $\bar{X}$ es un estimador puntual de μ_X

Interpretación: Si tomamos muchas veces una m.a.s. y calculamos la media muestral, el promedio de estas medias será aproximadamente μ_X .

Teorema Central del Límite: Si n es suficientemente grande, $\bar{X}$ sigue aproximadamente una distribución normal:

$$\bar{X} \approx N\left(\mu_X, \frac{\sigma_X}{\sqrt{n}}\right)$$

Propiedades de la Media Muestral

Insesgadez: $E(\bar{X}) = \mu_X$

Consistencia: A medida que n aumenta, $\sigma_{\bar{X}} = \frac{\sigma_X}{\sqrt{n}}$ disminuye.

Eficiencia: Entre los estimadores insesgados, la media muestral tiene varianza mínima (bajo ciertas condiciones).

Notación y Convenios

Estadísticos (v.a.): $X_1, \dots, X_n, \bar{X}, S^2$

Realizaciones (valores): $x_1, \dots, x_n, \bar{x}, s^2$

Muestra sin reposición: Si $N \gg n$, los resultados son aproximadamente los mismos que para m.a.s.

Intervalos de Confianza

Definición de Intervalo de Confianza

Concepto: Un intervalo de confianza $(1 - \alpha)$ para un parámetro θ es un intervalo aleatorio $[L, U]$ tal que:

$$P(L \leq \theta \leq U) = 1 - \alpha$$

Interpretación: Si construimos muchos intervalos de confianza $(1 - \alpha)$ a partir de diferentes muestras, aproximadamente el $(1 - \alpha) \times 100\%$ de ellos contendrá el verdadero valor del parámetro θ .

Nivel de confianza: $1 - \alpha$ (típicamente 0.95, 0.99)

Nivel de significación: α (típicamente 0.05, 0.01)

Construcción de I.C.

Pasos:

1. Elegir nivel de confianza $1 - \alpha$
2. Encontrar estadístico pivote
3. Determinar distribución del pivote
4. Calcular cuantiles $z_{\alpha/2}$ o $t_{\alpha/2}$
5. Construir intervalo

Forma general:

$$\text{Estimador} \pm \text{Margen de error}$$

Cuantiles Importantes

Distribución Normal:

- $z_{0.025} = 1.96$ (95%)
- $z_{0.005} = 2.576$ (99%)
- $z_{0.05} = 1.645$ (90%)

Distribución t de Student:

- Depende de grados de libertad $\nu = n - 1$
- $t_{\alpha/2, \nu}$ se obtiene de tablas

Intervalo de Confianza para la Media μ

Caso 1: Varianza conocida σ^2 (o n grande):

$$\bar{X} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Intervalo: $\left[\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$

Caso 2: Varianza desconocida, muestra pequeña ($n < 30$):

$$\bar{X} \pm t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}}$$

donde $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$ es la desviación típica muestral.

Intervalo: $\left[\bar{x} - t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}, \bar{x} + t_{\alpha/2, n-1} \frac{s}{\sqrt{n}} \right]$

Amplitud del intervalo: $2 \cdot z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ (o con t y s)

I.C. para Proporción p

Condición: n grande ($np \geq 5$ y $n(1-p) \geq 5$)

Estimador: $\hat{p} = \frac{X}{n}$ donde $X \sim B(n, p)$

Intervalo:

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Forma: $\left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$

I.C. para Varianza σ^2

Condición: Población normal

Estadístico: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$

Intervalo:

$$\left[\frac{(n-1)s^2}{\chi^2_{\alpha/2, n-1}}, \frac{(n-1)s^2}{\chi^2_{1-\alpha/2, n-1}} \right]$$

Nota: $\chi^2_{\alpha/2, n-1}$ y $\chi^2_{1-\alpha/2, n-1}$ son cuantiles de chi-cuadrado con $n - 1$ grados de libertad.

Distribución t de Student

Definición: Si $Z \sim N(0, 1)$ y $V \sim \chi^2_\nu$ son independientes, entonces:

$$T = \frac{Z}{\sqrt{V/\nu}} \sim t_\nu$$

Propiedades:

- Simétrica alrededor de 0
- $E(T) = 0$ (si $\nu > 1$)
- $Var(T) = \frac{\nu}{\nu-2}$ (si $\nu > 2$)
- Cuando $\nu \rightarrow \infty$, $t_\nu \rightarrow N(0, 1)$

Uso: Cuando la varianza poblacional es desconocida y la muestra es pequeña.

Tamaño Muestral

Para media (varianza conocida):

$$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

Interpretación y Consideraciones

Interpretación correcta: "Tenemos un 95% de confianza de que el intervalo contiene el verdadero parámetro."

Interpretación incorrecta: "El parámetro tiene un 95% de probabilidad de estar en el intervalo."

Factores que afectan la amplitud:

- Nivel de confianza: mayor confianza $\Rightarrow$ mayor amplitud
- Tamaño muestral: mayor $n \Rightarrow$ menor amplitud
- Varianza: mayor varianza $\Rightarrow$ mayor amplitud

Contraste de Hipótesis

Definiciones Básicas

Hipótesis estadística: Afirmación sobre un parámetro poblacional que se desea verificar.

Hipótesis nula (H_0): Afirmación que se asume verdadera inicialmente. Representa "no hay efecto" o "no hay diferencia".

Hipótesis alternativa (H_1 o H_a): Afirmación que contradice H_0 . Representa el efecto o diferencia que se desea detectar.

Estadístico de prueba: Función de la muestra que se usa para tomar la decisión.

Región crítica (o de rechazo): Conjunto de valores del estadístico que llevan a rechazar H_0 .

Región de aceptación: Conjunto de valores del estadístico que llevan a no rechazar H_0 .

Tipos de Contrastes

Unilateral (cola derecha):

- $H_0 : \theta = \theta_0$
- $H_1 : \theta > \theta_0$

Unilateral (cola izquierda):

- $H_0 : \theta = \theta_0$
- $H_1 : \theta < \theta_0$

Bilateral:

- $H_0 : \theta = \theta_0$
- $H_1 : \theta \neq \theta_0$

Errores en el Contraste

Error Tipo I (α): Rechazar H_0 cuando es verdadera.

$$\alpha = P(\text{Rechazar } H_0 \mid H_0 \text{ es verdadera})$$

Error Tipo II (β): No rechazar H_0 cuando es falsa.

$$\beta = P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa})$$

Nivel de significación: Probabilidad máxima permitida de cometer Error Tipo I. Valores comunes: $\alpha = 0.05, 0.01, 0.10$.

Potencia del Test

Definición: Probabilidad de rechazar correctamente H_0 cuando H_1 es verdadera.

$$\text{Potencia} = 1 - \beta = P(\text{Rechazar } H_0 \mid H_1 \text{ es verdadera})$$

Factores que aumentan la potencia:

- Mayor tamaño muestral n
- Mayor diferencia entre θ_0 y θ_1
- Mayor nivel de significación α
- Menor varianza poblacional

p-valor

Definición: Probabilidad de obtener un resultado tan extremo como el observado (o más extremo), suponiendo que H_0 es verdadera.

Regla de decisión:

- Si $p\text{-valor} < \alpha$: Rechazar H_0
- Si $p\text{-valor} \geq \alpha$: No rechazar H_0

Interpretación:

- $p\text{-valor}$ pequeño: Evidencia fuerte contra H_0
- $p\text{-valor}$ grande: Poca evidencia contra H_0

Procedimiento General para Contrastes

Pasos:

- Formular H_0 y H_1
- Elegir el nivel de significación α
- Seleccionar el estadístico de prueba adecuado
- Determinar la región crítica (o calcular el p -valor)
- Calcular el valor del estadístico con los datos muestrales
- Tomar decisión: rechazar o no rechazar H_0
- Interpretar los resultados en el contexto del problema

Contrastes para la Media Poblacional μ

Caso 1: Varianza conocida σ^2

Condiciones: Población normal o n grande ($n \geq 30$)

Estadístico de prueba:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Regiones críticas:

- $H_1 : \mu > \mu_0$: Rechazar si $Z > z_\alpha$
- $H_1 : \mu < \mu_0$: Rechazar si $Z < -z_\alpha$
- $H_1 : \mu \neq \mu_0$: Rechazar si $|Z| > z_{\alpha/2}$

p-valor:

- $H_1 : \mu > \mu_0$: $p = P(Z > z_{\text{obs}})$
- $H_1 : \mu < \mu_0$: $p = P(Z < z_{\text{obs}})$
- $H_1 : \mu \neq \mu_0$: $p = 2P(Z > |z_{\text{obs}}|)$

Caso 2: Varianza desconocida

Condiciones: Población normal, muestra pequeña ($n < 30$)

Estadístico de prueba:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$$

donde $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$

Regiones críticas:

- $H_1 : \mu > \mu_0$: Rechazar si $T > t_{\alpha, n-1}$
- $H_1 : \mu < \mu_0$: Rechazar si $T < -t_{\alpha, n-1}$
- $H_1 : \mu \neq \mu_0$: Rechazar si $|T| > t_{\alpha/2, n-1}$

Nota: Si n es grande ($n \geq 30$), se puede usar Z aunque σ sea desconocida.

Contrastes para la Proporción Poblacional p

Contraste para una Proporción

Condiciones: n grande ($np_0 \geq 5$ y $n(1 - p_0) \geq 5$)
Estadístico de prueba:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim N(0, 1)$$

donde $\hat{p} = \frac{X}{n}$ es la proporción muestral.

Regiones críticas:

- $H_1 : p > p_0$: Rechazar si $Z > z_\alpha$
- $H_1 : p < p_0$: Rechazar si $Z < -z_\alpha$
- $H_1 : p \neq p_0$: Rechazar si $|Z| > z_{\alpha/2}$

p-valor:

- $H_1 : p > p_0$: $p = P(Z > z_{\text{obs}})$
- $H_1 : p < p_0$: $p = P(Z < z_{\text{obs}})$
- $H_1 : p \neq p_0$: $p = 2P(Z > |z_{\text{obs}}|)$

Contrastes para la Varianza Poblacional σ^2

Contraste para la Varianza

Condiciones: Población normal
Estadístico de prueba:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2$$

donde $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

Regiones críticas:

- $H_1 : \sigma^2 > \sigma_0^2$: Rechazar si $\chi^2 > \chi_{\alpha, n-1}^2$
- $H_1 : \sigma^2 < \sigma_0^2$: Rechazar si $\chi^2 < \chi_{1-\alpha, n-1}^2$
- $H_1 : \sigma^2 \neq \sigma_0^2$: Rechazar si $\chi^2 < \chi_{1-\alpha/2, n-1}^2$ o $\chi^2 > \chi_{\alpha/2, n-1}^2$

Contrastes para Dos Muestras

Diferencia de Medias (Muestras Independientes)

Caso: Varianzas conocidas

Estadístico:

$$Z = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

Caso: Varianzas desconocidas pero iguales

Estadístico:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)_0}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

donde $S_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$ (varianza combinada)

Caso: Varianzas desconocidas y diferentes

Estadístico (aproximado):

$$T = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)_0}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \sim t_\nu$$

donde $\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$ (Welch)

Diferencia de Medias (Muestras Pareadas)

Condiciones: Población normal, muestras dependientes

Definición: $D_i = X_{1i} - X_{2i}$ (diferencias pareadas)

Estadístico de prueba:

$$T = \frac{\bar{D} - \mu_{D_0}}{S_D/\sqrt{n}} \sim t_{n-1}$$

donde:

- $\bar{D} = \frac{1}{n} \sum_{i=1}^n D_i$ (media de diferencias)
- $S_D = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D})^2}$ (desviación típica de diferencias)

Hipótesis típicas:

- $H_0 : \mu_D = 0$ (no hay diferencia)
- $H_1 : \mu_D \neq 0$ (hay diferencia)

Diferencia de Proporciones

Condiciones: n_1 y n_2 grandes

Estadístico de prueba:

$$Z = \frac{\hat{p}_1 - \hat{p}_2 - (p_1 - p_2)_0}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1)$$

donde $\hat{p} = \frac{X_1+X_2}{n_1+n_2}$ (proporción combinada)

Regiones críticas:

Cociente de Varianzas

Condiciones: Poblaciones normales e independientes

Estadístico de prueba:

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} = \frac{S_1^2}{S_2^2} \sim F_{n_1-1,n_2-1}$$

(bajo $H_0 : \sigma_1^2 = \sigma_2^2$)

Regiones críticas:

- $H_1 : \sigma_1^2 > \sigma_2^2$: Rechazar si $F > F_{\alpha,n_1-1,n_2-1}$
- $H_1 : \sigma_1^2 < \sigma_2^2$: Rechazar si $F < F_{1-\alpha,n_1-1,n_2-1}$
- $H_1 : \sigma_1^2 \neq \sigma_2^2$: Rechazar si $F < F_{1-\alpha/2,n_1-1,n_2-1}$ o $F > F_{\alpha/2,n_1-1,n_2-1}$

Nota: $F_{1-\alpha,\nu_1,\nu_2} = \frac{1}{F_{\alpha,\nu_2,\nu_1}}$

Distribución F de Fisher

Definición: Si $U \sim \chi^2_{\nu_1}$ y $V \sim \chi^2_{\nu_2}$ son independientes, entonces:

$$F = \frac{U/\nu_1}{V/\nu_2} \sim F_{\nu_1,\nu_2}$$

Propiedades:

- F_{ν_1,ν_2} tiene dos parámetros: grados de libertad del numerador (ν_1) y del denominador (ν_2)
- $F_{1-\alpha,\nu_1,\nu_2} = \frac{1}{F_{\alpha,\nu_2,\nu_1}}$
- Usada para comparar varianzas de dos poblaciones normales

Tabla de Decisión

Decisión	H_0 verdadera	H_0 falsa
Rechazar H_0	Error Tipo I (α)	Decisión correcta (Poder)
No rechazar H_0	Decisión correcta ($1 - \alpha$)	Error Tipo II (β)

Consideraciones Importantes

Verificar supuestos:

- Normalidad (si es necesario)
- Tamaño muestral adecuado
- Independencia de observaciones

Interpretación:

- ”No rechazar H_0 ” $\neq$ ”Aceptar H_0 ”
- El p -valor mide la evidencia contra H_0
- Considerar el tamaño del efecto, no solo la significación

Relación con I.C.:

- Si θ_0 está fuera del I.C. ($1 - \alpha$): Rechazar H_0 al nivel α
- Si θ_0 está dentro del I.C. ($1 - \alpha$): No rechazar H_0 al nivel α

Bondad de Ajuste

Contrastes Paramétricos vs No Paramétricos

Contrastes paramétricos: Suponen que conocemos el tipo de distribución de la población (normal, binomial, Poisson, etc.) y contrastan hipótesis sobre los parámetros desconocidos (media, varianza, proporción, etc.).

Contrastes no paramétricos: No suponen un tipo específico de distribución. La hipótesis nula consiste en verificar si la distribución de la variable X es de un tipo determinado.

Procedimiento típico:

- Primero: Verificar la distribución usando contrastes no paramétricos (bondad de ajuste)
- Segundo: Si se acepta la distribución, usar contrastes paramétricos para los parámetros

Contraste de Bondad de Ajuste

Hipótesis:

$$\begin{cases} H_0 : \text{La distribución de } X \text{ es del tipo } X_0 \\ H_1 : \text{La distribución de } X \text{ no es del tipo } X_0 \end{cases}$$

donde X_0 es un tipo de distribución conocida (normal, binomial, Poisson, etc.), sin especificar parámetros.

Objetivo: Determinar si una muestra proviene de una distribución teórica específica.

Pruebas Gráficas

Histogramas y Densidad

Objetivo: Comparar visualmente la función de densidad estimada de la muestra con la función de densidad teórica.

Método:

- Estimar la densidad muestral usando `density()` en R
- Superponer la densidad teórica con parámetros estimados de la muestra
- Comparar visualmente las formas

Limitación: Prueba subjetiva, no cuantitativa.

Q-Q Plots (Cuantil-Cuantil)

Objetivo: Comparar los cuantiles observados de la muestra con los cuantiles teóricos de la distribución.

Interpretación:

- Si los puntos están cerca de la recta $y = x$: buena concordancia
- Desviaciones sistemáticas: indican diferencias con la distribución teórica

En R: `qqPlot()` del paquete `car`

- `distribution`: nombre de la distribución (entre comillas)
- Parámetros: `mean`, `sd`, `df`, etc.

Test Chi-Cuadrado de Bondad de Ajuste

Test χ^2 de Bondad de Ajuste

Condiciones:

- Muestra de tamaño n
- Datos agrupados en k clases o categorías
- Frecuencias observadas: O_i para $i = 1, \dots, k$
- Frecuencias esperadas: $E_i = n \cdot p_i$ donde p_i es la probabilidad teórica de la clase i

Estadístico de prueba:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi^2_{k-1-r}$$

donde r es el número de parámetros estimados a partir de la muestra.

Región crítica: Rechazar H_0 si $\chi^2 > \chi^2_{\alpha, k-1-r}$

Condición de aplicación: $E_i \geq 5$ para todas las clases (si no, agrupar clases).

En R: `chisq.test`

Sintaxis:

- `chisq.test(x, p = ...)`
- `x`: vector de frecuencias observadas
- `p`: vector de probabilidades teóricas

Parámetros importantes:

- `rescale.p = TRUE`: si `p` no suma 1
- `simulate.p.value = TRUE`: calcular p -valor por simulación
- `B`: número de simulaciones

Consideraciones

Ventajas:

- Aplicable a distribuciones discretas y continuas
- No requiere normalidad
- Fácil de aplicar

Desventajas:

- Requiere agrupar datos continuos
- Sensible a la elección de clases
- Requiere frecuencias esperadas ≥ 5

Tests de Normalidad

Test de Kolmogorov-Smirnov (K-S)

Objetivo: Contrastar si una muestra proviene de una distribución continua específica.
Estadístico:

$$D = \max_x |F_n(x) - F_0(x)|$$

donde:

- $F_n(x)$: función de distribución empírica
- $F_0(x)$: función de distribución teórica

En R: `ks.test(x, "distribución", parámetros)`

- `ks.test(x, y)`: contrasta si x e y provienen de la misma distribución
- `ks.test(x, "pnorm", mean, sd)`: contrasta normalidad

Limitación: Requiere que los parámetros sean conocidos (no estimados).

Test de Lilliefors (K-S-L)

Objetivo: Test de normalidad cuando los parámetros (μ, σ) se estiman de la muestra.
Mejora sobre K-S: Más robusto al estimar parámetros.
En R: `lillie.test()` del paquete `nortest`
Características:

- Muy sensible a diferencias alrededor de la media
- Menos sensible a diferencias en los extremos
- Puede fallar con distribuciones de colas pesadas (ej: t de Student)

Problema: Con muestras grandes (> 1000), aumenta probabilidad de Error Tipo I.

Test de Anderson-Darling (A-D)

Objetivo: Test de normalidad que resuelve el problema de K-S-L en los extremos.
Estadístico: Basado en diferencias ponderadas entre F_n y F_0 , dando más peso a los extremos.
En R: `ad.test()` del paquete `nortest`
Ventajas:

- Detecta mejor diferencias en los extremos
- Más potente que K-S-L para distribuciones con colas pesadas

Desventaja: Con muestras muy grandes, aumenta probabilidad de Error Tipo I.

Test de Shapiro-Wilk (S-W)

Objetivo: Test de normalidad robusto para muestras de cualquier tamaño.
Estadístico: Basado en la correlación entre los valores ordenados de la muestra y los valores esperados bajo normalidad.
En R: `shapiro.test()` (instalación básica de R)
Ventajas:

- Funciona bien con muestras pequeñas y grandes
- Alta potencia
- Menos afectado por empates que K-S-L y A-D

Limitación:

- Solo para normalidad (no otras distribuciones)
- Tamaño máximo recomendado: $n \leq 5000$

Test de D'Agostino-Pearson

Objetivo: Test de normalidad basado en asimetría y curtosis.
Estadísticos:

- Z_3 : Test de asimetría (skewness)
- Z_4 : Test de curtosis (kurtosis)
- χ^2 Omnibus: Combina ambos tests

En R: `dagoTest()` del paquete `fBasics`
Condición: Requiere $n \geq 20$
Ventaja: No es sensible a empates (a diferencia de K-S-L, A-D, S-W).
Interpretación: Compara la forma de la distribución muestral con la forma esperada de una normal.

Comparación de Tests de Normalidad

Test	Tamaño muestral	Sensible a extremos	Sensible a empates	Potencia
K-S-L	Pequeño-Grande	Baja	Sí	Media
A-D	Pequeño-Grande	Alta	Sí	Alta
S-W	Pequeño-Grande	Media	Baja	Alta
D'Agostino-Pearson	≥ 20	Media	No	Media

Recomendaciones:

- **Muestras pequeñas** ($n < 50$): S-W o A-D
- **Muestras medianas** ($50 \leq n < 1000$): S-W (preferido) o A-D
- **Muestras grandes** ($n \geq 1000$): Cuidado con todos (aumentan Error Tipo I)
- **Con empates:** D'Agostino-Pearson o S-W
- **Distribuciones de colas pesadas:** A-D o S-W

Guía Rápida de Funciones R

Pruebas gráficas:

- `density(x)`: Estimación de densidad
- `qqPlot(x, distribution=..., ...)`: Q-Q plot (paquete `car`)

Tests de bondad de ajuste:

- `chisq.test(x, p=...)`: Test χ^2 de bondad de ajuste
- `ks.test(x, "distribución", ...)`: Test de Kolmogorov-Smirnov

Tests de normalidad:

- `lillie.test(x)`: Test de Lilliefors (paquete `nortest`)
- `ad.test(x)`: Test de Anderson-Darling (paquete `nortest`)
- `shapiro.test(x)`: Test de Shapiro-Wilk
- `dagoTest(x)`: Test de D'Agostino-Pearson (paquete `fBasics`)

Contrastes de Independencia y Homogeneidad

Introducción

Objetivo: Contrastar si dos criterios de clasificación X e Y son independientes o si las distribuciones de una variable son homogéneas entre diferentes grupos.

Aplicación: Una de las aplicaciones más usadas del test de bondad de ajuste χ^2 .

Ejemplo: ¿Es el hecho de contraer hepatitis independiente de haber sido vacunado? (equivalente a: ¿es efectiva la vacuna?)

Tablas de Contingencia

Situación: Tenemos n individuos clasificados según dos criterios:

- Criterio X : con niveles $x_1, \dots, x_I$
- Criterio Y : con niveles $y_1, \dots, y_J$

Notación:

- n_{ij} : número de individuos en nivel x_i de X y nivel y_j de Y
- $n_{i\bullet} = \sum_{j=1}^J n_{ij}$: total de la fila i
- $n_{\bullet j} = \sum_{i=1}^I n_{ij}$: total de la columna j
- $n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}$: total de individuos

Tabla de contingencia:

$X \backslash Y$	y_1	$\dots$	y_j	$\dots$	y_J	$n_{i\bullet}$
x_1	n_{11}	$\dots$	n_{1j}	$\dots$	n_{1J}	$n_{1\bullet}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_i	n_{i1}	$\dots$	n_{ij}	$\dots$	n_{iJ}	$n_{i\bullet}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_I	n_{I1}	$\dots$	n_{Ij}	$\dots$	n_{IJ}	$n_{I\bullet}$
$n_{\bullet j}$	$n_{\bullet 1}$	$\dots$	$n_{\bullet j}$	$\dots$	$n_{\bullet J}$	n

Contraste de Independencia

Hipótesis del Contraste de Independencia

Hipótesis:

H_0 : Los criterios X e Y son independientes

H_1 : Los criterios X e Y no son independientes

Interpretación: X e Y son independientes si:

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j)$$

para todo $i = 1, \dots, I$ y $j = 1, \dots, J$.

Test χ^2 de Independencia

Modelo bajo H_0 : Variable aleatoria bidimensional (X, Y) con:

$$P((X, Y) = (x_i, y_j)) = P(X = x_i) \cdot P(Y = y_j) = \frac{n_{i\bullet}}{n} \cdot \frac{n_{\bullet j}}{n} = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n^2}$$

Frecuencias esperadas:

$$E_{ij} = n \cdot P((X, Y) = (x_i, y_j)) = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}$$

Estadístico de prueba:

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - E_{ij})^2}{E_{ij}} = \sum_{i=1}^I \sum_{j=1}^J \frac{\left(n_{ij} - \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} \cdot n_{\bullet j}}{n}}$$

Distribución: Bajo H_0 , si n es grande y $E_{ij} \geq 5$ para todo i, j :

$$\chi^2 \sim \chi_{(I-1)(J-1)}^2$$

Región crítica: Rechazar H_0 si $\chi^2 > \chi_{\alpha, (I-1)(J-1)}^2$

Grados de Libertad

Cálculo: $\nu = (I - 1)(J - 1)$

Justificación:

- $I \cdot J$ celdas en total
- I restricciones (suma de filas)
- J restricciones (suma de columnas)
- 1 restricción (suma total)
- $\nu = IJ - I - J + 1 = (I - 1)(J - 1)$

Condiciones de Aplicación

Requisitos:

- n suficientemente grande
- $E_{ij} \geq 5$ para todas las celdas (i, j)

Si no se cumple:

- Agrupar categorías adyacentes
- Usar simulación para calcular p -valor

En R: `chisq.test(..., simulate.p.value = TRUE)`

Contraste de Homogeneidad

Hipótesis del Contraste de Homogeneidad

Hipótesis:

$$\begin{cases} H_0 : \text{La distribución de } Y \text{ es la misma para todos los niveles de } X \\ H_1 : \text{La distribución de } Y \text{ no es la misma para todos los niveles de } X \end{cases}$$

Interpretación: Verificar si las distribuciones condicionales $P(Y = y_j \mid X = x_i)$ son iguales para todos los valores de X .

Equivalencia: Si $P(Y = y_j \mid X = x_i) = P(Y = y_j)$ para todo i , entonces X e Y son independientes.

Test χ^2 de Homogeneidad

Modelo bajo H_0 : Para cada fila i , la distribución de Y es la misma:

$$P(Y = y_j \mid X = x_i) = \frac{n_{\bullet j}}{n}$$

Frecuencias esperadas (para la fila i):

$$E_{ij} = n_{i\bullet} \cdot P(Y = y_j \mid X = x_i) = n_{i\bullet} \cdot \frac{n_{\bullet j}}{n} = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}$$

Estadístico de prueba:

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - E_{ij})^2}{E_{ij}} = \sum_{i=1}^I \sum_{j=1}^J \frac{\left(n_{ij} - \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} \cdot n_{\bullet j}}{n}}$$

Observación: ¡La misma expresión que en el test de independencia!

Distribución: $\chi^2 \sim \chi^2_{(I-1)(J-1)}$ (bajo H_0)

Diseño Experimental: Independencia

Procedimiento:

- Se toma una muestra transversal de n individuos
- Se clasifica cada individuo según X e Y
- Los totales de filas y columnas son aleatorios

Ejemplo: Muestra aleatoria de 1083 voluntarios, clasificados por vacunación y enfermedad.

Pregunta: ¿Son independientes las dos clasificaciones?

Diseño Experimental: Homogeneidad

Procedimiento:

- Se fijan los tamaños de muestra $n_{i\bullet}$ para cada nivel de X
- Para cada x_i , se toma una muestra aleatoria de tamaño $n_{i\bullet}$
- Se observa la variable Y en cada muestra
- Los totales de filas están fijados de antemano

Ejemplo: 50 clientes del Norte, 100 del Centro, 50 del Sur (fijados). Se observa número de lotes comprados.

Pregunta: ¿Es la distribución de Y igual en los tres grupos?

Comparación: Independencia vs Homogeneidad

Aspecto	Independencia	Homogeneidad
Muestra	Transversal (una sola)	Estratificada (múltiples)
Totales de filas	Aleatorios	Fijados de antemano
Objetivo	Verificar independencia	Verificar igualdad de distribuciones
Estadístico	χ^2 (mismo)	χ^2 (mismo)
Grados de libertad	$(I - 1)(J - 1)$	$(I - 1)(J - 1)$
Interpretación	$P(X, Y) = P(X) \cdot P(Y)$	$P(Y \mid X) = P(Y)$

Conclusión: Desde el punto de vista computacional, ambos contrastes son idénticos. La diferencia está en el diseño experimental y la interpretación.

Funciones R para Tablas de Contingencia

Construcción de Tablas

`table(x, y)`: Crea tabla de contingencia de frecuencias absolutas.

`prop.table(tabla)`: Convierte a frecuencias relativas (proporciones).

`prop.table(tabla, margin=1)`: Frecuencias relativas por filas.

Operaciones con Tablas

colSums(tabla): Vector con sumas de columnas.
rowSums(tabla): Vector con sumas de filas.
chisq.test(tabla): Test χ^2 de independencia/homogeneidad.
Resultado de chisq.test:

- **statistic:** valor de χ^2
- **parameter:** grados de libertad
- **p.value:** p -valor
- **expected:** frecuencias esperadas

chisq.test: Parámetros Avanzados

Sintaxis básica:

- **chisq.test(tabla):** Test estándar
- **chisq.test(x, y):** Si x e y son vectores

Parámetros importantes:

- **simulate.p.value = TRUE:** Calcula p -valor mediante simulaciones (útil cuando $E_{ij} < 5$)
- **B:** Número de simulaciones (por defecto 2000)
- **correct = TRUE/FALSE:** Corrección de Yates (solo para tablas 2×2)

Ejemplo:

```
tabla <- matrix(c(11, 70, 538, 464), 2, 2)
chisq.test(tabla)
chisq.test(tabla, simulate.p.value = TRUE, B = 10000)
```

Ejemplo: Vacuna de Hepatitis

Datos:

	Vacunado	No vacunado	Total
Enfermo	11	70	81
No enfermo	538	464	1002
Total	549	534	1083

Hipótesis:

- H_0 : Vacunación e infección son independientes (vacuna no efectiva)
- H_1 : Vacunación e infección no son independientes (vacuna efectiva)

En R:

```
tabla <- matrix(c(11, 70, 538, 464), 2, 2,
                 byrow = TRUE)
chisq.test(tabla)
```

Interpretación: Si rechazamos H_0 , hay evidencia de que la vacuna es efectiva.

Tabla 2×2 : Caso Especial

Formato:

	Y_1	Y_2
X_1	a	b
X_2	c	d

Estadístico:

$$\chi^2 = \frac{n(ad - bc)^2}{(a + b)(c + d)(a + c)(b + d)}$$

con $\nu = 1$ grado de libertad.

Corrección de Yates (si n pequeño):

$$\chi^2 = \frac{n(|ad - bc| - n/2)^2}{(a + b)(c + d)(a + c)(b + d)}$$

Consideraciones Finales

Verificar condiciones:

- Todas las frecuencias esperadas ≥ 5
- Si no, usar simulación o agrupar categorías

Interpretación:

- Rechazar H_0 : Hay asociación/dependencia
- No rechazar H_0 : No hay evidencia de asociación

Límites:

- Test asintótico (requiere n grande)
- No indica dirección ni fuerza de asociación
- Para medir fuerza: coeficiente de contingencia, V de Cramér

Regresión Lineal Simple

Introducción

Objetivo: Hallar la mejor relación funcional entre dos variables X e Y a partir de una muestra $\{(x_i, y_i)\}_{i=1, \dots, n}$.

Variable dependiente (respuesta): Y - variable aleatoria que queremos predecir.

Variable independiente (regresora): X - variable de control o explicativa (no necesariamente aleatoria).

Modelo de regresión lineal: Si la relación es una recta:

$$\mu_{Y|x} = \beta_0 + \beta_1 x$$

donde $\mu_{Y|x}$ es el valor esperado de Y cuando $X = x$.

Parámetros a estimar: β_0 (ordenada al origen) y β_1 (pendiente).

Modelo de Regresión Lineal

Ecuación del modelo:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

donde:

- y_i : valor observado de Y para x_i
- $\beta_0 + \beta_1 x_i$: valor predicho por el modelo
- ε_i : error aleatorio (residuo)

Estimaciones: b_0 y b_1 estiman β_0 y β_1 respectivamente.

Recta de regresión estimada:

$$\hat{y} = b_0 + b_1 x$$

Predicción: Para x_0 , $\hat{y}_0 = b_0 + b_1 x_0$.

Método de Mínimos Cuadrados

Método de Mínimos Cuadrados

Error cuadrático teórico:

$$SS_\varepsilon = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Objetivo: Encontrar b_0 y b_1 que minimizan SS_ε .

Condiciones de mínimo (derivadas igualadas a cero):

$$\left. \frac{\partial SS_\varepsilon}{\partial \beta_0} \right|_{\beta_0=b_0, \beta_1=b_1} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0$$
$$\left. \frac{\partial SS_\varepsilon}{\partial \beta_1} \right|_{\beta_0=b_0, \beta_1=b_1} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) x_i = 0$$

Justificación: Se elevan los errores al cuadrado para penalizar siempre los errores (positivos y negativos) y evitar que se anulen.

Estimadores de Mínimos Cuadrados

Solución del sistema:

$$b_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}$$
$$b_0 = \frac{\sum_{i=1}^n y_i - b_1 \sum_{i=1}^n x_i}{n} = \bar{y} - b_1 \bar{x}$$

En términos de estadísticos muestrales:

- $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ (medias)
- $\tilde{s}_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ (varianza muestral de X)
- $\tilde{s}_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$ (varianza muestral de Y)
- $\tilde{s}_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$ (covarianza muestral)

Forma alternativa:

$$b_1 = \frac{\tilde{s}_{xy}}{\tilde{s}_x^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$b_0 = \bar{y} - b_1 \bar{x}$$

Coefficiente de Correlación y Determinación

Coefficiente de Correlación

Definición:

$$\tilde{s}_{xu} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Coefficiente de Determinación R^2

Definición:

$$R^2 = r^2 = \frac{\tilde{s}_{xy}^2}{\tilde{s}_x^2 \tilde{s}_y^2}$$

Interpretación: Proporción de la varianza de Y explicada por el modelo.

Propiedades:

- $0 \leq R^2 \leq 1$
- $R^2 = 1$: el modelo explica toda la variabilidad
- $R^2 = 0$: el modelo no explica nada
- R^2 cercano a 1: buen ajuste

Suma de cuadrados:

$$R^2 = \frac{SS_{reg}}{SS_{tot}} = 1 - \frac{SS_{res}}{SS_{tot}}$$

donde SS_{reg} es la suma de cuadrados de la regresión y SS_{res} es la suma de cuadrados de los residuos.

Descomposición de la Varianza

Suma total de cuadrados:

$$SS_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2$$

Suma de cuadrados de la regresión:

$$SS_{reg} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

Suma de cuadrados de los residuos:

$$SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \varepsilon_i^2$$

Identidad fundamental:

$$SS_{tot} = SS_{reg} + SS_{res}$$

Coefficiente de determinación:

$$R^2 = \frac{SS_{reg}}{SS_{tot}} = 1 - \frac{SS_{res}}{SS_{tot}}$$

Inferencia en Regresión Lineal

Supuestos del Modelo

Modelo:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Supuestos sobre los errores:

- $E(\varepsilon_i) = 0$ para todo i
- $\text{Var}(\varepsilon_i) = \sigma^2$ (homocedasticidad)
- ε_i independientes
- $\varepsilon_i \sim N(0, \sigma^2)$ (normalidad, opcional para inferencia)

Consecuencias:

- $E(Y_i \mid x_i) = \beta_0 + \beta_1 x_i$
- $\text{Var}(Y_i \mid x_i) = \sigma^2$

Estimación de σ^2

Varianza residual:

$$s^2 = \frac{SS_{res}}{n - 2} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - 2}$$

Desviación estándar residual:

$$s = \sqrt{s^2}$$

Grados de libertad: $n - 2$ (se pierden 2 grados por estimar β_0 y β_1).

Interpretación: Medida de la dispersión de los datos alrededor de la recta de regresión.

Inferencia sobre los Parámetros

Distribuciones (bajo normalidad):

- $b_0 \sim N\left(\beta_0, \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2}\right]\right)$
- $b_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right)$

Errores estándar estimados:

$$SE(b_0) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2}}$$
$$SE(b_1) = \frac{s}{\sqrt{\sum (x_i - \bar{x})^2}}$$

Estadísticos t:

$$t_0 = \frac{b_0 - \beta_0}{SE(b_0)} \sim t_{n-2}, \quad t_1 = \frac{b_1 - \beta_1}{SE(b_1)} \sim t_{n-2}$$

Intervalos de confianza (nivel $1 - \alpha$):

$$b_0 \pm t_{\alpha/2, n-2} \cdot SE(b_0), \quad b_1 \pm t_{\alpha/2, n-2} \cdot SE(b_1)$$

Contrastes de hipótesis:

- $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$: ¿Hay relación lineal?
- $H_0 : \beta_0 = 0$ vs $H_1 : \beta_0 \neq 0$: ¿Pasa por el origen?

Transformaciones y Modelos No Lineales

Modelo Potencial

Modelo: $y = \beta_0 \cdot x^{\beta_1}$ con $\beta_0 > 0$

Transformación: Aplicar $\log_{10}$ a ambos lados:

$$\log_{10}(y) = \log_{10}(\beta_0) + \beta_1 \log_{10}(x)$$

Modelo lineal equivalente:

$$Y' = \beta'_0 + \beta_1 X'$$

donde $Y' = \log_{10}(y)$, $X' = \log_{10}(x)$, $\beta'_0 = \log_{10}(\beta_0)$, $\beta'_1 = \beta_1$.

Estimación:

- Ajustar $\text{lm}(\log_{10}(y) \sim \log_{10}(x))$
- Obtener b'_0 y b'_1
- $\beta_0 = 10^{b'_0}$, $\beta_1 = b'_1$

Gráfico: Escala log-log (ambos ejes logarítmicos).

Modelo Exponencial

Modelo: $y = \beta_0 \cdot \beta_1^x$ con $\beta_0 > 0$, $\beta_1 > 0$

Transformación: Aplicar $\log_{10}$ solo a y :

$$\log_{10}(y) = \log_{10}(\beta_0) + \log_{10}(\beta_1) \cdot x$$

Modelo lineal equivalente:

$$Y' = \beta'_0 + \beta'_1 x$$

donde $Y' = \log_{10}(y)$, $\beta'_0 = \log_{10}(\beta_0)$, $\beta'_1 = \log_{10}(\beta_1)$.

Estimación:

- Ajustar $\text{lm}(\log_{10}(y) \sim x)$
- Obtener b'_0 y b'_1
- $\beta_0 = 10^{b'_0}$, $\beta_1 = 10^{b'_1}$

Gráfico: Escala semi-logarítmica (solo eje y logarítmico).

Resumen de Transformaciones

Modelo	Ecuación	Transformación	Modelo Lineal
Lineal	$y = \beta_0 + \beta_1 x$	Ninguna	$y = \beta_0 + \beta_1 x$
Potencial	$y = \beta_0 x^{\beta_1}$	$\log_{10}(y), \log_{10}(x)$	$Y' = \beta'_0 + \beta_1 X'$
Exponencial	$y = \beta_0 \beta_1^x$	$\log_{10}(y)$	$Y' = \beta'_0 + \beta'_1 x$
Logarítmico	$y = \beta_0 + \beta_1 \log(x)$	$\log(x)$	$y = \beta_0 + \beta_1 X'$

Nota: Después de la transformación, se aplica regresión lineal estándar y luego se transforman los parámetros de vuelta a la escala original.

Funciones R para Regresión Lineal

lm(): Ajuste del Modelo

Sintaxis:

```
modelo <- lm(y ~ x)
modelo <- lm(y ~ x + 1) # explícito
```

Resultado: Objeto de clase lm con:

- coefficients:** b_0 y b_1
- fitted.values:** valores predichos $\hat{y}_i$
- residuals:** residuos ε_i
- df.residual:** grados de libertad $(n - 2)$

Acceso:

- `modelo$coefficients[1]:` b_0
- `modelo$coefficients[2]:` b_1

summary(): Resumen del Modelo

Sintaxis: summary(modelo)

Información proporcionada:

- Estimate: estimaciones b_0 y b_1
- Std. Error: errores estándar
- t value: estadísticos t
- Pr(> |t|): p -valores
- Residual standard error: s (desviación estándar residual)
- Multiple R-squared: R^2
- Adjusted R-squared: R^2 ajustado
- F-statistic: estadístico F para el modelo

Funciones Adicionales

Predicción:

- predict(modelo, newdata = data.frame(x = x0)): Predice y para x_0
- predict(modelo, interval = "confidence"): Intervalos de confianza para la media
- predict(modelo, interval = "prediction"): Intervalos de predicción para observaciones

Diagnóstico:

- plot(modelo): Gráficos de diagnóstico (4 gráficos)
- residuals(modelo): Residuos
- fitted(modelo): Valores ajustados

Información del modelo:

- coef(modelo): Coeficientes
- confint(modelo): Intervalos de confianza para los parámetros
- anova(modelo): Tabla ANOVA

Gráficos:

- plot(x, y): Diagrama de dispersión
- abline(modelo): Añade la recta de regresión
- lines(x, y_pred): Añade curva predicha

Ejemplo: Modelo Potencial

Datos: $y = 11 \cdot x^2$ (con error)

Código R:

```
# Transformación
modelo <- lm(log10(y) ~ log10(x))

# Parámetros estimados
b0 <- modelo$coefficients[1]
b1 <- modelo$coefficients[2]

# Transformación inversa
beta0 <- 10^b0
beta1 <- b1

# Recta estimada
y_est <- beta0 * x^beta1
```

Resultado: $\beta_0 \approx 11$, $\beta_1 \approx 2$

Ejemplo: Modelo Exponencial

Datos: $y = 3 \cdot 2^x$ (con error)

Código R:

```
# Transformación
modelo <- lm(log10(y) ~ x)

# Parámetros estimados
b0 <- modelo$coefficients[1]
b1 <- modelo$coefficients[2]

# Transformación inversa
beta0 <- 10^b0
beta1 <- 10^b1

# Curva estimada
y_est <- beta0 * beta1^x
```

Resultado: $\beta_0 \approx 3$, $\beta_1 \approx 2$

Consideraciones Importantes

Validación del modelo:

- Verificar supuestos (normalidad de residuos, homocedasticidad)
- Revisar gráficos de diagnóstico
- Comprobar outliers e influyentes
- Validar R^2 y significación de parámetros

Limitaciones:

- Relación lineal (o linealizable)
- Independencia de observaciones
- Homocedasticidad (varianza constante)
- No extrapolar fuera del rango de X observado

Interpretación:

- b_1 : cambio esperado en Y por unidad de cambio en X
- b_0 : valor esperado de Y cuando $X = 0$ (si tiene sentido)
- R^2 : proporción de variabilidad explicada

Clustering

Introducción al Clustering

Problema: Dado un conjunto de objetos, clasificarlos en grupos (clusters) basándonos en sus parecidos y diferencias.

Aplicaciones:

- **Biología:** Clasificación jerárquica de organismos, agrupamiento de genes y proteínas
- **Marketing:** Identificación de individuos por comportamientos similares
- **Tratamiento de imágenes:** Eliminación de ruido, detección de bordes
- **Biometría:** Identificación de individuos (caras, huellas dactilares)

Objetivo: Encontrar grupos naturales en los datos sin etiquetas previas (aprendizaje no supervisado).

Principios Básicos

Homogeneidad: Los objetos dentro de un mismo cluster deben ser próximos o parecidos entre sí.

Separación: Los objetos que pertenecen a clusters diferentes deben estar alejados.

Objetivo: Maximizar la homogeneidad dentro de los clusters y maximizar la separación entre clusters.

Validación: Un buen clustering cumple ambos principios simultáneamente.

Tipos de Algoritmos

Algoritmos de partición:

- Número de clusters k prefijado
- Ejemplo: k -medias (k -means)

Algoritmos jerárquicos:

- Producen un árbol de clasificación (dendrograma)
- **Aglomerativos:** De n clusters a 1 (bottom-up)
- **Divisivos:** De 1 cluster a n (top-down)

Resultado jerárquico: Árbol binario donde cada nodo representa una agrupación/división.

Algoritmo k-medias (k-means)

Descripción del Problema

Datos: Tabla de n filas (objetos) y m columnas (variables continuas).

Representación: Cada objeto i se representa como un vector:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{im}) \in \mathbb{R}^m$$

Objetivo: Encontrar k puntos (centros) $\mathbf{c}_1, \dots, \mathbf{c}_k \in \mathbb{R}^m$ y una partición de los n objetos en k clusters $C_1, \dots, C_k$ tal que se minimice:

$$SS_C = \sum_{j=1}^k \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \mathbf{c}_j\|^2$$

donde $\|\mathbf{x}_i - \mathbf{c}_j\|$ es la distancia euclídea entre el objeto $\mathbf{x}_i$ y el centro $\mathbf{c}_j$.

Distancia Euclídea

Definición: Dados dos objetos $\mathbf{x} = (x_1, \dots, x_m)$ e $\mathbf{y} = (y_1, \dots, y_m)$ en $\mathbb{R}^m$:

$$\|\mathbf{x} - \mathbf{y}\| = \sqrt{\sum_{i=1}^m (x_i - y_i)^2}$$

Interpretación: Para $m = 2$ o $m = 3$, es la longitud del segmento que une los puntos.

Propiedad: Dos objetos están más próximos cuanto menor es la distancia euclídea entre ellos.

Uso: Medida de proximidad entre objetos en el espacio de características.

Algoritmo k-medias: Pasos

Inicialización:

1. Elegir k centros iniciales $\mathbf{c}_1^{(0)}, \dots, \mathbf{c}_k^{(0)}$ aleatoriamente

Iteración (repetir hasta convergencia):

1. **Asignación:** Para cada objeto $\mathbf{x}_i$, asignarlo al cluster C_j cuyo centro $\mathbf{c}_j$ esté más cerca:

$$\mathbf{x}_i \in C_j \text{ si } \|\mathbf{x}_i - \mathbf{c}_j\| = \min_{l=1, \dots, k} \|\mathbf{x}_i - \mathbf{c}_l\|$$

2. **Actualización:** Recalcular los centros como las medias de los objetos en cada cluster:

$$\mathbf{c}_j = \frac{1}{|C_j|} \sum_{\mathbf{x}_i \in C_j} \mathbf{x}_i$$

Criterio de parada: Cuando los clusters no cambian entre iteraciones (o cambio mínimo).

Propiedades del Algoritmo

Ventajas:

- Simple y eficiente
- Escalable a grandes conjuntos de datos
- Converge rápidamente

Desventajas:

- Requiere especificar k a priori
- Sensible a la inicialización
- Puede quedar atrapado en mínimos locales
- Asume clusters esféricos y de tamaño similar

Solución: Ejecutar múltiples veces con diferentes inicializaciones y elegir el mejor resultado.

Suma de Cuadrados

Suma de cuadrados dentro de clusters:

$$SS_C = \sum_{j=1}^k SS_{C_j} = \sum_{j=1}^k \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \mathbf{c}_j\|^2$$

Suma total de cuadrados:

$$SS_{tot} = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2$$

donde $\bar{\mathbf{x}}$ es el centroide global.

Suma entre clusters:

$$SS_{between} = SS_{tot} - SS_C$$

Interpretación: Minimizar SS_C equivale a maximizar $SS_{between}$.

Clustering Jerárquico

Métodos Jerárquicos Aglomerativos

Proceso:

- **Paso inicial:** Cada objeto forma su propio cluster (n clusters)
- **En cada paso:** Se unen los dos clusters más próximos
- **Paso final:** Un único cluster con todos los objetos

Resultado: Dendrograma (árbol binario) que muestra la jerarquía de agrupaciones.

Ventajas:

- No requiere especificar k a priori
- Proporciona jerarquía completa
- Visualización clara del proceso

Desventajas:

- Computacionalmente más costoso ($O(n^3)$)
- Decisiones irreversibles
- Sensible a outliers

Métodos de Enlace

Enlace simple (single):

$$d(C_i, C_j) = \min_{\mathbf{x} \in C_i, \mathbf{y} \in C_j} \|\mathbf{x} - \mathbf{y}\|$$

Distancia mínima entre clusters.

Enlace completo (complete):

$$d(C_i, C_j) = \max_{\mathbf{x} \in C_i, \mathbf{y} \in C_j} \|\mathbf{x} - \mathbf{y}\|$$

Distancia máxima entre clusters.

Enlace promedio (average):

$$d(C_i, C_j) = \frac{1}{|C_i| \cdot |C_j|} \sum_{\mathbf{x} \in C_i} \sum_{\mathbf{y} \in C_j} \|\mathbf{x} - \mathbf{y}\|$$

Distancia promedio entre clusters.

Métodos de Enlace (cont.)

Mediana (median):

$$d(C_i, C_j) = \|\mathbf{c}_i - \mathbf{c}_j\|$$

donde $\mathbf{c}_i$ y $\mathbf{c}_j$ son las medianas de los clusters.

Centroide (centroid):

$$d(C_i, C_j) = \|\bar{\mathbf{x}}_i - \bar{\mathbf{x}}_j\|$$

donde $\bar{\mathbf{x}}_i$ y $\bar{\mathbf{x}}_j$ son los centroides.

Ward (ward.D):

$$d(C_i, C_j) = \frac{|C_i| \cdot |C_j|}{|C_i| + |C_j|} \|\bar{\mathbf{x}}_i - \bar{\mathbf{x}}_j\|^2$$

Minimiza la varianza dentro de clusters.

Dendrograma

Definición: Representación gráfica del árbol jerárquico de clustering.

Elementos:

- **Hojas:** Objetos individuales (base del árbol)
- **Nodos:** Uniones de clusters
- **Altura:** Distancia a la que se unen los clusters
- **Raíz:** Cluster único con todos los objetos (cima del árbol)

Corte del dendrograma:

- Por altura h : Cortar a una distancia específica
- Por número de clusters k : Obtener k clusters

Interpretación: La altura indica la "distancia" entre clusters unidos.

Distancias y Escalado

Tipos de Distancias

Euclídea (por defecto):

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^m (x_i - y_i)^2}$$

Manhattan:

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^m |x_i - y_i|$$

Máximo:

$$d(\mathbf{x}, \mathbf{y}) = \max_{i=1, \dots, m} |x_i - y_i|$$

Canberra:

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^m \frac{|x_i - y_i|}{|x_i| + |y_i|}$$

Tipos de Distancias (cont.)

Minkowski (con parámetro $p > 0$):

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_{i=1}^m |x_i - y_i|^p \right)^{1/p}$$

- $p = 1$: Manhattan
- $p = 2$: Euclídea
- $p \rightarrow \infty$: Máximo

Binaria (para vectores binarios):

$$d(\mathbf{x}, \mathbf{y}) = \frac{\text{número de posiciones diferentes}}{\text{número de posiciones con al menos un 1}}$$

Nota: La elección de la distancia afecta significativamente los resultados del clustering.

Escalado de Datos

Problema: Variables con diferentes escalas pueden dominar el clustering.

Solución: Estandarizar las variables antes del clustering.

Estandarización:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

donde:

- $\bar{x}_j$: media de la variable j
- s_j : desviación estándar de la variable j

Resultado: Variables con media 0 y desviación estándar 1.

Importancia: Especialmente crítico cuando las variables tienen unidades diferentes o rangos muy distintos.

Funciones R para Clustering

kmeans(): k-medias

Sintaxis:

```
resultado <- kmeans(x, centers = k,
                    iter.max = 10,
                    nstart = 1)
```

Parámetros:

- **x**: tabla de datos (matriz o data.frame)
- **centers**: número de clusters k
- **iter.max**: máximo de iteraciones
- **nstart**: número de inicializaciones aleatorias

Salida:

- **resultado\$cluster**: asignación de clusters
- **resultado\$centers**: centros de clusters
- **resultado\$size**: tamaños de clusters
- **resultado\$withinss**: SS_{C_j} por cluster
- **resultado\$tot.withinss**: SS_C total

dist(): Matriz de Distancias

Sintaxis:

```
d <- dist(x, method = "euclidean")
```

Parámetros:

- **x**: tabla de datos
- **method**: tipo de distancia
 - "euclidean" (por defecto)
 - "manhattan"
 - "maximum"
 - "canberra"
 - "minkowski" (requiere p)
 - "binary"

Salida: Objeto de clase **dist** (no matriz estándar).

scale(): Estandarización

Sintaxis:

```
x_scaled <- scale(x, center = TRUE,
                  scale = TRUE)
```

Parámetros:

- **center = TRUE**: resta la media (por defecto)
- **scale = TRUE**: divide por desviación estándar (por defecto)
- También acepta vectores numéricos para centrar/escalar manualmente

Resultado: Datos estandarizados (media 0, desv. estándar 1).

hclust(): Clustering Jerárquico

Sintaxis:

```
hc <- hclust(d, method = "ward.D")
```

Parámetros:

- **d**: matriz de distancias (objeto **dist**)
- **method**: método de enlace
 - "ward.D", "complete", "single"
 - "average", "median", "centroid"

Salida:

- **hc\$merge**: matriz de fusiones
- **hc\$height**: alturas de fusiones

Visualización y Extracción de Clusters

plot(hc): Dibuja el dendrograma

- **hang:** controla posición de hojas
- **labels:** nombres de objetos

cutree(hc, k = ...): Extrae k clusters del dendrograma

- Alternativa: **cutree(hc, h = ...)** por altura

rect.hclust(hc, k = ...): Dibuja rectángulos alrededor de clusters en el dendrograma

- Requiere haber llamado **plot()** primero
- Útil para visualizar la partición elegida

Ejemplo:

```
plot(hc)
clusters <- cutree(hc, k = 3)
rect.hclust(hc, k = 3)
```

Determinación del Número de Clusters

Método del codo (Elbow):

- Graficar SS_C vs k
- Buscar el "codo" donde SS_C deja de disminuir rápidamente

Silueta (Silhouette):

- Mide qué tan bien está asignado cada objeto
- Valores altos: buena asignación
- Elegir k que maximice la silueta promedio

Gap statistic:

- Compara SS_C con valores esperados bajo distribución nula
- Elegir k que maximice el gap

Consideraciones Finales

Preprocesamiento:

- Estandarizar variables (especialmente si escalas diferentes)
- Manejar valores faltantes
- Considerar transformaciones si datos sesgados

Validación:

- Verificar homogeneidad y separación
- Comparar diferentes métodos
- Usar conocimiento del dominio

Limitaciones:

- Resultados dependen de inicialización (k-means)
- Asume clusters convexos (k-means)
- Sensible a outliers
- Elección de distancia y método afecta resultados