

## Conjuntos

Teoría de Conjuntos

$x \in A:$

$A \subseteq B:$

$|A| = \#(A):$

$\mathcal{P}(A):$

$|\mathcal{P}(A)| = 2^{|A|}:$

$x$  es un elemento de  $A$

todos los elementos de  $A$  están en  $B$

número de elementos de  $A$  (cardinal)

conjunto de todos los subconjuntos de  $A$

cardinal del conjunto de potencia

Operaciones Básicas

**Intersección:**

**Unión:**

**Diferencia:**

**Complemento:**

$A \cap B = \{x \in \Omega \mid x \in A \wedge x \in B\}$

$A \cup B = \{x \in \Omega \mid x \in A \vee x \in B\}$

$A - B = \{x \in \Omega \mid x \in A \wedge x \notin B\}$

$A^c = \Omega - A = \{x \in \Omega \mid x \notin A\}$

Función Característica

Asigna 1 si el elemento está en  $A$ , 0 en caso contrario. Útil para operaciones booleanas.

$$\chi_A(\omega) = \begin{cases} 1 & \text{si } \omega \in A \\ 0 & \text{si } \omega \notin A \end{cases}$$

Leyes de De Morgan

$(A \cup B)^c = A^c \cap B^c$

$(A \cap B)^c = A^c \cup B^c$

Propiedades adicionales

Dos conjuntos son disjuntos si  $A \cap B = \emptyset$

$\emptyset^c = \Omega, \Omega^c = \emptyset$

## Combinatoria

Número Binomial (Combinaciones sin Repetición)

Número de subconjuntos de tamaño  $k$  en un conjunto de  $n$  elementos (orden no importa, sin repetición).

$$\binom{n}{k} = C_k^n = \frac{n!}{k! \cdot (n-k)!}$$

Ejemplo:  $\binom{7}{5} = 21$  (equipos de 5 con 7 posibles jugadores).

Número Binomial (Combinaciones sin Repetición)

Número de formas de elegir  $k$  elementos de  $n$  tipos permitiendo repeticiones (multiconjuntos).

$$CR_k^n = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k! \cdot (n-1)!}$$

Ejemplo: Repartir 12 caramelos en 4 personas:  $\binom{4+12-1}{12} = 455$ .

Variaciones sin Repetición

Número de formas de elegir y ordenar  $k$  elementos de  $n$  sin repetir (permutaciones parciales).

$$V_k^n = \frac{n!}{(n-k)!} = (n-k+1) \cdot (n-k+2) \cdots n$$

Ejemplo: Números de 2 cifras de {1,2,3}:  $V_2^3 = 6$ .

Variaciones con Repetición

Similar a variaciones, pero permitiendo repeticiones.

$$VR_k^n = n^k$$

Ejemplo: Números de 2 cifras de {1,2,3} con repetición:  $3^2 = 9$ .

Permutaciones sin Repetición

Número de formas de ordenar todos los  $n$  elementos de un conjunto.

$$P_n = n!$$

Ejemplo: Permutaciones de {1,2,3}:  $3! = 6$ .

Permutaciones con Repetición

Número de permutaciones cuando hay elementos repetidos.

$$PR_{n_1, n_2, \dots, n_k}^n = \binom{n}{n_1 n_2 \dots n_k} = \frac{n!}{n_1! \cdot n_2! \cdots n_k!},$$

donde  $n = n_1 + \cdots + n_k$

Ejemplo: Palabras con letras de “PROBABILIDAD” (12 letras, repeticiones específicas):  $\frac{12!}{2!4!1!4} = 29,937,600$ .

Principio de la Suma

Suma los cardinales de conjuntos mutuamente exclusivos.

Si  $A_1, \dots, A_n$  son disjuntos:  $\#(\cup_{i=1}^n A_i) = \sum_{i=1}^n \#(A_i)$ .

Principio del Producto

Corrige el solapamiento al contar uniones de conjuntos no disjuntos.

$\#(A_1 \cup A_2) = \#(A_1) + \#(A_2) - \#(A_1 \cap A_2)$ .

Problema de las estrellas y barras

Queremos encontrar el número de soluciones no negativas de  $x_1 + x_2 + \cdots + x_k = n$ ,  $x_i \geq 0$

Imaginamos que tenemos  $n$  objetos idénticos que queremos repartir en  $k$  cajones. Alineamos los  $n$  objetos ★ en fila:

★★★★⋯★

para separar estos objetos en  $k$  cajones colocamos  $k - 1$  barras que marcan dónde termina cada grupo y empieza el siguiente. Por ejemplo,  $n = 7$  y  $k = 3$ :

★★★★★ | ★★ | ★

Esto representa cada cajón  $x_1 = 4, x_2 = 2, x_3 = 1$ .

Cada solución corresponde a una secuencia de  $n$  estrellas y  $k - 1$  barras en fila.

- Número total de estrellas:  $n$
- Número total de barras:  $k - 1$
- Número total de símbolos:  $n + k - 1$

Así que el problema se reduce a: ¿de cuántas formas podemos elegir las posiciones de las  $k - 1$  barras entre  $n + k - 1$  lugares posibles?

$\binom{n + k - 1}{k - 1}$

Sucesos

| Definiciones                                 |                                                                                                                       |
|----------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| <b>Experimento aleatorio:</b>                | Experimento que, repetido en las mismas condiciones, puede dar resultados diferentes, pero predecibles a largo plazo. |
| <b>Suceso elemental:</b>                     | Cada posible resultado del experimento.                                                                               |
| <b>Espacio muestral <math>\Omega</math>:</b> | Conjunto de todos los sucesos elementales.                                                                            |
| <b>Suceso:</b>                               | Cualquier subconjunto de $\Omega$ .                                                                                   |
| <b>Suceso seguro:</b>                        | $\Omega$ , $P(\Omega) = 1$ .                                                                                          |
| <b>Suceso imposible:</b>                     | $\emptyset$ , $P(\emptyset) = 0$ .                                                                                    |

| Operaciones            |                                             |
|------------------------|---------------------------------------------|
| <b>Unión:</b>          | $A \cup B$ (si sucede $A$ o $B$ )           |
| <b>Intersección:</b>   | $A \cap B$ (si sucede $A$ y $B$ )           |
| <b>Complementario:</b> | $A^c$ (si no sucede $A$ )                   |
| <b>Diferencia:</b>     | $A - B = A \cap B^c$ (sucede $A$ y no $B$ ) |
| <b>Incompatibles:</b>  | $A \cap B = \emptyset$                      |

| Propiedades Operaciones |                                                                                                      |
|-------------------------|------------------------------------------------------------------------------------------------------|
| <b>Conmutativas:</b>    | $A \cup B = B \cup A$ , $A \cap B = B \cap A$                                                        |
| <b>Asociativas:</b>     | $A \cup (B \cup C) = (A \cup B) \cup C$<br>$A \cap (B \cap C) = (A \cap B) \cap C$                   |
| <b>Distributivas:</b>   | $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$<br>$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$ |
| <b>Complementario:</b>  | $(A^c)^c = A$                                                                                        |
| <b>De Morgan:</b>       | $(A \cup B)^c = A^c \cap B^c$<br>$(A \cap B)^c = A^c \cup B^c$                                       |

Probabilidad

**Definición**

Para un espacio muestral finito  $\Omega$ , una probabilidad  $P : \mathcal{P}(\Omega) \rightarrow [0, 1]$  satisface:

- $0 \leq P(A) \leq 1$  para todo suceso  $A$
- $P(\Omega) = 1$
- Si  $A_1, \dots, A_n$  disjuntos,  
 $P(A_1 \cup \dots \cup A_n) = P(A_1) + \dots + P(A_n)$

Si todos los elementales son equiprobables,  $P(A) = \frac{|A|}{|\Omega|}$ .

**Propiedades**

- $P(\emptyset) = 0$
- $P(A^c) = 1 - P(A)$
- Si  $B \subseteq A$ , entonces  $0 \leq P(B) \leq P(A)$
- $P(A - B) = P(A) - P(A \cap B)$
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- Para tres conjuntos:  $P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$

**Probabilidad Condicionada**

Dado  $A, B$  con  $P(A) > 0$ :

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}.$$

Propiedades (similar a probabilidad estándar):

- $P(B^c \mid A) = 1 - P(B \mid A)$ .
- $P(B_1 \cup B_2 \mid A) = P(B_1 \mid A) + P(B_2 \mid A) - P(B_1 \cap B_2 \mid A)$ .

**Independencia**

$A$  y  $B$  son independientes si:

$$P(A \cap B) = P(A) \cdot P(B)$$

Equivalentes (si  $P(A), P(B) > 0$ ):

- $P(A \mid B) = P(A)$
- $P(B \mid A) = P(B)$

Para familia  $\{A_1, \dots, A_n\}$ : Para toda subfamilia, el producto de probabilidades individuales iguala la probabilidad de la intersección. También: Independencia se preserva con complementarios (e.g.,  $A^c$  y  $B$  independientes si  $A$  y  $B$  lo son).

Probabilidad Total

Para  $A, B$ :

$$P(B) = P(B \cap A) + P(B \cap A^c) = P(A) \cdot P(B \mid A) + P(A^c) \cdot P(B \mid A^c).$$

Para partición  $\{A_1, \dots, A_n\}$  de  $\Omega$ :

$$P(B) = \sum_{i=1}^n P(A_i) \cdot P(B \mid A_i).$$

Teorema de Bayes

Para  $A, B$  con  $P(B) > 0$ :

$$P(A \mid B) = \frac{P(A) \cdot P(B \mid A)}{P(B)} = \frac{P(A) \cdot P(B \mid A)}{P(A) \cdot P(B \mid A) + P(A^c) \cdot P(B \mid A^c)}.$$

Para partición  $\{A_1, \dots, A_n\}$ :

$$P(A_i \mid B) = \frac{P(A_i) \cdot P(B \mid A_i)}{\sum_{j=1}^n P(A_j) \cdot P(B \mid A_j)}.$$

Variables Aleatorias

Definiciones

**Variable aleatoria (v.a.):** Aplicación que asigna a cada elemento  $\omega$  del espacio muestral  $\Omega$  un número real  $X(\omega) \in \mathbb{R}$ .

- Se denota con letras mayúsculas:  $X, Y, Z$ .
- Sus valores se denotan en minúscula:  $x, y, z$ .

**Tipos de v.a.**

- **Discreta:** Toma valores numerables con probabilidad positiva.
- **Continua:** Sus valores están en intervalos y se describen con funciones de densidad.

Variables Aleatorias Discretas

Función de Probabilidad

$$P_X(x) = P(X = x)$$

**Propiedades:**

- $\sum_{x \in D_X} P_X(x) = 1$
- $0 \leq P_X(x) \leq 1$

**Dominio:**

$$D_X(x) = \{x \in \mathbb{R} \mid P_X(x) > 0\}$$

Ejemplo: dado justo

$$P_X(x) = \begin{cases} \frac{1}{6}, & x = 1, 2, 3, 4, 5, 6 \\ 0, & \text{en otro caso} \end{cases}$$

Función de Distribución Acumulada (CDF)

$$F_X(x) = P(X \leq x).$$

Ejemplo: dado

$$F_X(x) = \begin{cases} 0, & x < 1 \\ \frac{k}{6}, & k \leq x < k + 1, \quad k = 1, \dots, 5 \\ 1, & x \geq 6 \end{cases}$$

**Propiedades:**

- $0 \leq F_X(x) \leq 1$
- $P(X > x) = 1 - P(X \leq x) = 1 - F_X(x)$
- Sean  $a$  y  $b$  tales que  $a < b$ :  
 $P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a)$
- $\lim_{x \rightarrow -\infty} F_X(x) = 0, \lim_{x \rightarrow \infty} F_X(x) = 1$
- Continua por la derecha:  $\lim_{x \rightarrow x_0^+} F_X(x) = F_X(x_0)$

Valor Esperado

El valor esperado, esperanza o media  $E(X)$  de una v.a. discreta  $X$  se define como:

$$\bar{x} = \mu = \mu_X = E(X) = \sum_{x \in X(\Omega)} x \cdot P_X(x)$$

**Ejemplo:** lanzamos un dado  $n$  veces y obtenemos unas frecuencias  $n_i$  para  $i = 1, \dots, 6$ :

$$\bar{x} = \frac{1 \cdot n_1 + 2 \cdot n_2 + 3 \cdot n_3 + 4 \cdot n_4 + 5 \cdot n_5 + 6 \cdot n_6}{n} = \sum_{i=1}^6 x \cdot P_X(x)$$

**Propiedades:**

- $E(k) = k$  para cualquier constante  $k$
- Si  $a \leq X \leq b$  entonces  $a \leq E(X) \leq b$
- Si  $X$  es una v.a. discreta que toma valores enteros no negativos entonces  $E(X) = \sum_{x=0}^{+\infty} (1 - F_X(x))$
- $E(g(X)) = \sum_x g(x) \cdot P_X(x)$

Series Geométricas

**Progresión de razón  $r$ :**  $r^0, r^1, \dots, r^n$

**Serie:**  $\sum_{k=0}^{+\infty} r^k$

**Sumas paricales:**  $\sum_{k=n_0}^n r^k = \frac{r^{n_0} - r^{n+1}}{1-r}$

**Momento de orden  $m$ :**  $E((X - C)^m)$

**Propiedades:**

- Si se empieza en  $n_0$  se tiene que  $\sum_{k=n_0}^{+\infty} r^k = \frac{r^{n_0}}{1-r}$

- Si  $|r| < 1$  la serie es convergente y  $\sum_{k=0}^{+\infty} r^k = \frac{1}{1-r}$  y sus derivadas también son convergentes:

$$\left(\sum_{k=0}^{+\infty} r^k\right)' = \sum_{k=1}^{+\infty} k r^{k-1}; \left(\frac{1}{1-r}\right)' = \frac{1}{(1-r)^2}$$
$$\left(\sum_{k=0}^{+\infty} r^k\right)'' = \sum_{k=2}^{+\infty} k(k-1) r^{k-2}; \left(\frac{1}{1-r}\right)'' = \frac{2}{(1-r)^3}$$

Varianza

**Varianza:**  $\text{Var}(X) = E((X - E(X))^2) = \sum (x - E(X))^2 P_X(x)$

$$\text{Var}(X) = E(X^2) - (E(X))^2 = \sum_x x^2 P_X(x) - (E(X))^2$$

**Desviación típica o estándar:**  $\sigma = \sigma_X = +\sqrt{\text{Var}(X)}$

**Propiedades:**

- $\text{Var}(X) \geq 0$

- $\text{Var}(cte) = E(cte^2) - (E(cte))^2 = cte^2 - cte^2 = 0$
- Si  $Y = a + bX$ :
  - $E(Y) = E(a + bX) = a + bE(X) = a + b\mu_X$
  - $\text{Var}(Y) = \text{Var}(a + bX) = b^2 \text{Var}(x) = b^2 \sigma_X^2$
  - $\sigma_Y = \sqrt{\text{Var}(Y)} = \sqrt{b^2 \text{Var}(X)} = |b| \sigma_X$

Variables Aleatorias Continuas

Variables Aleatorias Continuas

**Propiedades**

- $P_X(X = x_0) = F_X(x_0) - F_X(x_0^-) = 0$
- $P(X \leq b) = P(X < b)$
- $P(X < b) = P(X < a) + P(a < X < b)$
- $F_X(b) = F_X(a) + P(a < X < b)$
- $P(a < X < b) = F_X(b) - F_X(a) = P(a \leq X \leq b)$

**Función de densidad**

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1, f_X(x) \geq 0 \forall x \in \mathbb{R}$$

**Función de distribución**

$$F_X(x) = \int_{-\infty}^x f_X(t) dt, \forall x \in \mathbb{R}$$

Esperanza y Varianza

**Esperanza**

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx$$

**Varianza**

$$\text{Var}(X) = E((X - \mu_X)^2) = \int_{-\infty}^{+\infty} (x - \mu_X)^2 \cdot f_X(x) dx$$

**Propiedades**

- $E(Y) = E(a + bX) = a + bE(X)$
- $\text{Var}(Y) = \text{Var}(a + bX) = b^2 E(X)$
- $\sigma_Y = |b| \sigma_X$
- $Z = \frac{X - \mu_X}{\sigma_X} \implies E(Z) = 0, \text{Var}(Z) = 1$

Distribuciones notables

**Bernoulli**

Tirar una moneda y observar si sale cara o cruz (éxito o fracaso).

$X \sim \text{Ber}(p)$

$D_X = \{0, 1\}$

$$P_X(x) = P(X = x) = \begin{cases} 1 - p = q & \text{si } x = 0 \\ p & \text{si } x = 1 \\ 0 & \text{en otro caso} \end{cases}$$
$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - p & \text{si } 0 \leq x < 1 \\ 1 & \text{si } x \leq 1 \end{cases}$$

$E(X) = p, \text{Var}(X) = p(1 - p)$

**Binomial**

Probabilidad de obtener  $x$  caras al lanzar una moneda  $n$  veces.

$X \sim B(n, p)$

$D_X = \{0, 1, \dots, n\}$

$$P_X(x) = \begin{cases} \binom{n}{x} p^x (1 - p)^{n-x} & \text{si } x \in [0, n] \\ 0 & \text{en otro caso} \end{cases}$$
$$F_X(x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k \binom{n}{i} p^i (1 - p)^{n-i} & \text{si } k \leq x < k + 1, \text{ para } k \in [0, n] \\ 1 & \text{si } x \geq n \end{cases}$$

$E(X) = np, \text{Var}(X) = np(1 - p)$

### Geométrica

Tirar una moneda hasta que obtenemos la primera cara.

$X \sim Ge(p)$   
 $X = \text{número de fracasos para conseguir primer éxito}$   
 $D_X = \{0, 1, \dots, n, \dots\}$   

$$P_X(x) = P(X = x) = \begin{cases} (1-p)^x p & \text{si } x \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$

$$F_X(x) = F(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - (1-p)^{k+1} & \text{si } \begin{cases} k \leq x < k+1 \\ \text{para } k \geq 0 \end{cases} \end{cases}$$

$$E(X) = \frac{1-p}{p}, Var(X) = \frac{1-p}{p^2}$$

$Y \sim Ge(p)$   
 $Y = \text{número de intentos para conseguir primer éxito}$   
 $D_Y = \{0, 1, \dots, n, \dots\}$   

$$P_Y(y) = P(Y = y) = \begin{cases} (1-p)^{y-1} & \text{si } y \geq 1 \\ 0 & \text{en otro caso} \end{cases}$$

$$F_Y(y) = F(Y \leq y) = \begin{cases} 0 & \text{si } x < 1 \\ 1 - (1-p)^k & \text{si } \begin{cases} k \leq x < k+1 \\ \text{para } k \geq 1 \end{cases} \end{cases}$$

$$E(Y) = \frac{1}{p}, Var(Y) = \frac{1-p}{p^2}$$

### Binomial Negativa

Abrir dos puertas consecutivas con un conjunto de llaves sin memoria.

 $X \sim BN(n, p)$   
 $X = \text{número de fracasos hasta conseguir el } n\text{-ésimo éxito}$   
 $D_X = \{0, 1, 2, 3, \dots\}$   

$$P_X(x) = P(X = x) = \begin{cases} \binom{x+n-1}{n-1} (1-p)^x p^n & \text{si } k \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$

$$F_X(x) = P(X \leq x) = \begin{cases} \sum_{i=0}^x P(X = i) & \text{si } \begin{cases} k \leq x < k+1, \\ k \geq 0 \end{cases} \end{cases}$$

$$E(X) = n \frac{1-p}{p}, Var(X) = n \frac{1-p}{p^2}$$

### Hipergeométrica

Sacar bolas de una urna con reposición.

 $X \sim H(m, n, k)$   
 $X = \begin{cases} \text{número de bolas blancas en } k \text{ extracciones} \\ \text{sin reposición de una urna con} \\ m \text{ bolas blancas y } n \text{ negras} \end{cases}$   
 $D_X = \{x \in \mathbb{N} \mid \max\{0, k-n\} \leq x \leq \min\{m, k\}\}$   

$$P_X(x) = \begin{cases} \frac{\binom{m}{x} \binom{n}{k-x}}{\binom{m+n}{k}} & \text{si } \max\{0, k-n\} \leq x \leq \min\{m, k\} \\ 0 & \text{en otro caso} \end{cases}$$

$$F_X(x) = P(X \leq x)$$

$$E(X) = \frac{km}{m+n}, Var(X) = k \frac{m}{m+n} (1 - \frac{m}{m+n}) \frac{m+n-k}{m+n-1}$$

### Poisson

$X$  con distribución Poisson de media o promedio  $\lambda$

 $X_t = \text{número de eventos en el intervalo } (0, t] Po(\lambda \ t) \text{ donde } t \text{ promedio pro u.t.}$   
 $X \sim Po(\lambda)$   
 $D_X = \{0, 1, \dots\}$   

$$P_X(x) = P(X = x) = \begin{cases} \frac{\lambda^x}{x!} e^{-\lambda} & \text{si } x \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$

$$F_X(x) = F(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^x P(X = i) & \text{si } \begin{cases} k \leq x < k+1, \\ k \geq 0 \end{cases} \end{cases}$$

$$E(X) = \lambda, Var(X) = \lambda$$

$X_t \sim Po(\lambda \ t)$   
 $D_X = \{0, 1, \dots\}$   

$$P_X(x) = P(X = x) = \begin{cases} \frac{(\lambda \ t)^x}{x!} e^{-\lambda \ t} & \text{si } x \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$

$$F_X(x) = F(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^x P(X = i) & \text{si } \begin{cases} k \leq x < k+1, \\ k \geq 0 \end{cases} \end{cases}$$

$$E(X) = \lambda t, Var(X) = \lambda t$$

### Uniforme

 $X \sim U(a, b)$   
 $D_X = (a, b)$   

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{si } a < x < b \\ 0 & \text{en otro caso} \end{cases}$$

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x \leq a \\ \frac{x-a}{b-a} & \text{si } a \leq x \leq b \\ 1 & \text{si } x \leq b \end{cases}$$

$$E(X) = \frac{a+b}{2}, Var(X) = \frac{(b-a)^2}{12}$$

### Exponencial

 $X \sim Exp(\lambda)$   
 $D_X = (0, +\infty)$   

$$f_X(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ \lambda e^{-\lambda x} & \text{si } x > 0 \end{cases}$$

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 - e^{-\lambda x} & \text{si } x > 0 \end{cases}$$

$$E(X) = \frac{1}{\lambda}, Var(X) = \frac{1}{\lambda^2}$$

### Normal o Gaussian

 $X \sim N(\mu, \sigma)$   
 $D_X = \mathbb{R} = (-\infty, +\infty)$   

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \forall x \in \mathbb{R}$$

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t) dt$$

$$E(X) = \mu, Var(X) = \sigma^2$$

# Variables Aleatorias Multidimensionales

## Variables Aleatorias Bidimensionales

### Definiciones

- **Discreta:** su conjunto de valores es  $\mathbb{R}^2, (X, Y)(\Omega)$  es un conjunto finito o numerable.
- **Continua:** su conjunto de valores es  $\mathbb{R}^2, (X, Y)(\Omega)$  es un conjunto es un producto de intervalos.
- **Heterogénea:**  $X$  e  $Y$  no comportan ser continuas o discretas.

### Dominio

$$D_{XY} = \{(x, y) \in \mathbb{R}^2 \mid P_{XY}(x, y) > 0\}$$

### Función de probabilidad

$$P_{XY}(x, y) = P(X = x, Y = y)$$

$$\sum_i \sum_j P_{XY}(x_i, y_j) = 1$$

$$P((X, Y) \in B) = \sum_{(x_i, x_j) \in B} P_{XY}(x_i, y_j), B \subset D_{XY}$$

### Función de distribución acumulada

$$F_{XY} = P(X \leq x, Y \leq y) = \sum_{x_i \leq x, y_j \leq y} P_{XY}(x_i, y_j)$$

### Función de densidad

$$f_{XY} : \mathbb{R} \times \mathbb{R} \rightarrow [0, +\infty)$$

- $f_{XY}(x, y) > 0, \forall (x, y) \in D_{XY}$
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{XY}(t_x, t_y) dt_x dt_y = 1$
- $F_{XY}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{XY}(t_x, t_y) dt_x dt_y$

## Distribuciones Marginales

### Probabilidad Marginal

$$P_X(x_i) = \sum_j P_{XY}(x_i, y_j)$$

$$P_Y(y_j) = \sum_i P_{XY}(x_i, y_j)$$

### Densidad Marginal

$$f_X(x) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dx$$

### Discretas

#### Independencia

$X$  e  $Y$  son independientes si se cumple alguna de las condiciones:

- $P_{XY}(x_i, y_j) = P_X(x_i) \cdot P_Y(y_j)$
- $P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j)$
- $F_{XY}(x, y) = F_X(x) \cdot F_Y(y)$

#### Esperanza y varianza

- $E(X) = \sum_{x \in D_X} x \cdot P_X(x)$
- $E(Y) = \sum_{y \in D_Y} y \cdot P_Y(y)$
- $\sigma_X^2 = Var(X) = E((X - E(X))^2) = E(X^2) - E(X)^2$
- $\sigma_Y^2 = Var(Y) = E((Y - E(Y))^2) = E(Y^2) - E(Y)^2$

### Distribuciones condicionales

Dado un valor fijo  $y \in D_Y$ :

$$P(X = x \mid Y = y) = \frac{P_{XY}(x, y)}{P_Y(y)}$$

Dado un valor fijo  $x \in D_X$ :

$$P(Y = y \mid X = x) = \frac{P_{XY}(x, y)}{P_X(x)}$$

Independientes si y sólo si:

- $P(X = x \mid Y = y) = P(X = x)$
- $P(Y = y \mid X = x) = P(Y = y)$

Esperanza:

$$E(X \mid Y = y) = \sum_{x \in D_X} x \cdot P(X = x \mid Y = y)$$

$X$  e  $Y$  independientes si:

- $E(X \mid Y = y) = E(X)$
- $E(Y \mid X = x) = E(Y)$

### Continuas

#### Independencia

$X$  e  $Y$  son independientes si se cumple alguna de las condiciones:

- $f_{XY}(x, y) = f_X(x) \cdot f_Y(y), \forall (x, y) \in D_{XY}$
- $F_{XY}(x, y) = F_X(x) \cdot F_Y(y), \forall (x, y) \in D_{XY}$

#### Esperanza y varianza

- $E(X) = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx$
- $E(Y) = \int_{-\infty}^{+\infty} y \cdot f_Y(y) dy$
- $\sigma_X^2 = Var(X) = E((X - E(X))^2) = E(X^2) - E(X)^2$
- $\sigma_Y^2 = Var(Y) = E((Y - E(Y))^2) = E(Y^2) - E(Y)^2$

### Distribuciones condicionales

Dado un valor fijo  $y \in D_Y$ :

$$f_{X|Y=y}(x) = \frac{f_{XY}(x, y)}{f_Y(y)}$$

Dado un valor fijo  $x \in D_X$ :

$$f_{Y|X=x}(y) = \frac{f_{XY}(x, y)}{f_X(x)}$$

Independientes si y sólo si:

- $f_{X|Y=y}(x) = f_X(x)$
- $f_{Y|X=x}(y) = f_Y(y)$

Esperanza:

$$E(X \mid Y = y) = \int_{-\infty}^{+\infty} x \cdot f_{X|Y=y}(x) dx$$

# Estimación Puntual

Estadística Inferencial

**Problema:** Queremos conocer una característica de una población, pero no podemos medirla en todos los individuos. Extraemos una muestra aleatoria e inferimos el valor para toda la población.

Muestra Aleatoria Simple (m.a.s.)

**Definición intuitiva:** De una población de  $N$  individuos, repetimos  $n$  veces el proceso de escoger equiprobablemente un individuo (con reposición).

**Definición formal:** Un conjunto de  $n$  variables aleatorias independientes  $X_1, \dots, X_n$ , todas con la distribución de  $X$ .

**Realización:** Los  $n$  valores  $x_1, \dots, x_n$  que toman las v.a.  $X_1, \dots, X_n$ .

Estadístico (Estimador Puntual)

**Definición:** Una función aplicada a la muestra  $X_1, \dots, X_n$ :

$$T = f(X_1, \dots, X_n)$$

**Propiedades:**

- Es una variable aleatoria con distribución, esperanza, etc.
- La distribución muestral de  $T$  es la distribución de esta v.a.
- Error estándar de  $T$ : desviación típica de  $T$  ( $\sigma_T$ )

**Convenio:** Estadísticos en mayúsculas ( $\bar{X}$ ), realizaciones en minúsculas ( $\bar{x}$ ).

Media Muestral

**Definición:** Sea  $X_1, \dots, X_n$  una m.a.s. de tamaño  $n$  de una v.a.  $X$  con esperanza  $\mu_X$  y desviación típica  $\sigma_X$ :

$$\bar{X} = \frac{X_1 + \dots + X_n}{n}$$

**Propiedades:**

- $E(\bar{X}) = \mu_X$  (estimador insesgado)
- $\sigma_{\bar{X}} = \frac{\sigma_X}{\sqrt{n}}$  (error estándar)
- $\bar{X}$  es un estimador puntual de  $\mu_X$

**Interpretación:** Si tomamos muchas veces una m.a.s. y calculamos la media muestral, el promedio de estas medias será aproximadamente  $\mu_X$ .

**Teorema Central del Límite:** Si  $n$  es suficientemente grande,  $\bar{X}$  sigue aproximadamente una distribución normal:

$$\bar{X} \approx N\left(\mu_X, \frac{\sigma_X}{\sqrt{n}}\right)$$

Propiedades de la Media Muestral

**Insesgadez:**  $E(\bar{X}) = \mu_X$

**Consistencia:** A medida que  $n$  aumenta,  $\sigma_{\bar{X}} = \frac{\sigma_X}{\sqrt{n}}$  disminuye.

**Eficiencia:** Entre los estimadores insesgados, la media muestral tiene varianza mínima (bajo ciertas condiciones).

Notación y Convenios

**Estadísticos** (v.a.):  $X_1, \dots, X_n, \bar{X}, S^2$

**Realizaciones** (valores):  $x_1, \dots, x_n, \bar{x}, s^2$

**Muestra sin reposición:** Si  $N \gg n$ , los resultados son aproximadamente los mismos que para m.a.s.

# Intervalos de Confianza

## Definición de Intervalo de Confianza

**Concepto:** Un intervalo de confianza  $(1 - \alpha)$  para un parámetro  $\theta$  es un intervalo aleatorio  $[L, U]$  tal que:

$$P(L \leq \theta \leq U) = 1 - \alpha$$

**Interpretación:** Si construimos muchos intervalos de confianza  $(1 - \alpha)$  a partir de diferentes muestras, aproximadamente el  $(1 - \alpha) \times 100\%$  de ellos contendrá el verdadero valor del parámetro  $\theta$ .

**Nivel de confianza:**  $1 - \alpha$  (típicamente 0.95, 0.99)

**Nivel de significación:**  $\alpha$  (típicamente 0.05, 0.01)

## Construcción de I.C.

**Pasos:**

1. Elegir nivel de confianza  $1 - \alpha$
2. Encontrar estadístico pivote
3. Determinar distribución del pivote
4. Calcular cuantiles  $z_{\alpha/2}$  o  $t_{\alpha/2}$
5. Construir intervalo

**Forma general:**

$$\text{Estimador} \pm \text{Margen de error}$$

## Cuantiles Importantes

**Distribución Normal:**

- $z_{0.025} = 1.96$  (95%)
- $z_{0.005} = 2.576$  (99%)
- $z_{0.05} = 1.645$  (90%)

**Distribución t de Student:**

- Depende de grados de libertad  $\nu = n - 1$
- $t_{\alpha/2, \nu}$  se obtiene de tablas

## Intervalo de Confianza para la Media $\mu$

**Caso 1: Varianza conocida  $\sigma^2$**  (o  $n$  grande):

$$\bar{X} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Intervalo:  $\left[ \bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$

**Caso 2: Varianza desconocida, muestra pequeña ( $n < 30$ ):**

$$\bar{X} \pm t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}}$$

donde  $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$  es la desviación típica muestral.

Intervalo:  $\left[ \bar{x} - t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}, \bar{x} + t_{\alpha/2, n-1} \frac{s}{\sqrt{n}} \right]$

**Amplitud del intervalo:**  $2 \cdot z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$  (o con  $t$  y  $s$ )

## I.C. para Proporción $p$

**Condición:**  $n$  grande ( $np \geq 5$  y  $n(1-p) \geq 5$ )

**Estimador:**  $\hat{p} = \frac{X}{n}$  donde  $X \sim B(n, p)$

**Intervalo:**

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

**Forma:**  $\left[ \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$

## I.C. para Varianza $\sigma^2$

**Condición:** Población normal

**Estadístico:**  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$

**Intervalo:**

$$\left[ \frac{(n-1)s^2}{\chi^2_{\alpha/2, n-1}}, \frac{(n-1)s^2}{\chi^2_{1-\alpha/2, n-1}} \right]$$

**Nota:**  $\chi^2_{\alpha/2, n-1}$  y  $\chi^2_{1-\alpha/2, n-1}$  son cuantiles de chi-cuadrado con  $n - 1$  grados de libertad.

## Distribución t de Student

**Definición:** Si  $Z \sim N(0, 1)$  y  $V \sim \chi^2_\nu$  son independientes, entonces:

$$T = \frac{Z}{\sqrt{V/\nu}} \sim t_\nu$$

**Propiedades:**

- Simétrica alrededor de 0
- $E(T) = 0$  (si  $\nu > 1$ )
- $Var(T) = \frac{\nu}{\nu-2}$  (si  $\nu > 2$ )
- Cuando  $\nu \rightarrow \infty$ ,  $t_\nu \rightarrow N(0, 1)$

**Uso:** Cuando la varianza poblacional es desconocida y la muestra es pequeña.

## Tamaño Muestral

**Para media** (varianza conocida):

$$n = \left( \frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

Interpretación y Consideraciones

**Interpretación correcta:** "Tenemos un 95% de confianza de que el intervalo contiene el verdadero parámetro."

**Interpretación incorrecta:** "El parámetro tiene un 95% de probabilidad de estar en el intervalo."

**Factores que afectan la amplitud:**

- Nivel de confianza: mayor confianza  $\Rightarrow$  mayor amplitud
- Tamaño muestral: mayor  $n \Rightarrow$  menor amplitud
- Varianza: mayor varianza  $\Rightarrow$  mayor amplitud

# Contraste de Hipótesis

## Definiciones Básicas

**Hipótesis estadística:** Afirmación sobre un parámetro poblacional que se desea verificar.

**Hipótesis nula ( $H_0$ ):** Afirmación que se asume verdadera inicialmente. Representa "no hay efecto" o "no hay diferencia".

**Hipótesis alternativa ( $H_1$  o  $H_a$ ):** Afirmación que contradice  $H_0$ . Representa el efecto o diferencia que se desea detectar.

**Estadístico de prueba:** Función de la muestra que se usa para tomar la decisión.

**Región crítica (o de rechazo):** Conjunto de valores del estadístico que llevan a rechazar  $H_0$ .

**Región de aceptación:** Conjunto de valores del estadístico que llevan a no rechazar  $H_0$ .

## Tipos de Contrastes

**Unilateral (cola derecha):**

- $H_0 : \theta = \theta_0$
- $H_1 : \theta > \theta_0$

**Unilateral (cola izquierda):**

- $H_0 : \theta = \theta_0$
- $H_1 : \theta < \theta_0$

**Bilateral:**

- $H_0 : \theta = \theta_0$
- $H_1 : \theta \neq \theta_0$

## Errores en el Contraste

**Error Tipo I ( $\alpha$ ):** Rechazar  $H_0$  cuando es verdadera.

$$\alpha = P(\text{Rechazar } H_0 \mid H_0 \text{ es verdadera})$$

**Error Tipo II ( $\beta$ ):** No rechazar  $H_0$  cuando es falsa.

$$\beta = P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa})$$

**Nivel de significación:** Probabilidad máxima permitida de cometer Error Tipo I. Valores comunes:  $\alpha = 0.05, 0.01, 0.10$ .

## Potencia del Test

**Definición:** Probabilidad de rechazar correctamente  $H_0$  cuando  $H_1$  es verdadera.

$$\text{Potencia} = 1 - \beta = P(\text{Rechazar } H_0 \mid H_1 \text{ es verdadera})$$

**Factores que aumentan la potencia:**

- Mayor tamaño muestral  $n$
- Mayor diferencia entre  $\theta_0$  y  $\theta_1$
- Mayor nivel de significación  $\alpha$
- Menor varianza poblacional

## p-valor

**Definición:** Probabilidad de obtener un resultado tan extremo como el observado (o más extremo), suponiendo que  $H_0$  es verdadera.

**Regla de decisión:**

- Si  $p\text{-valor} < \alpha$ : Rechazar  $H_0$
- Si  $p\text{-valor} \geq \alpha$ : No rechazar  $H_0$

**Interpretación:**

- $p\text{-valor}$  pequeño: Evidencia fuerte contra  $H_0$
- $p\text{-valor}$  grande: Poca evidencia contra  $H_0$

## Procedimiento General para Contrastes

**Pasos:**

- Formular  $H_0$  y  $H_1$
- Elegir el nivel de significación  $\alpha$
- Seleccionar el estadístico de prueba adecuado
- Determinar la región crítica (o calcular el  $p$ -valor)
- Calcular el valor del estadístico con los datos muestrales
- Tomar decisión: rechazar o no rechazar  $H_0$
- Interpretar los resultados en el contexto del problema

# Contrastes para la Media Poblacional $\mu$

## Caso 1: Varianza conocida $\sigma^2$

**Condiciones:** Población normal o  $n$  grande ( $n \geq 30$ )

**Estadístico de prueba:**

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$$

**Regiones críticas:**

- $H_1 : \mu > \mu_0$ : Rechazar si  $Z > z_\alpha$
- $H_1 : \mu < \mu_0$ : Rechazar si  $Z < -z_\alpha$
- $H_1 : \mu \neq \mu_0$ : Rechazar si  $|Z| > z_{\alpha/2}$

**p-valor:**

- $H_1 : \mu > \mu_0$ :  $p = P(Z > z_{\text{obs}})$
- $H_1 : \mu < \mu_0$ :  $p = P(Z < z_{\text{obs}})$
- $H_1 : \mu \neq \mu_0$ :  $p = 2P(Z > |z_{\text{obs}}|)$

## Caso 2: Varianza desconocida

**Condiciones:** Población normal, muestra pequeña ( $n < 30$ )

**Estadístico de prueba:**

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$$

donde  $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$

**Regiones críticas:**

- $H_1 : \mu > \mu_0$ : Rechazar si  $T > t_{\alpha, n-1}$
- $H_1 : \mu < \mu_0$ : Rechazar si  $T < -t_{\alpha, n-1}$
- $H_1 : \mu \neq \mu_0$ : Rechazar si  $|T| > t_{\alpha/2, n-1}$

**Nota:** Si  $n$  es grande ( $n \geq 30$ ), se puede usar  $Z$  aunque  $\sigma$  sea desconocida.

# Contrastes para la Proporción Poblacional $p$

Contraste para una Proporción

Condiciones:  $n$  grande ( $np_0 \geq 5$  y  $n(1 - p_0) \geq 5$ )  
Estadístico de prueba:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim N(0, 1)$$

donde  $\hat{p} = \frac{X}{n}$  es la proporción muestral.

Regiones críticas:

- $H_1 : p > p_0$ : Rechazar si  $Z > z_\alpha$
- $H_1 : p < p_0$ : Rechazar si  $Z < -z_\alpha$
- $H_1 : p \neq p_0$ : Rechazar si  $|Z| > z_{\alpha/2}$

p-valor:

- $H_1 : p > p_0$ :  $p = P(Z > z_{\text{obs}})$
- $H_1 : p < p_0$ :  $p = P(Z < z_{\text{obs}})$
- $H_1 : p \neq p_0$ :  $p = 2P(Z > |z_{\text{obs}}|)$

Contrastes para la Varianza Poblacional  $\sigma^2$

Contraste para la Varianza

Condiciones: Población normal  
Estadístico de prueba:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2$$

donde  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

Regiones críticas:

- $H_1 : \sigma^2 > \sigma_0^2$ : Rechazar si  $\chi^2 > \chi_{\alpha, n-1}^2$
- $H_1 : \sigma^2 < \sigma_0^2$ : Rechazar si  $\chi^2 < \chi_{1-\alpha, n-1}^2$
- $H_1 : \sigma^2 \neq \sigma_0^2$ : Rechazar si  $\chi^2 < \chi_{1-\alpha/2, n-1}^2$  o  $\chi^2 > \chi_{\alpha/2, n-1}^2$

Contrastes para Dos Muestras

Diferencia de Medias (Muestras Independientes)

Caso: Varianzas conocidas

Estadístico:

$$Z = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

Caso: Varianzas desconocidas pero iguales

Estadístico:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)_0}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

donde  $S_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$  (varianza combinada)

Caso: Varianzas desconocidas y diferentes

Estadístico (aproximado):

$$T = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)_0}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \sim t_\nu$$

donde  $\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$  (Welch)

Diferencia de Medias (Muestras Pareadas)

Condiciones: Población normal, muestras dependientes

Definición:  $D_i = X_{1i} - X_{2i}$  (diferencias pareadas)

Estadístico de prueba:

$$T = \frac{\bar{D} - \mu_{D_0}}{S_D/\sqrt{n}} \sim t_{n-1}$$

donde:

- $\bar{D} = \frac{1}{n} \sum_{i=1}^n D_i$  (media de diferencias)
- $S_D = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D})^2}$  (desviación típica de diferencias)

Hipótesis típicas:

- $H_0 : \mu_D = 0$  (no hay diferencia)
- $H_1 : \mu_D \neq 0$  (hay diferencia)

Diferencia de Proporciones

Condiciones:  $n_1$  y  $n_2$  grandes

Estadístico de prueba:

$$Z = \frac{\hat{p}_1 - \hat{p}_2 - (p_1 - p_2)_0}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1)$$

donde  $\hat{p} = \frac{X_1+X_2}{n_1+n_2}$  (proporción combinada)

Regiones críticas:

Cociente de Varianzas

Condiciones: Poblaciones normales e independientes

Estadístico de prueba:

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} = \frac{S_1^2}{S_2^2} \sim F_{n_1-1,n_2-1}$$

(bajo  $H_0 : \sigma_1^2 = \sigma_2^2$ )

Regiones críticas:

- $H_1 : \sigma_1^2 > \sigma_2^2$ : Rechazar si  $F > F_{\alpha,n_1-1,n_2-1}$
- $H_1 : \sigma_1^2 < \sigma_2^2$ : Rechazar si  $F < F_{1-\alpha,n_1-1,n_2-1}$
- $H_1 : \sigma_1^2 \neq \sigma_2^2$ : Rechazar si  $F < F_{1-\alpha/2,n_1-1,n_2-1}$  o  $F > F_{\alpha/2,n_1-1,n_2-1}$

Nota:  $F_{1-\alpha,\nu_1,\nu_2} = \frac{1}{F_{\alpha,\nu_2,\nu_1}}$

Distribución F de Fisher

Definición: Si  $U \sim \chi^2_{\nu_1}$  y  $V \sim \chi^2_{\nu_2}$  son independientes, entonces:

$$F = \frac{U/\nu_1}{V/\nu_2} \sim F_{\nu_1,\nu_2}$$

Propiedades:

- $F_{\nu_1,\nu_2}$  tiene dos parámetros: grados de libertad del numerador ( $\nu_1$ ) y del denominador ( $\nu_2$ )
- $F_{1-\alpha,\nu_1,\nu_2} = \frac{1}{F_{\alpha,\nu_2,\nu_1}}$
- Usada para comparar varianzas de dos poblaciones normales

Tabla de Decisión

| Decisión          | $H_0$ verdadera                    | $H_0$ falsa               |
|-------------------|------------------------------------|---------------------------|
| Rechazar $H_0$    | Error Tipo I ( $\alpha$ )          | Decisión correcta (Poder) |
| No rechazar $H_0$ | Decisión correcta ( $1 - \alpha$ ) | Error Tipo II ( $\beta$ ) |

Consideraciones Importantes

Verificar supuestos:

- Normalidad (si es necesario)
- Tamaño muestral adecuado
- Independencia de observaciones

Interpretación:

- ”No rechazar  $H_0$ ”  $\neq$  ”Aceptar  $H_0$ ”
- El  $p$ -valor mide la evidencia contra  $H_0$
- Considerar el tamaño del efecto, no solo la significación

Relación con I.C.:

- Si  $\theta_0$  está fuera del I.C. ( $1 - \alpha$ ): Rechazar  $H_0$  al nivel  $\alpha$
- Si  $\theta_0$  está dentro del I.C. ( $1 - \alpha$ ): No rechazar  $H_0$  al nivel  $\alpha$

# Bondad de Ajuste

## Contrastes Paramétricos vs No Paramétricos

**Contrastes paramétricos:** Suponen que conocemos el tipo de distribución de la población (normal, binomial, Poisson, etc.) y contrastan hipótesis sobre los parámetros desconocidos (media, varianza, proporción, etc.).

**Contrastes no paramétricos:** No suponen un tipo específico de distribución. La hipótesis nula consiste en verificar si la distribución de la variable  $X$  es de un tipo determinado.

**Procedimiento típico:**

- Primero: Verificar la distribución usando contrastes no paramétricos (bondad de ajuste)
- Segundo: Si se acepta la distribución, usar contrastes paramétricos para los parámetros

## Contraste de Bondad de Ajuste

**Hipótesis:**

$$\begin{cases} H_0 : \text{La distribución de } X \text{ es del tipo } X_0 \\ H_1 : \text{La distribución de } X \text{ no es del tipo } X_0 \end{cases}$$

donde  $X_0$  es un tipo de distribución conocida (normal, binomial, Poisson, etc.), sin especificar parámetros.

**Objetivo:** Determinar si una muestra proviene de una distribución teórica específica.

# Pruebas Gráficas

## Histogramas y Densidad

**Objetivo:** Comparar visualmente la función de densidad estimada de la muestra con la función de densidad teórica.

**Método:**

- Estimar la densidad muestral usando `density()` en R
- Superponer la densidad teórica con parámetros estimados de la muestra
- Comparar visualmente las formas

**Limitación:** Prueba subjetiva, no cuantitativa.

## Q-Q Plots (Cuantil-Cuantil)

**Objetivo:** Comparar los cuantiles observados de la muestra con los cuantiles teóricos de la distribución.

**Interpretación:**

- Si los puntos están cerca de la recta  $y = x$ : buena concordancia
- Desviaciones sistemáticas: indican diferencias con la distribución teórica

**En R:** `qqPlot()` del paquete `car`

- `distribution`: nombre de la distribución (entre comillas)
- Parámetros: `mean`, `sd`, `df`, etc.

# Test Chi-Cuadrado de Bondad de Ajuste

## Test $\chi^2$ de Bondad de Ajuste

**Condiciones:**

- Muestra de tamaño  $n$
- Datos agrupados en  $k$  clases o categorías
- Frecuencias observadas:  $O_i$  para  $i = 1, \dots, k$
- Frecuencias esperadas:  $E_i = n \cdot p_i$  donde  $p_i$  es la probabilidad teórica de la clase  $i$

**Estadístico de prueba:**

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi_{k-1-r}^2$$

donde  $r$  es el número de parámetros estimados a partir de la muestra.

**Región crítica:** Rechazar  $H_0$  si  $\chi^2 > \chi_{\alpha, k-1-r}^2$

**Condición de aplicación:**  $E_i \geq 5$  para todas las clases (si no, agrupar clases).

## En R: `chisq.test`

**Sintaxis:**

- `chisq.test(x, p = ...)`
- `x`: vector de frecuencias observadas
- `p`: vector de probabilidades teóricas

**Parámetros importantes:**

- `rescale.p = TRUE`: si `p` no suma 1
- `simulate.p.value = TRUE`: calcular  $p$ -valor por simulación
- `B`: número de simulaciones

## Consideraciones

**Ventajas:**

- Aplicable a distribuciones discretas y continuas
- No requiere normalidad
- Fácil de aplicar

**Desventajas:**

- Requiere agrupar datos continuos
- Sensible a la elección de clases
- Requiere frecuencias esperadas  $\geq 5$

# Tests de Normalidad

Test de Kolmogorov-Smirnov (K-S)

**Objetivo:** Contrastar si una muestra proviene de una distribución continua específica.  
**Estadístico:**

$$D = \max_x |F_n(x) - F_0(x)|$$

donde:

- $F_n(x)$ : función de distribución empírica
- $F_0(x)$ : función de distribución teórica

**En R:** `ks.test(x, "distribución", parámetros)`

- `ks.test(x, y)`: contrasta si  $x$  e  $y$  provienen de la misma distribución
- `ks.test(x, "pnorm", mean, sd)`: contrasta normalidad

**Limitación:** Requiere que los parámetros sean conocidos (no estimados).

Test de Lilliefors (K-S-L)

**Objetivo:** Test de normalidad cuando los parámetros ( $\mu, \sigma$ ) se estiman de la muestra.  
**Mejora sobre K-S:** Más robusto al estimar parámetros.  
**En R:** `lillie.test()` del paquete `nortest`  
**Características:**

- Muy sensible a diferencias alrededor de la media
- Menos sensible a diferencias en los extremos
- Puede fallar con distribuciones de colas pesadas (ej:  $t$  de Student)

**Problema:** Con muestras grandes ( $> 1000$ ), aumenta probabilidad de Error Tipo I.

Test de Anderson-Darling (A-D)

**Objetivo:** Test de normalidad que resuelve el problema de K-S-L en los extremos.  
**Estadístico:** Basado en diferencias ponderadas entre  $F_n$  y  $F_0$ , dando más peso a los extremos.  
**En R:** `ad.test()` del paquete `nortest`  
**Ventajas:**

- Detecta mejor diferencias en los extremos
- Más potente que K-S-L para distribuciones con colas pesadas

**Desventaja:** Con muestras muy grandes, aumenta probabilidad de Error Tipo I.

Test de Shapiro-Wilk (S-W)

**Objetivo:** Test de normalidad robusto para muestras de cualquier tamaño.  
**Estadístico:** Basado en la correlación entre los valores ordenados de la muestra y los valores esperados bajo normalidad.  
**En R:** `shapiro.test()` (instalación básica de R)  
**Ventajas:**

- Funciona bien con muestras pequeñas y grandes
- Alta potencia
- Menos afectado por empates que K-S-L y A-D

**Limitación:**

- Solo para normalidad (no otras distribuciones)
- Tamaño máximo recomendado:  $n \leq 5000$

Test de D'Agostino-Pearson

**Objetivo:** Test de normalidad basado en asimetría y curtosis.  
**Estadísticos:**

- $Z_3$ : Test de asimetría (skewness)
- $Z_4$ : Test de curtosis (kurtosis)
- $\chi^2$  Omnibus: Combina ambos tests

**En R:** `dagoTest()` del paquete `fBasics`  
**Condición:** Requiere  $n \geq 20$   
**Ventaja:** No es sensible a empates (a diferencia de K-S-L, A-D, S-W).  
**Interpretación:** Compara la forma de la distribución muestral con la forma esperada de una normal.

Comparación de Tests de Normalidad

| Test               | Tamaño muestral | Sensible a extremos | Sensible a empates | Potencia |
|--------------------|-----------------|---------------------|--------------------|----------|
| K-S-L              | Pequeño-Grande  | Baja                | Sí                 | Media    |
| A-D                | Pequeño-Grande  | Alta                | Sí                 | Alta     |
| S-W                | Pequeño-Grande  | Media               | Baja               | Alta     |
| D'Agostino-Pearson | $\geq 20$       | Media               | No                 | Media    |

**Recomendaciones:**

- **Muestras pequeñas** ( $n < 50$ ): S-W o A-D
- **Muestras medianas** ( $50 \leq n < 1000$ ): S-W (preferido) o A-D
- **Muestras grandes** ( $n \geq 1000$ ): Cuidado con todos (aumentan Error Tipo I)
- **Con empates:** D'Agostino-Pearson o S-W
- **Distribuciones de colas pesadas:** A-D o S-W

Guía Rápida de Funciones R

**Pruebas gráficas:**

- `density(x)`: Estimación de densidad
- `qqPlot(x, distribution=..., ...)`: Q-Q plot (paquete `car`)

**Tests de bondad de ajuste:**

- `chisq.test(x, p=...)`: Test  $\chi^2$  de bondad de ajuste
- `ks.test(x, "distribución", ...)`: Test de Kolmogorov-Smirnov

**Tests de normalidad:**

- `lillie.test(x)`: Test de Lilliefors (paquete `nortest`)
- `ad.test(x)`: Test de Anderson-Darling (paquete `nortest`)
- `shapiro.test(x)`: Test de Shapiro-Wilk
- `dagoTest(x)`: Test de D'Agostino-Pearson (paquete `fBasics`)

# Contrastes de Independencia y Homogeneidad

Introducción

**Objetivo:** Contrastar si dos criterios de clasificación  $X$  e  $Y$  son independientes o si las distribuciones de una variable son homogéneas entre diferentes grupos.

**Aplicación:** Una de las aplicaciones más usadas del test de bondad de ajuste  $\chi^2$ .

**Ejemplo:** ¿Es el hecho de contraer hepatitis independiente de haber sido vacunado? (equivalente a: ¿es efectiva la vacuna?)

Tablas de Contingencia

**Situación:** Tenemos  $n$  individuos clasificados según dos criterios:

- Criterio  $X$ : con niveles  $x_1, \dots, x_I$
- Criterio  $Y$ : con niveles  $y_1, \dots, y_J$

**Notación:**

- $n_{ij}$ : número de individuos en nivel  $x_i$  de  $X$  y nivel  $y_j$  de  $Y$
- $n_{i\bullet} = \sum_{j=1}^J n_{ij}$ : total de la fila  $i$
- $n_{\bullet j} = \sum_{i=1}^I n_{ij}$ : total de la columna  $j$
- $n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}$ : total de individuos

**Tabla de contingencia:**

| $X \backslash Y$ | $y_1$           | $\dots$  | $y_j$           | $\dots$  | $y_J$           | $n_{i\bullet}$ |
|------------------|-----------------|----------|-----------------|----------|-----------------|----------------|
| $x_1$            | $n_{11}$        | $\dots$  | $n_{1j}$        | $\dots$  | $n_{1J}$        | $n_{1\bullet}$ |
| $\vdots$         | $\vdots$        | $\ddots$ | $\vdots$        | $\ddots$ | $\vdots$        | $\vdots$       |
| $x_i$            | $n_{i1}$        | $\dots$  | $n_{ij}$        | $\dots$  | $n_{iJ}$        | $n_{i\bullet}$ |
| $\vdots$         | $\vdots$        | $\ddots$ | $\vdots$        | $\ddots$ | $\vdots$        | $\vdots$       |
| $x_I$            | $n_{I1}$        | $\dots$  | $n_{Ij}$        | $\dots$  | $n_{IJ}$        | $n_{I\bullet}$ |
| $n_{\bullet j}$  | $n_{\bullet 1}$ | $\dots$  | $n_{\bullet j}$ | $\dots$  | $n_{\bullet J}$ | $n$            |

## Contraste de Independencia

Hipótesis del Contraste de Independencia

**Hipótesis:**

$$\begin{cases} H_0 : \text{Los criterios } X \text{ e } Y \text{ son independientes} \\ H_1 : \text{Los criterios } X \text{ e } Y \text{ no son independientes} \end{cases}$$

**Interpretación:**  $X$  e  $Y$  son independientes si:

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j)$$

para todo  $i = 1, \dots, I$  y  $j = 1, \dots, J$ .

Test  $\chi^2$  de Independencia

**Modelo bajo  $H_0$ :** Variable aleatoria bidimensional  $(X, Y)$  con:

$$P((X, Y) = (x_i, y_j)) = P(X = x_i) \cdot P(Y = y_j) = \frac{n_{i\bullet}}{n} \cdot \frac{n_{\bullet j}}{n} = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n^2}$$

**Frecuencias esperadas:**

$$E_{ij} = n \cdot P((X, Y) = (x_i, y_j)) = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}$$

**Estadístico de prueba:**

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - E_{ij})^2}{E_{ij}} = \sum_{i=1}^I \sum_{j=1}^J \frac{\left(n_{ij} - \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} \cdot n_{\bullet j}}{n}}$$

**Distribución:** Bajo  $H_0$ , si  $n$  es grande y  $E_{ij} \geq 5$  para todo  $i, j$ :

$$\chi^2 \sim \chi_{(I-1)(J-1)}^2$$

**Región crítica:** Rechazar  $H_0$  si  $\chi^2 > \chi_{\alpha, (I-1)(J-1)}^2$

Grados de Libertad

**Cálculo:**  $\nu = (I - 1)(J - 1)$

**Justificación:**

- $I \cdot J$  celdas en total
- $I$  restricciones (suma de filas)
- $J$  restricciones (suma de columnas)
- 1 restricción (suma total)
- $\nu = IJ - I - J + 1 = (I - 1)(J - 1)$

Condiciones de Aplicación

Requisitos:

- $n$  suficientemente grande
- $E_{ij} \geq 5$  para todas las celdas  $(i, j)$

Si no se cumple:

- Agrupar categorías adyacentes
- Usar simulación para calcular  $p$ -valor

En R: `chisq.test(..., simulate.p.value = TRUE)`

## Contraste de Homogeneidad

Hipótesis del Contraste de Homogeneidad

Hipótesis:

$$\begin{cases} H_0 : \text{La distribución de } Y \text{ es la misma para todos los niveles de } X \\ H_1 : \text{La distribución de } Y \text{ no es la misma para todos los niveles de } X \end{cases}$$

Interpretación: Verificar si las distribuciones condicionales  $P(Y = y_j \mid X = x_i)$  son iguales para todos los valores de  $X$ .

Equivalencia: Si  $P(Y = y_j \mid X = x_i) = P(Y = y_j)$  para todo  $i$ , entonces  $X$  e  $Y$  son independientes.

Test  $\chi^2$  de Homogeneidad

Modelo bajo  $H_0$ : Para cada fila  $i$ , la distribución de  $Y$  es la misma:

$$P(Y = y_j \mid X = x_i) = \frac{n_{\bullet j}}{n}$$

Frecuencias esperadas (para la fila  $i$ ):

$$E_{ij} = n_{i\bullet} \cdot P(Y = y_j \mid X = x_i) = n_{i\bullet} \cdot \frac{n_{\bullet j}}{n} = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}$$

Estadístico de prueba:

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - E_{ij})^2}{E_{ij}} = \sum_{i=1}^I \sum_{j=1}^J \frac{\left(n_{ij} - \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} \cdot n_{\bullet j}}{n}}$$

Observación: ¡La misma expresión que en el test de independencia!

Distribución:  $\chi^2 \sim \chi^2_{(I-1)(J-1)}$  (bajo  $H_0$ )

Diseño Experimental: Independencia

Procedimiento:

- Se toma una muestra transversal de  $n$  individuos
- Se clasifica cada individuo según  $X$  e  $Y$
- Los totales de filas y columnas son aleatorios

Ejemplo: Muestra aleatoria de 1083 voluntarios, clasificados por vacunación y enfermedad.

Pregunta: ¿Son independientes las dos clasificaciones?

Diseño Experimental: Homogeneidad

Procedimiento:

- Se fijan los tamaños de muestra  $n_{i\bullet}$  para cada nivel de  $X$
- Para cada  $x_i$ , se toma una muestra aleatoria de tamaño  $n_{i\bullet}$
- Se observa la variable  $Y$  en cada muestra
- Los totales de filas están fijados de antemano

Ejemplo: 50 clientes del Norte, 100 del Centro, 50 del Sur (fijados). Se observa número de lotes comprados.

Pregunta: ¿Es la distribución de  $Y$  igual en los tres grupos?

Comparación: Independencia vs Homogeneidad

| Aspecto            | Independencia               | Homogeneidad                         |
|--------------------|-----------------------------|--------------------------------------|
| Muestra            | Transversal (una sola)      | Estratificada (múltiples)            |
| Totales de filas   | Aleatorios                  | Fijados de antemano                  |
| Objetivo           | Verificar independencia     | Verificar igualdad de distribuciones |
| Estadístico        | $\chi^2$ (mismo)            | $\chi^2$ (mismo)                     |
| Grados de libertad | $(I - 1)(J - 1)$            | $(I - 1)(J - 1)$                     |
| Interpretación     | $P(X, Y) = P(X) \cdot P(Y)$ | $P(Y \mid X) = P(Y)$                 |

Conclusión: Desde el punto de vista computacional, ambos contrastes son idénticos. La diferencia está en el diseño experimental y la interpretación.

## Funciones R para Tablas de Contingencia

Construcción de Tablas

`table(x, y)`: Crea tabla de contingencia de frecuencias absolutas.

`prop.table(tabla)`: Convierte a frecuencias relativas (proporciones).

`prop.table(tabla, margin=1)`: Frecuencias relativas por filas.

Operaciones con Tablas

**colSums(tabla):** Vector con sumas de columnas.  
**rowSums(tabla):** Vector con sumas de filas.  
**chisq.test(tabla):** Test  $\chi^2$  de independencia/homogeneidad.  
**Resultado de chisq.test:**

- **statistic:** valor de  $\chi^2$
- **parameter:** grados de libertad
- **p.value:**  $p$ -valor
- **expected:** frecuencias esperadas

chisq.test: Parámetros Avanzados

**Sintaxis básica:**

- **chisq.test(tabla):** Test estándar
- **chisq.test(x, y):** Si  $x$  e  $y$  son vectores

**Parámetros importantes:**

- **simulate.p.value = TRUE:** Calcula  $p$ -valor mediante simulaciones (útil cuando  $E_{ij} < 5$ )
- **B:** Número de simulaciones (por defecto 2000)
- **correct = TRUE/FALSE:** Corrección de Yates (solo para tablas  $2 \times 2$ )

**Ejemplo:**

```
tabla <- matrix(c(11, 70, 538, 464), 2, 2)
chisq.test(tabla)
chisq.test(tabla, simulate.p.value = TRUE, B = 10000)
```

Ejemplo: Vacuna de Hepatitis

Datos:

|            |          |             |       |
|------------|----------|-------------|-------|
|            | Vacunado | No vacunado | Total |
| Enfermo    | 11       | 70          | 81    |
| No enfermo | 538      | 464         | 1002  |
| Total      | 549      | 534         | 1083  |

**Hipótesis:**

- $H_0$ : Vacunación e infección son independientes (vacuna no efectiva)
- $H_1$ : Vacunación e infección no son independientes (vacuna efectiva)

**En R:**

```
tabla <- matrix(c(11, 70, 538, 464), 2, 2,
                 byrow = TRUE)
chisq.test(tabla)
```

**Interpretación:** Si rechazamos  $H_0$ , hay evidencia de que la vacuna es efectiva.

Tabla  $2 \times 2$ : Caso Especial

**Formato:**

|       |       |       |
|-------|-------|-------|
|       | $Y_1$ | $Y_2$ |
| $X_1$ | $a$   | $b$   |
| $X_2$ | $c$   | $d$   |

**Estadístico:**

$$\chi^2 = \frac{n(ad - bc)^2}{(a + b)(c + d)(a + c)(b + d)}$$

con  $\nu = 1$  grado de libertad.

**Corrección de Yates** (si  $n$  pequeño):

$$\chi^2 = \frac{n(|ad - bc| - n/2)^2}{(a + b)(c + d)(a + c)(b + d)}$$

Consideraciones Finales

**Verificar condiciones:**

- Todas las frecuencias esperadas  $\geq 5$
- Si no, usar simulación o agrupar categorías

**Interpretación:**

- Rechazar  $H_0$ : Hay asociación/dependencia
- No rechazar  $H_0$ : No hay evidencia de asociación

**Límites:**

- Test asintótico (requiere  $n$  grande)
- No indica dirección ni fuerza de asociación
- Para medir fuerza: coeficiente de contingencia, V de Cramér

# Regresión Lineal Simple

Introducción

**Objetivo:** Hallar la mejor relación funcional entre dos variables  $X$  e  $Y$  a partir de una muestra  $\{(x_i, y_i)\}_{i=1, \dots, n}$ .

**Variable dependiente (respuesta):**  $Y$  - variable aleatoria que queremos predecir.

**Variable independiente (regresora):**  $X$  - variable de control o explicativa (no necesariamente aleatoria).

**Modelo de regresión lineal:** Si la relación es una recta:

$$\mu_{Y|x} = \beta_0 + \beta_1 x$$

donde  $\mu_{Y|x}$  es el valor esperado de  $Y$  cuando  $X = x$ .

**Parámetros a estimar:**  $\beta_0$  (ordenada al origen) y  $\beta_1$  (pendiente).

Modelo de Regresión Lineal

**Ecuación del modelo:**

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

donde:

- $y_i$ : valor observado de  $Y$  para  $x_i$
- $\beta_0 + \beta_1 x_i$ : valor predicho por el modelo
- $\varepsilon_i$ : error aleatorio (residuo)

**Estimaciones:**  $b_0$  y  $b_1$  estiman  $\beta_0$  y  $\beta_1$  respectivamente.

**Recta de regresión estimada:**

$$\hat{y} = b_0 + b_1 x$$

**Predicción:** Para  $x_0$ ,  $\hat{y}_0 = b_0 + b_1 x_0$ .

# Método de Mínimos Cuadrados

Método de Mínimos Cuadrados

**Error cuadrático teórico:**

$$SS_\varepsilon = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

**Objetivo:** Encontrar  $b_0$  y  $b_1$  que minimizan  $SS_\varepsilon$ .

**Condiciones de mínimo** (derivadas igualadas a cero):

$$\left. \frac{\partial SS_\varepsilon}{\partial \beta_0} \right|_{\beta_0=b_0, \beta_1=b_1} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0$$
$$\left. \frac{\partial SS_\varepsilon}{\partial \beta_1} \right|_{\beta_0=b_0, \beta_1=b_1} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) x_i = 0$$

**Justificación:** Se elevan los errores al cuadrado para penalizar siempre los errores (positivos y negativos) y evitar que se anulen.

Estimadores de Mínimos Cuadrados

**Solución del sistema:**

$$b_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}$$
$$b_0 = \frac{\sum_{i=1}^n y_i - b_1 \sum_{i=1}^n x_i}{n} = \bar{y} - b_1 \bar{x}$$

**En términos de estadísticos muestrales:**

- $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ,  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  (medias)
- $\tilde{s}_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$  (varianza muestral de  $X$ )
- $\tilde{s}_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$  (varianza muestral de  $Y$ )
- $\tilde{s}_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$  (covarianza muestral)

**Forma alternativa:**

$$b_1 = \frac{\tilde{s}_{xy}}{\tilde{s}_x^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$b_0 = \bar{y} - b_1 \bar{x}$$

# Coefficiente de Correlación y Determinación

Coefficiente de Correlación

Definición:

$$r = \frac{\tilde{s}_{xy}}{\tilde{s}_x \tilde{s}_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Propiedades:

- $-1 \leq r \leq 1$
- $r = 1$ : correlación positiva perfecta
- $r = -1$ : correlación negativa perfecta
- $r = 0$ : no hay correlación lineal
- $r > 0$ : relación positiva
- $r < 0$ : relación negativa

Relación con  $b_1$ :

$$b_1 = r \cdot \frac{\tilde{s}_y}{\tilde{s}_x}$$

Coefficiente de Determinación  $R^2$

Definición:

$$R^2 = r^2 = \frac{\tilde{s}_{xy}^2}{\tilde{s}_x^2 \tilde{s}_y^2}$$

Interpretación:

Proporción de la varianza de  $Y$  explicada por el modelo.

Propiedades:

- $0 \leq R^2 \leq 1$
- $R^2 = 1$ : el modelo explica toda la variabilidad
- $R^2 = 0$ : el modelo no explica nada
- $R^2$  cercano a 1: buen ajuste

Suma de cuadrados:

$$R^2 = \frac{SS_{reg}}{SS_{tot}} = 1 - \frac{SS_{res}}{SS_{tot}}$$

donde  $SS_{reg}$  es la suma de cuadrados de la regresión y  $SS_{res}$  es la suma de cuadrados de los residuos.

Descomposición de la Varianza

Suma total de cuadrados:

$$SS_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2$$

Suma de cuadrados de la regresión:

$$SS_{reg} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

Suma de cuadrados de los residuos:

$$SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \varepsilon_i^2$$

Identidad fundamental:

$$SS_{tot} = SS_{reg} + SS_{res}$$

Coefficiente de determinación:

$$R^2 = \frac{SS_{reg}}{SS_{tot}} = 1 - \frac{SS_{res}}{SS_{tot}}$$

## Inferencia en Regresión Lineal

Supuestos del Modelo

Modelo:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Supuestos sobre los errores:

- $E(\varepsilon_i) = 0$  para todo  $i$
- $\text{Var}(\varepsilon_i) = \sigma^2$  (homocedasticidad)
- $\varepsilon_i$  independientes
- $\varepsilon_i \sim N(0, \sigma^2)$  (normalidad, opcional para inferencia)

Consecuencias:

- $E(Y_i | x_i) = \beta_0 + \beta_1 x_i$
- $\text{Var}(Y_i | x_i) = \sigma^2$

Estimación de  $\sigma^2$

Varianza residual:

$$s^2 = \frac{SS_{res}}{n - 2} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - 2}$$

Desviación estándar residual:

$$s = \sqrt{s^2}$$

Grados de libertad:

$n - 2$  (se pierden 2 grados por estimar  $\beta_0$  y  $\beta_1$ ).

Interpretación:

Medida de la dispersión de los datos alrededor de la recta de regresión.

Inferencia sobre los Parámetros

Distribuciones (bajo normalidad):

- $b_0 \sim N\left(\beta_0, \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2}\right]\right)$
- $b_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right)$

Errores estándar estimados:

$$SE(b_0) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2}}$$
$$SE(b_1) = \frac{s}{\sqrt{\sum (x_i - \bar{x})^2}}$$

Estadísticos t:

$$t_0 = \frac{b_0 - \beta_0}{SE(b_0)} \sim t_{n-2}, \quad t_1 = \frac{b_1 - \beta_1}{SE(b_1)} \sim t_{n-2}$$

Intervalos de confianza (nivel  $1 - \alpha$ ):

$$b_0 \pm t_{\alpha/2, n-2} \cdot SE(b_0), \quad b_1 \pm t_{\alpha/2, n-2} \cdot SE(b_1)$$

Contrastes de hipótesis:

- $H_0 : \beta_1 = 0$  vs  $H_1 : \beta_1 \neq 0$ : ¿Hay relación lineal?
- $H_0 : \beta_0 = 0$  vs  $H_1 : \beta_0 \neq 0$ : ¿Pasa por el origen?

Transformaciones y Modelos No Lineales

Modelo Potencial

**Modelo:**  $y = \beta_0 \cdot x^{\beta_1}$  con  $\beta_0 > 0$

**Transformación:** Aplicar  $\log_{10}$  a ambos lados:

$$\log_{10}(y) = \log_{10}(\beta_0) + \beta_1 \log_{10}(x)$$

Modelo lineal equivalente:

$$Y' = \beta'_0 + \beta_1 X'$$

donde  $Y' = \log_{10}(y)$ ,  $X' = \log_{10}(x)$ ,  $\beta'_0 = \log_{10}(\beta_0)$ ,  $\beta'_1 = \beta_1$ .

Estimación:

- Ajustar  $\text{lm}(\log_{10}(y) \sim \log_{10}(x))$
- Obtener  $b'_0$  y  $b'_1$
- $\beta_0 = 10^{b'_0}$ ,  $\beta_1 = b'_1$

**Gráfico:** Escala log-log (ambos ejes logarítmicos).

Modelo Exponencial

**Modelo:**  $y = \beta_0 \cdot \beta_1^x$  con  $\beta_0 > 0$ ,  $\beta_1 > 0$

**Transformación:** Aplicar  $\log_{10}$  solo a  $y$ :

$$\log_{10}(y) = \log_{10}(\beta_0) + \log_{10}(\beta_1) \cdot x$$

Modelo lineal equivalente:

$$Y' = \beta'_0 + \beta'_1 x$$

donde  $Y' = \log_{10}(y)$ ,  $\beta'_0 = \log_{10}(\beta_0)$ ,  $\beta'_1 = \log_{10}(\beta_1)$ .

Estimación:

- Ajustar  $\text{lm}(\log_{10}(y) \sim x)$
- Obtener  $b'_0$  y  $b'_1$
- $\beta_0 = 10^{b'_0}$ ,  $\beta_1 = 10^{b'_1}$

**Gráfico:** Escala semi-logarítmica (solo eje  $y$  logarítmico).

Resumen de Transformaciones

| Modelo      | Ecuación                        | Transformación               | Modelo Lineal                |
|-------------|---------------------------------|------------------------------|------------------------------|
| Lineal      | $y = \beta_0 + \beta_1 x$       | Ninguna                      | $y = \beta_0 + \beta_1 x$    |
| Potencial   | $y = \beta_0 x^{\beta_1}$       | $\log_{10}(y), \log_{10}(x)$ | $Y' = \beta'_0 + \beta_1 X'$ |
| Exponencial | $y = \beta_0 \beta_1^x$         | $\log_{10}(y)$               | $Y' = \beta'_0 + \beta'_1 x$ |
| Logarítmico | $y = \beta_0 + \beta_1 \log(x)$ | $\log(x)$                    | $y = \beta_0 + \beta_1 X'$   |

**Nota:** Después de la transformación, se aplica regresión lineal estándar y luego se transforman los parámetros de vuelta a la escala original.

Funciones R para Regresión Lineal

lm(): Ajuste del Modelo

Sintaxis:

```
modelo <- lm(y ~ x)
modelo <- lm(y ~ x + 1) # explícito
```

Resultado: Objeto de clase lm con:

- coefficients:**  $b_0$  y  $b_1$
- fitted.values:** valores predichos  $\hat{y}_i$
- residuals:** residuos  $\varepsilon_i$
- df.residual:** grados de libertad  $(n - 2)$

Acceso:

- `modelo$coefficients[1]:`  $b_0$
- `modelo$coefficients[2]:`  $b_1$

summary(): Resumen del Modelo

Sintaxis: summary(modelo)

Información proporcionada:

- Estimate: estimaciones  $b_0$  y  $b_1$
- Std. Error: errores estándar
- t value: estadísticos  $t$
- Pr(> |t|):  $p$ -valores
- Residual standard error:  $s$  (desviación estándar residual)
- Multiple R-squared:  $R^2$
- Adjusted R-squared:  $R^2$  ajustado
- F-statistic: estadístico  $F$  para el modelo

Funciones Adicionales

Predicción:

- predict(modelo, newdata = data.frame(x = x0)): Predice  $y$  para  $x_0$
- predict(modelo, interval = "confidence"): Intervalos de confianza para la media
- predict(modelo, interval = "prediction"): Intervalos de predicción para observaciones

Diagnóstico:

- plot(modelo): Gráficos de diagnóstico (4 gráficos)
- residuals(modelo): Residuos
- fitted(modelo): Valores ajustados

Información del modelo:

- coef(modelo): Coeficientes
- confint(modelo): Intervalos de confianza para los parámetros
- anova(modelo): Tabla ANOVA

Gráficos:

- plot(x, y): Diagrama de dispersión
- abline(modelo): Añade la recta de regresión
- lines(x, y\_pred): Añade curva predicha

Ejemplo: Modelo Potencial

Datos:  $y = 11 \cdot x^2$  (con error)

Código R:

```
# Transformación
modelo <- lm(log10(y) ~ log10(x))

# Parámetros estimados
b0 <- modelo$coefficients[1]
b1 <- modelo$coefficients[2]

# Transformación inversa
beta0 <- 10^b0
beta1 <- b1

# Recta estimada
y_est <- beta0 * x^beta1
```

Resultado:  $\beta_0 \approx 11$ ,  $\beta_1 \approx 2$

Ejemplo: Modelo Exponencial

Datos:  $y = 3 \cdot 2^x$  (con error)

Código R:

```
# Transformación
modelo <- lm(log10(y) ~ x)

# Parámetros estimados
b0 <- modelo$coefficients[1]
b1 <- modelo$coefficients[2]

# Transformación inversa
beta0 <- 10^b0
beta1 <- 10^b1

# Curva estimada
y_est <- beta0 * beta1^x
```

Resultado:  $\beta_0 \approx 3$ ,  $\beta_1 \approx 2$

Consideraciones Importantes

Validación del modelo:

- Verificar supuestos (normalidad de residuos, homocedasticidad)
- Revisar gráficos de diagnóstico
- Comprobar outliers e influyentes
- Validar  $R^2$  y significación de parámetros

Limitaciones:

- Relación lineal (o linealizable)
- Independencia de observaciones
- Homocedasticidad (varianza constante)
- No extrapolar fuera del rango de  $X$  observado

Interpretación:

- $b_1$ : cambio esperado en  $Y$  por unidad de cambio en  $X$
- $b_0$ : valor esperado de  $Y$  cuando  $X = 0$  (si tiene sentido)
- $R^2$ : proporción de variabilidad explicada

# Clustering

## Introducción al Clustering

**Problema:** Dado un conjunto de objetos, clasificarlos en grupos (clusters) basándonos en sus parecidos y diferencias.

**Aplicaciones:**

- **Biología:** Clasificación jerárquica de organismos, agrupamiento de genes y proteínas
- **Marketing:** Identificación de individuos por comportamientos similares
- **Tratamiento de imágenes:** Eliminación de ruido, detección de bordes
- **Biometría:** Identificación de individuos (caras, huellas dactilares)

**Objetivo:** Encontrar grupos naturales en los datos sin etiquetas previas (aprendizaje no supervisado).

## Principios Básicos

**Homogeneidad:** Los objetos dentro de un mismo cluster deben ser próximos o parecidos entre sí.

**Separación:** Los objetos que pertenecen a clusters diferentes deben estar alejados.

**Objetivo:** Maximizar la homogeneidad dentro de los clusters y maximizar la separación entre clusters.

**Validación:** Un buen clustering cumple ambos principios simultáneamente.

## Tipos de Algoritmos

**Algoritmos de partición:**

- Número de clusters  $k$  prefijado
- Ejemplo:  $k$ -medias ( $k$ -means)

**Algoritmos jerárquicos:**

- Producen un árbol de clasificación (dendrograma)
- **Aglomerativos:** De  $n$  clusters a 1 (bottom-up)
- **Divisivos:** De 1 cluster a  $n$  (top-down)

**Resultado jerárquico:** Árbol binario donde cada nodo representa una agrupación/división.

# Algoritmo k-medias (k-means)

## Descripción del Problema

**Datos:** Tabla de  $n$  filas (objetos) y  $m$  columnas (variables continuas).

**Representación:** Cada objeto  $i$  se representa como un vector:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{im}) \in \mathbb{R}^m$$

**Objetivo:** Encontrar  $k$  puntos (centros)  $\mathbf{c}_1, \dots, \mathbf{c}_k \in \mathbb{R}^m$  y una partición de los  $n$  objetos en  $k$  clusters  $C_1, \dots, C_k$  tal que se minimice:

$$SS_C = \sum_{j=1}^k \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \mathbf{c}_j\|^2$$

donde  $\|\mathbf{x}_i - \mathbf{c}_j\|$  es la distancia euclídea entre el objeto  $\mathbf{x}_i$  y el centro  $\mathbf{c}_j$ .

## Distancia Euclídea

**Definición:** Dados dos objetos  $\mathbf{x} = (x_1, \dots, x_m)$  e  $\mathbf{y} = (y_1, \dots, y_m)$  en  $\mathbb{R}^m$ :

$$\|\mathbf{x} - \mathbf{y}\| = \sqrt{\sum_{i=1}^m (x_i - y_i)^2}$$

**Interpretación:** Para  $m = 2$  o  $m = 3$ , es la longitud del segmento que une los puntos.

**Propiedad:** Dos objetos están más próximos cuanto menor es la distancia euclídea entre ellos.

**Uso:** Medida de proximidad entre objetos en el espacio de características.

## Algoritmo k-medias: Pasos

### Inicialización:

1. Elegir  $k$  centros iniciales  $\mathbf{c}_1^{(0)}, \dots, \mathbf{c}_k^{(0)}$  aleatoriamente

### Iteración (repetir hasta convergencia):

1. **Asignación:** Para cada objeto  $\mathbf{x}_i$ , asignarlo al cluster  $C_j$  cuyo centro  $\mathbf{c}_j$  esté más cerca:

$$\mathbf{x}_i \in C_j \text{ si } \|\mathbf{x}_i - \mathbf{c}_j\| = \min_{l=1, \dots, k} \|\mathbf{x}_i - \mathbf{c}_l\|$$

2. **Actualización:** Recalcular los centros como las medias de los objetos en cada cluster:

$$\mathbf{c}_j = \frac{1}{|C_j|} \sum_{\mathbf{x}_i \in C_j} \mathbf{x}_i$$

**Criterio de parada:** Cuando los clusters no cambian entre iteraciones (o cambio mínimo).

Propiedades del Algoritmo

Ventajas:

- Simple y eficiente
- Escalable a grandes conjuntos de datos
- Converge rápidamente

Desventajas:

- Requiere especificar  $k$  a priori
- Sensible a la inicialización
- Puede quedar atrapado en mínimos locales
- Asume clusters esféricos y de tamaño similar

Solución:

Ejecutar múltiples veces con diferentes inicializaciones y elegir el mejor resultado.

Suma de Cuadrados

Suma de cuadrados dentro de clusters:

$$SS_C = \sum_{j=1}^k SS_{C_j} = \sum_{j=1}^k \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \mathbf{c}_j\|^2$$

Suma total de cuadrados:

$$SS_{tot} = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2$$

donde  $\bar{\mathbf{x}}$  es el centroide global.

Suma entre clusters:

$$SS_{between} = SS_{tot} - SS_C$$

Interpretación:

Minimizar  $SS_C$  equivale a maximizar  $SS_{between}$ .

## Clustering Jerárquico

Métodos Jerárquicos Aglomerativos

Proceso:

- Paso inicial:** Cada objeto forma su propio cluster ( $n$  clusters)
- En cada paso:** Se unen los dos clusters más próximos
- Paso final:** Un único cluster con todos los objetos

Resultado:

Dendrograma (árbol binario) que muestra la jerarquía de agrupaciones.

Ventajas:

- No requiere especificar  $k$  a priori
- Proporciona jerarquía completa
- Visualización clara del proceso

Desventajas:

- Computacionalmente más costoso ( $O(n^3)$ )
- Decisiones irreversibles
- Sensible a outliers

Métodos de Enlace

Enlace simple (single):

$$d(C_i, C_j) = \min_{\mathbf{x} \in C_i, \mathbf{y} \in C_j} \|\mathbf{x} - \mathbf{y}\|$$

Distancia mínima entre clusters.

Enlace completo (complete):

$$d(C_i, C_j) = \max_{\mathbf{x} \in C_i, \mathbf{y} \in C_j} \|\mathbf{x} - \mathbf{y}\|$$

Distancia máxima entre clusters.

Enlace promedio (average):

$$d(C_i, C_j) = \frac{1}{|C_i| \cdot |C_j|} \sum_{\mathbf{x} \in C_i} \sum_{\mathbf{y} \in C_j} \|\mathbf{x} - \mathbf{y}\|$$

Distancia promedio entre clusters.

Métodos de Enlace (cont.)

Mediana (median):

$$d(C_i, C_j) = \|\mathbf{c}_i - \mathbf{c}_j\|$$

donde  $\mathbf{c}_i$  y  $\mathbf{c}_j$  son las medianas de los clusters.

Centroide (centroid):

$$d(C_i, C_j) = \|\bar{\mathbf{x}}_i - \bar{\mathbf{x}}_j\|$$

donde  $\bar{\mathbf{x}}_i$  y  $\bar{\mathbf{x}}_j$  son los centroides.

Ward (ward.D):

$$d(C_i, C_j) = \frac{|C_i| \cdot |C_j|}{|C_i| + |C_j|} \|\bar{\mathbf{x}}_i - \bar{\mathbf{x}}_j\|^2$$

Minimiza la varianza dentro de clusters.

Dendrograma

Definición:

Representación gráfica del árbol jerárquico de clustering.

Elementos:

- Hojas:** Objetos individuales (base del árbol)
- Nodos:** Uniones de clusters
- Altura:** Distancia a la que se unen los clusters
- Raíz:** Cluster único con todos los objetos (cima del árbol)

Corte del dendrograma:

- Por altura  $h$ : Cortar a una distancia específica
- Por número de clusters  $k$ : Obtener  $k$  clusters

Interpretación:

La altura indica la ”distancia” entre clusters unidos.

## Distancias y Escalado

## Tipos de Distancias

**Euclídea** (por defecto):

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^m (x_i - y_i)^2}$$

**Manhattan:**

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^m |x_i - y_i|$$

**Máximo:**

$$d(\mathbf{x}, \mathbf{y}) = \max_{i=1, \dots, m} |x_i - y_i|$$

**Canberra:**

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^m \frac{|x_i - y_i|}{|x_i| + |y_i|}$$

## Tipos de Distancias (cont.)

**Minkowski** (con parámetro  $p > 0$ ):

$$d(\mathbf{x}, \mathbf{y}) = \left( \sum_{i=1}^m |x_i - y_i|^p \right)^{1/p}$$

- $p = 1$ : Manhattan
- $p = 2$ : Euclídea
- $p \rightarrow \infty$ : Máximo

**Binaria** (para vectores binarios):

$$d(\mathbf{x}, \mathbf{y}) = \frac{\text{número de posiciones diferentes}}{\text{número de posiciones con al menos un 1}}$$

**Nota:** La elección de la distancia afecta significativamente los resultados del clustering.

## Escalado de Datos

**Problema:** Variables con diferentes escalas pueden dominar el clustering.

**Solución:** Estandarizar las variables antes del clustering.

**Estandarización:**

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

donde:

- $\bar{x}_j$ : media de la variable  $j$
- $s_j$ : desviación estándar de la variable  $j$

**Resultado:** Variables con media 0 y desviación estándar 1.

**Importancia:** Especialmente crítico cuando las variables tienen unidades diferentes o rangos muy distintos.

## Funciones R para Clustering

### kmeans(): k-medias

**Sintaxis:**

```
resultado <- kmeans(x, centers = k,
                    iter.max = 10,
                    nstart = 1)
```

**Parámetros:**

- **x**: tabla de datos (matriz o data.frame)
- **centers**: número de clusters  $k$
- **iter.max**: máximo de iteraciones
- **nstart**: número de inicializaciones aleatorias

**Salida:**

- **resultado\$cluster**: asignación de clusters
- **resultado\$centers**: centros de clusters
- **resultado\$size**: tamaños de clusters
- **resultado\$withinss**:  $SS_{C_j}$  por cluster
- **resultado\$tot.withinss**:  $SS_C$  total

### dist(): Matriz de Distancias

**Sintaxis:**

```
d <- dist(x, method = "euclidean")
```

**Parámetros:**

- **x**: tabla de datos
- **method**: tipo de distancia
  - "euclidean" (por defecto)
  - "manhattan"
  - "maximum"
  - "canberra"
  - "minkowski" (requiere p)
  - "binary"

**Salida:** Objeto de clase **dist** (no matriz estándar).

### scale(): Estandarización

**Sintaxis:**

```
x_scaled <- scale(x, center = TRUE,
                  scale = TRUE)
```

**Parámetros:**

- **center = TRUE**: resta la media (por defecto)
- **scale = TRUE**: divide por desviación estándar (por defecto)
- También acepta vectores numéricos para centrar/escalar manualmente

**Resultado:** Datos estandarizados (media 0, desv. estándar 1).

### hclust(): Clustering Jerárquico

**Sintaxis:**

```
hc <- hclust(d, method = "ward.D")
```

**Parámetros:**

- **d**: matriz de distancias (objeto dist)
- **method**: método de enlace
  - "ward.D", "complete", "single"
  - "average", "median", "centroid"

**Salida:**

- **hc\$merge**: matriz de fusiones
- **hc\$height**: alturas de fusiones

## Visualización y Extracción de Clusters

**plot(hc):** Dibuja el dendrograma

- **hang:** controla posición de hojas
- **labels:** nombres de objetos

**cutree(hc, k = ...):** Extrae  $k$  clusters del dendrograma

- Alternativa: **cutree(hc, h = ...)** por altura

**rect.hclust(hc, k = ...):** Dibuja rectángulos alrededor de clusters en el dendrograma

- Requiere haber llamado **plot()** primero
- Útil para visualizar la partición elegida

**Ejemplo:**

```
plot(hc)
clusters <- cutree(hc, k = 3)
rect.hclust(hc, k = 3)
```

## Determinación del Número de Clusters

**Método del codo (Elbow):**

- Graficar  $SS_C$  vs  $k$
- Buscar el "codo" donde  $SS_C$  deja de disminuir rápidamente

**Silueta (Silhouette):**

- Mide qué tan bien está asignado cada objeto
- Valores altos: buena asignación
- Elegir  $k$  que maximice la silueta promedio

**Gap statistic:**

- Compara  $SS_C$  con valores esperados bajo distribución nula
- Elegir  $k$  que maximice el gap

## Consideraciones Finales

**Preprocesamiento:**

- Estandarizar variables (especialmente si escalas diferentes)
- Manejar valores faltantes
- Considerar transformaciones si datos sesgados

**Validación:**

- Verificar homogeneidad y separación
- Comparar diferentes métodos
- Usar conocimiento del dominio

**Limitaciones:**

- Resultados dependen de inicialización (k-means)
- Asume clusters convexos (k-means)
- Sensible a outliers
- Elección de distancia y método afecta resultados