

Tema 3: Intervalos de Confianza

Parte 2: Inferencia estadística con R y python

noviembre 2023

Lección 1

Definiciones básicas

Estimación por intervalos

Una estimación por intervalos de un parámetro poblacional es una regla para calcular, a partir de una muestra, un intervalo en el que, con una cierta probabilidad (nivel de confianza), se encuentra el valor verdadero del parámetro.

Estas reglas definirán, a su vez, estimadores.

Estimación por intervalos. Ejemplos

Ejemplo

Hemos escogido al azar 50 estudiantes de grado de la UIB, hemos calculado sus notas medias de las asignaturas del primer semestre, y la media de estas medias ha sido $\bar{x} = 6.3$, con una varianza muestral $\tilde{s}^2 = 1.8$.

Determinar un intervalo del que podamos afirmar con probabilidad 95% que contiene la media real de las notas medias de los estudiantes de grado de la UIB este primer semestre.

Ejemplo

En un experimento en el que se ha medido la tasa oficial de alcoholemia en sangre a 40 varones (sobrios) después de tomar 3 cañas de cerveza de 330 ml. La media y la desviación típica de esta tasa han sido

$$\bar{x} = 0.7, \quad \tilde{s} = 0.1.$$

Determinar un intervalo que podamos afirmar con probabilidad 95% que contiene la tasa de alcoholemia media en sangre de una varón después de beber 3 cañas de cerveza de 330 ml.

Definición de intervalo de confianza

Intervalo de confianza. Dado un parámetro θ , el intervalo (A, B) es un intervalo de confianza del $(1 - \alpha) \cdot 100\%$ para el parámetro θ cuando

$$P(A < \theta < B) = 1 - \alpha.$$


El valor $(1 - \alpha) \cdot 100\%$ (y también $1 - \alpha$) recibe el nombre de **nivel de confianza**.

El valor α recibe el nombre de **nivel de significación**.

Definición de intervalo de confianza

Por defecto, buscaremos intervalos bilaterales tales que la **cola de probabilidad sobrante** α se reparta por igual a cada lado del intervalo:

$$P(\theta < A) = P(\theta > B) = \frac{\alpha}{2}$$



Por ejemplo, para buscar un intervalo de confianza (A, B) del 95%, buscaremos valores A, B de manera que

Lección 2

Intervalos de confianza para el parámetro μ de una población normal

Intervalos de confianza para el parámetro μ de una población normal con σ conocida

Sea X una v.a. normal con media poblacional μ desconocida y desviación típica poblacional σ conocida (en la práctica, usualmente, estimada en un experimento anterior)

Sea $X_1, \dots, X_n$ una m.a.s. de X , con media muestral $\bar{X}$

Queremos determinar un intervalo de confianza para μ con un cierto nivel de confianza (digamos, 97.5%, $\alpha = 0.025$): un intervalo (A, B) tal que

$$P(A < \mu < B) = 1 - \alpha = 0.975$$

I.C. para el parámetro μ de una población normal con σ conocida

Bajo estas condiciones, sabemos que

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

sigue una distribución normal estándar.

Comencemos calculando un intervalo centrado en 0 en el que Z tenga probabilidad 0.975:

$$\begin{aligned} 0.975 &= P(-\delta < Z < \delta) = F_Z(\delta) - F_Z(-\delta) = 2 \cdot F_Z(\delta) - 1 \\ F_Z(\delta) &= \frac{1.975}{2} = 0.9875 \Rightarrow \delta = \text{qnorm}(0.9875) = 2.2414. \end{aligned}$$

I.C. para el parámetro μ de una población normal con σ conocida

Por lo tanto

$$P(-2.2414 < Z < 2.2414) = 0.975$$

Substituyendo $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$:

$$P\left(-2.2414 < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < 2.2414\right) = 0.975$$

$$P\left(\bar{X} - 2.2414\frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + 2.2414\frac{\sigma}{\sqrt{n}}\right) = 0.975$$

I.C. para el parámetro μ de una población normal con σ conocida

Por lo tanto, la probabilidad que la media poblacional μ de X se encuentre dentro del intervalo

$$\left(\bar{X} - 2.2414 \frac{\sigma}{\sqrt{n}}, \bar{X} + 2.2414 \frac{\sigma}{\sqrt{n}} \right)$$

es 0.975: es un intervalo de confianza del 97.5%.

Además tenemos que está centrado en $\bar{X}$: el 0.025 de probabilidad restante está repartido por igual en los dos extremos del intervalo.

I.C. para el parámetro μ de una población normal con σ conocida

Como estimador: un 97.5% de las veces que tomemos una muestra de tamaño n de X , el verdadero valor de μ caerá dentro de este intervalo

Para una muestra concreta: la probabilidad de que, si una media μ poblacional ha producido esta muestra, entonces esté en este intervalo concreto, es del 97.5%.

En ocasiones lo entenderemos como: *La probabilidad de que μ esté en este intervalo es del 97.5%.*

Pero la frase anterior es mentira (*es un abuso de lenguaje*): La μ concreta es un valor fijo, por lo tanto que pertenezca o no a este intervalo concreto tiene probabilidad 1 (si pertenece) y 0 (si no pertenece).

I.C. para el parámetro μ de una población normal con σ conocida

Teorema. Sea $X \sim N(\mu, \sigma)$ con μ desconocida y σ conocida.

Tomamos una m.a.s. de X de tamaño n , con media $\bar{X}$.

Un intervalo de confianza del $(1 - \alpha) \cdot 100\%$ para μ es

$$\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right)$$

donde $z_{1-\frac{\alpha}{2}}$ es el $(1 - \frac{\alpha}{2})$ -cuantil de la normal estándar Z (es decir, $z_{1-\frac{\alpha}{2}} = F_Z^{-1}(1 - \frac{\alpha}{2})$, o $P(Z \leq z_{1-\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2}$).

I.C. para el parámetro μ de una población normal con σ conocida

Si X es normal con σ conocida, un intervalo de confianza I.C. para μ de población normal con σ conocida μ del $(1 - \alpha) \cdot 100\%$ es

$$\bar{X} \pm z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} := \left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right)$$

Observad que está centrado en $\bar{X}$.

I.C. para el parámetro μ de una población normal con σ conocida

La tabla siguiente muestra los cuantiles más usados:

Confianza $1 - \alpha$	Significación α	Cuantil $z_{1-\frac{\alpha}{2}}$
0.90	0.1	1.645
0.95	0.05	1.96
0.975	0.025	2.241

Simulación de intervalos de confianza

Ejemplo

A continuación vamos a simular el funcionamiento de un intervalo de confianza para una distribución normal.

Consideramos una población de 10^6 individuos que proviene de una distribución normal de parámetros $\mu = 1.5$ y $\sigma = 1$:

```
set.seed(4)
mu=1.5; sigma=1; alpha=0.05
Poblacion=rnorm(n=10^6,mean = mu, sd=sigma)
```

Vamos a generar 100 muestras aleatorias simples de tamaño 50 de dicha población para posteriormente generar un intervalo de confianza al 95% de confianza para el parámetro μ para cada muestra.

Simulación de intervalos de confianza

Primero definiremos una función para que, dada una muestra, un valor σ y un nivel de significación α nos genere el intervalo correspondiente para el parámetro μ al nivel de confianza $100 \cdot (1 - \alpha)\%$. La llamaremos ICZ:

```
ICZ=function(x,sigma,alpha){  
  c(mean(x)-qnorm(1-alpha/2)*sigma/sqrt(length(x)),  
    mean(x)+qnorm(1-alpha/2)*sigma/sqrt(length(x)))}
```

Simulación de intervalos de confianza

Usando la función `replicate` de R generamos las muestras y los intervalos de confianza correspondientes usando la función anterior:

```
set.seed(2)
M=replicate(100,ICZ(sample(Poblacion,50,replace=T),
  sigma,alpha))
```

Simulación de intervalos de confianza


El objeto M de R es una matriz de 2 filas y 100 columnas donde la columna i -ésima representa el intervalo de confianza para la muestra i -ésima generada.

Finalmente vamos a dibujar todos los intervalos anteriores y resaltaremos en color rojo aquéllos en los que el parámetro $\mu = 1.5$ no esté en ellos. Esperamos que haya aproximadamente 5 en los que esta condición falle.

```
plot(1:10,type="n",xlim=c(1.2,1.8),ylim=c(0,100),
     xlab="Valores",ylab="Replicaciones")
seg.int=function(i){color="grey";
  if((mu<M[1,i]) | (mu>M[2,i])){color = "red"}
  segments(M[1,i],i,M[2,i],i,col=color,lwd=3)}
invisible(sapply(1:100,FUN=seg.int))
abline(v=mu,lwd=3)
```

Simulación de intervalos de confianza

El resultado se muestra en la figura siguiente:



Intervalos de confianza para el parámetro μ de una población normal con σ conocida.

¡Atención! De media, un $\alpha \cdot 100\%$ de las veces, un intervalo de confianza del $(1 - \alpha) \cdot 100\%$ no contendrá el valor real del parámetro.

Por ejemplo, de media, un 5% de las veces un intervalo de confianza del 95% no contendrá el valor real del parámetro.

Intervalos de confianza para el parámetro μ de una población normal con σ conocida. Ejemplo

Ejercicio

Tomamos una m.a.s. de tamaño $n = 16$ de una v.a. normal con $\sigma = 4$ y μ desconocida. La media de la m.a.s. es $\bar{x} = 20$. Calculad un intervalo de confianza del 97.5% para μ de una población normal con σ conocida.

El valor de α será $\alpha = 1 - 0.975 = 0.025$. El intervalo de confianza será:

$$\left(\bar{x} - z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} \right) = \left(20 - 2.241 \cdot \frac{4}{\sqrt{16}}, 20 + 2.241 \cdot \frac{4}{\sqrt{16}} \right) = (17.759, 22.241)$$

La probabilidad de que, si una media μ poblacional ha producido esta muestra, entonces esté en este intervalo concreto, es del 97.5%.

Intervalos de confianza para el parámetro μ de una población normal con σ conocida. Ejemplo

Ejemplo

Queremos analizar un sensor que mide la temperatura de un procesador en grados centígrados, en concreto un Intel Core i7-2600K, que tiene como temperatura normal de 32° a 40°. Para saber si está bien calibrado, diseñamos un experimento en el que ponemos el procesador en las mismas condiciones y tomamos una muestra de 40 valores de su temperatura.

Los resultados son los siguientes:

```
temperatura=c(36,35,38,38,36,37,38,36,37,36,  
              37,37,34,38,35,37,36,36,34,38,  
              36,37,35,35,35,35,36,36,36,35,  
              36,35,34,34,37,37,35,36,34,36)
```

Intervalos de confianza para el parámetro μ de una población normal con σ conocida. Ejemplo

Supongamos que las medidas de nuestro sensor siguen una distribución normal con varianza poblacional conocida $\sigma^2 = 1.44$. Calculad un intervalo de confianza del 90% para el resultado medio de la temperatura del procesador.

Intervalos de confianza para el parámetro μ de una población normal con σ conocida. Ejemplo

Tenemos las siguientes condiciones:

- Población normal con $\sigma = \sqrt{1.44} = 1.2$ conocida.
- Muestra aleatoria simple de tamaño $n = 40$.
- Media de la muestra $\bar{x} = 35.975$.
- $1 - \alpha = 0.9 \Rightarrow \alpha = 0.1 \Rightarrow 1 - \frac{\alpha}{2} = 0.95$.
- $z_{0.95} \approx 1.645$.

Aplicamos la fórmula $\bar{X} \pm z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$ con $\bar{x} = 35.975$, $z_{0.95} = 1.645$, $\sigma = 1.2$, $n = 40$.

Obtenemos que el intervalo de confianza del 90% es

$$35.975 \pm 1.645 \cdot \frac{1.2}{\sqrt{40}} = (35.663, 36.287).$$

Intervalos de confianza para el parámetro μ de una población normal con σ conocida. Amplitud

Amplitud del intervalo de confianza. La amplitud A del intervalo de confianza a un nivel $100 \cdot (1 - \alpha)\%$ de confianza será:

$$A = \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} - \left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right) = 2 \cdot z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}.$$

Error máximo cometido. El error máximo, al nivel de confianza $100 \cdot (1 - \alpha)\%$, que cometemos al estimar μ por $\bar{X}$ es la mitad de la amplitud,

$$z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}.$$

Intervalos de confianza para el parámetro μ de una población normal con σ conocida. Amplitud

Propiedades

- La **amplitud** del intervalo de confianza para el parámetro μ de una población normal con σ conocida, n y α fijos **crece**, si σ **crece**.
- La **amplitud** del intervalo de confianza para el parámetro μ de una población normal con σ conocida y α fijo **decrece**, si n **crece**.
- La **amplitud** del intervalo de confianza para el parámetro μ de una población normal con σ conocida y n fijo **crece**, si $1 - \alpha$ **crece**, o si α **decrece**.

Intervalos de confianza para el parámetro μ de una población normal con σ conocida. Amplitud

Problema: hallar el tamaño n mínimo de la muestra para asegurar que el intervalo de confianza para μ al nivel de confianza $(1 - \alpha)$ tenga una amplitud prefijada máxima A_0 (o un error máximo $A_0/2$).

Resolución: usando que la amplitud máxima tiene que ser A_0 tenemos que se tiene que verificar $A_0 \geq 2z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$.

Despejando n de la expresión anterior, tendremos que el tamaño de la muestra mínimo será:

$$n \geq \left(2z_{1-\frac{\alpha}{2}} \frac{\sigma}{A_0} \right)^2.$$

I.C. para el parámetro μ de una población normal con σ conocida. Ejemplo

Ejemplo

Recordemos que las medidas de nuestro sensor de temperatura seguían una distribución normal con varianza poblacional conocida $\sigma^2 = 1.44$, $\sigma = 1.2$.

¿Cuántas medidas tendríamos que tomar para obtener la temperatura media con un error máximo de 0.05° al nivel de confianza del 90%?

Nos dicen que $\frac{A_0}{2} = 0.05$, o sea, $A_0 = 0.1$. Usando la expresión anterior, tendremos que el número de medidas mínimo n que tendríamos que tomar es:

$$n = \left\lceil \left(2z_{1-\frac{\alpha}{2}} \frac{\sigma}{A_0} \right)^2 \right\rceil$$

donde $z_{1-\frac{\alpha}{2}} = 1.645$, $\sigma = 1.2$. Obtenemos $n = \left\lceil \left(2 \cdot 1.645 \cdot \frac{1.2}{0.1} \right)^2 \right\rceil = \lceil 1558.393 \rceil = 1559$.

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida

Recordemos que para hallar el intervalo de confianza para el parámetro μ de una población normal, era clave la variable aleatoria $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}$.

El problema es que ahora no la podemos usar al no conocer σ .

Lo que haremos será sustituir la desviación típica poblacional σ por la desviación típica muestral $\tilde{S}_X$ y nos quedará: $\frac{\bar{X}-\mu}{\tilde{S}_X/\sqrt{n}}$, donde $\bar{X}$ es la media muestral y n , el tamaño de la muestra.

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida

La distribución de la variable anterior $\frac{\bar{X}-\mu}{\tilde{S}_X/\sqrt{n}}$, no será normal sino t de Student con $n - 1$ grados de libertad como nos dice el teorema siguiente:

> **Teorema.** Sea $X \sim N(\mu, \sigma)$. Sea $X_1, \dots, X_n$ una m.a.s. de X , con media $\bar{X}$ y desviación típica muestral $\tilde{S}_X$

En estas condiciones, la v.a. $t = \frac{\bar{X}-\mu}{\tilde{S}_X/\sqrt{n}}$, sigue una distribución t de Student con $n - 1$ grados de libertad, t_{n-1} .

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida. Distribución t de Student

La distribución t de Student con ν grados de libertad, t_ν tiene como función de densidad

$$f_{t_\nu}(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi} \Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}},$$

donde $\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt$ si $x > 0$.

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida. Distribución t de Student

Propiedades


- $E(t_\nu) = 0$ si $\nu > 1$ y $Var(t_\nu) = \frac{\nu}{\nu - 2}$ si $\nu > 2$.
- Su función de distribución es simétrica respecto de $E(t_\nu) = 0$ (como la de una $N(0, 1)$):

$$P(t_\nu \leq -x) = P(t_\nu \geq x) = 1 - P(t_\nu \leq x).$$

- Si ν es grande, su distribución es aproximadamente la de $N(0, 1)$ (pero con más varianza: un poco más aplastada)

Distribución t de Student

Gráficas de las densidades de diferentes distribuciones t de Student junto con la densidad de la $N(0, 1)$:



Intervalos de confianza para el parámetro μ de una población normal con σ desconocida. Distribución t de Student

Indicaremos con $t_{\nu,q}$ el q -cuantil de una v.a. X que sigue una distribución t_{ν} :

$$P(X \leq t_{\nu,q}) = q$$

Por simetría, $t_{\nu,q} = -t_{\nu,1-q}$.

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida

Consideremos la situación siguiente:

- X una v.a. normal con μ y σ desconocidas.
- $X_1, \dots, X_n$ una m.a.s. de X de tamaño n , con media $\bar{X}$ y varianza muestral $\tilde{S}_X^2$.

> **Intervalo de confianza para el parámetro μ .** En estas condiciones, un intervalo de confianza del $(1 - \alpha) \cdot 100\%$ para el parámetro μ de una población normal con σ desconocida es

$$\left(\bar{X} - t_{n-1, 1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}}, \bar{X} + t_{n-1, 1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}} \right).$$

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida. Ejemplo

Ejemplo

La empresa *3D-print* ofrece una impresora industrial de papel en color de alta capacidad. En su publicidad afirma que sus cartuchos imprimen una media de 500 mil copias con la especificación:

Ficha técnica: Muestra de tamaño $n=100$, población aproximadamente normal, nivel de confianza del 90%.

La OCU (asociación de consumidores) desea comprobar estas afirmaciones y su laboratorio toma una muestra aleatoria de tamaño $n = 24$, obteniendo una media de $\bar{x} = 518$ mil impresiones y una desviación típica muestral $\tilde{s} = 40$ mil.

Con esta muestra ¿la media poblacional anunciada por fabricante cae en el intervalo de confianza del 90%?

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida. Ejemplo

Hay que calcular el intervalo de confianza para la μ de una población normal con σ desconocida μ con los valores siguientes: $n = 24, \bar{x} = 518, \tilde{s} = 40, \alpha = 0.1$.

Dicho intervalo será el siguiente:

$$\left(\bar{x} - t_{23,0.95} \frac{\tilde{s}}{\sqrt{n}}, \bar{x} + t_{23,0.95} \frac{\tilde{s}}{\sqrt{n}} \right) = \left(518.000 - 1.714 \frac{40.000}{\sqrt{24}}, 518.000 + 1.714 \frac{40.000}{\sqrt{24}} \right) =$$

$$(5.040063 \times 10^5, 5.319937 \times 10^5).$$

Observamos que no contiene a 500.000 (¡pero se equivoca a favor del consumidor!)

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida. Ejemplo

Observaciones:

- El intervalo de confianza obtenido está centrado en $\bar{X}$
- La fórmula $\left(\bar{X} - t_{n-1, 1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}}, \bar{X} + t_{n-1, 1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}} \right)$ nos da el intervalo de confianza para μ en una población normal con σ desconocida. La expresión anterior se puede utilizar cuando X es normal y n cualquiera

Intervalos de confianza para el parámetro μ de una población normal con σ desconocida. Ejemplo

Observaciones:

- Si n es grande $t_{n-1, 1-\frac{\alpha}{2}} \approx z_{1-\frac{\alpha}{2}}$ y podemos **aproximar** el intervalo de confianza anterior mediante la expresión siguiente:

$$\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}} \right)$$

Intervalos de confianza para el parámetro μ de una población cualquiera con σ conocida y tamaño muestral grande

Consideremos la situación siguiente:

- X una v.a. **cualquiera** con media poblacional μ desconocida y desviación típica σ desconocida.
- $X_1, \dots, X_n$ una m.a.s. de X , con media $\bar{X}$.
- n **es grande** (pongamos que $n \geq 40$)

Intervalos de confianza para el parámetro μ de una población cualquiera con σ conocida y tamaño muestral grande

En estas condiciones, usando el **Teorema Central del Límite** $\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \approx N(0, 1)$.

Teorema. En las condiciones anteriores, podemos tomar como intervalo de confianza del $(1 - \alpha) \cdot 100\%$ de confianza para el parámetro μ de una población cualquiera con σ conocida la expresión siguiente:

$$\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right)$$

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande

Si la σ es desconocida, podemos aplicar el Teorema anterior sustituyendo σ por $\tilde{S}_X$:

Teorema. En las condiciones anteriores, podemos tomar como intervalo de confianza del $(1 - \alpha) \cdot 100\%$ de confianza para el parámetro μ de una población cualquiera con σ desconocida la expresión siguiente:

$$\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}} \right)$$

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande. Ejemplo

Ejercicio

Se ha tomado una muestra del tiempo de visualización de vídeo semanal en horas de 1000 usuarios de un canal de vídeos por internet. Se ha obtenido una media muestral de 9.5 horas/semana con una desviación típica muestral de 0.5 horas/semana.

Calculad un intervalo de confianza del 95% para la media poblacional del número de horas visualizadas por semana supuesto que sigue aproximadamente una población normal con σ desconocida.

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande. Ejemplo

Como $n = 1000$ es grande, podemos utilizar la expresión siguiente para hallar el intervalo de confianza:

$$\left(\bar{x} - z_{1-\frac{\alpha}{2}} \frac{\tilde{s}}{\sqrt{n}}, \bar{x} + z_{1-\frac{\alpha}{2}} \frac{\tilde{s}}{\sqrt{n}} \right),$$

donde $\bar{x} = 9.5$, $\tilde{s} = 0.5$, $\alpha = 0.05$, $z_{1-\frac{\alpha}{2}} = 1.96$. El intervalo de confianza será, pues:

```
media=9.5
sd=0.5
n=1000
alpha=0.05
cuantil=qnorm(1-alpha/2)
```

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande. Ejemplo

```
(extremo.izquierdo=round(media-cuantil*sd/sqrt(n),3))
```

```
[1] 9.469
```

```
(extremo.derecho=round(media+cuantil*sd/sqrt(n),3))
```

```
[1] 9.531
```

Podemos afirmar con un 95% de confianza que la media poblacional de vídeo consumido en horas por semana está entre 9.469 y 9.531 horas/semana

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande. Amplitud

La amplitud de $\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}}\right)$ es $A = 2z_{1-\frac{\alpha}{2}} \frac{\tilde{S}_X}{\sqrt{n}}$.

Para determinar n (grande) que dé como máximo una amplitud A prefijada, necesitamos $\tilde{S}_X$, que depende de la muestra.

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande. Amplitud

Soluciones:

- Si sabemos la desviación típica poblacional σ , la utilizaremos en lugar de $\tilde{S}_X$.
- Si hemos tomado una muestra previa (piloto), emplearemos la desviación típica muestral de esta **muestra piloto** para estimar σ .

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande. Amplitud

De una población X hemos tomado una m.a.s. (piloto) que ha tenido una desviación típica muestral $\tilde{s}_{piloto}$.

Estimaremos que el tamaño mínimo n de una m.a.s. de X que dé un intervalo de confianza I.C. para μ de una población normal con σ desconocida de nivel de confianza $1 - \alpha$ y amplitud máxima A_0 es

$$n = \left\lceil \left(2z_{1-\frac{\alpha}{2}} \frac{\tilde{s}_{piloto}}{A_0} \right)^2 \right\rceil$$

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande. Amplitud. Ejemplo

Ejercicio

Queremos estimar la estatura media de los estudiantes de la UIB. Queremos obtener un intervalo de confianza del 99% con una precisión máxima de 1 cm. En una muestra piloto de 25 estudiantes, obtuvimos que

$$\bar{x} = 170 \text{ cm}, \tilde{s} = 10 \text{ cm}.$$

¿Basándonos en estos datos, cuál es el tamaño necesario de la muestra para poder alcanzar nuestro objetivo?

Intervalos de confianza para el parámetro μ de una población cualquiera con σ desconocida y tamaño muestral grande. Amplitud. Ejemplo

Con una precisión de 1 cm. tendremos que la amplitud máxima será el doble: 2 cm.

Por tanto el tamaño necesario de la muestra será:

```
alpha=0.01
cuantil = qnorm(1-alpha/2)
amplitud = 2
s.piloto = 10
(n.minimo = ceiling((2*cuantil*s.piloto/amplitud)^2))
```

```
[1] 664
```

Intervalo de confianza para el parámetro μ de una población normal basado en la t de Student en R

Si queremos, podemos estudiar estos conceptos directamente utilizando la función `t.test` de R:

```
t.test(X, conf.level=...)$conf.int
```

donde `conf.level` es el nivel de confianza $1 - \alpha$ en tanto por uno. Su valor por defecto es $1 - \alpha = 0.95$.

Ejemplo tabla de datos iris

Ejemplo

Hallemos un intervalo de confianza para la media de la longitud del pétalo para una muestra de 30 flores de la tabla de datos **iris**.

- En primer lugar elegimos las flores de la muestra:

```
set.seed(1000)
muestra.iris = sample(1:150,30,replace=TRUE)
```

A continuación calculamos las longitudes del pétalo de las flores de nuestra muestra:

```
long.pétalo.muestra = iris[muestra.iris,]$Petal.Length
```

Ejemplo tabla de datos iris

Un intervalo de confianza al 95% de confianza para las longitudes del pétalo sería:

```
t.test(long.pétalo.muestra, conf.level=0.95)$conf.int
```

```
[1] 2.986537 4.106796  
attr(,"conf.level")  
[1] 0.95
```

Experimento sobre la “confianza”

Experimento

Vamos a comprobar con un experimento qué papel juega la “confianza” en los intervalos de confianza.

Vamos a generar al azar una Población de 10000000 (10^7) “individuos” con distribución normal estándar. Vamos a tomar 200 muestras aleatorias simples de tamaño 50 de esta población y calcularemos el intervalo de confianza para la media poblacional usando dicha fórmula.

Finalmente, contaremos cuántos de estos intervalos de confianza contienen la media de la población. Fijaremos la semilla de aleatoriedad para que el experimento sea reproducible y podáis comprobar que no hacemos trampa.

Experimento sobre la “confianza”

En primer lugar, generamos la población de valores:

```
set.seed(2020)  
valores.población=rnorm(10^7)
```

Seguidamente, hallamos la media poblacional:

```
(mu=mean(valores.población))
```

```
[1] -2.9034e-06
```

Experimento sobre la “confianza”

Para hallar 200 muestras, usaremos la función `replicate` de R que nos permite ejecutar una misma función las veces que le indiquemos:

```
muestras=replicate(200, sample(valores.población,50,replace=TRUE))
```

De esta forma `muestras` es una matriz de 50 filas y 200 columnas donde cada fila representa una muestra.

```
class(muestras)
```

```
[1] "matrix" "array"
```

```
dim(muestras)
```

```
[1] 50 200
```

Experimento sobre la “confianza”

A continuación, Vamos a aplicar a cada una de estas muestras la función `t.test` para calcular un intervalo de confianza del 95% y luego contaremos los aciertos, es decir, cuántos de ellos contienen la media poblacional.

Primero definimos la función `IC.t` que nos da el intervalo de confianza para la media dada una muestra `X`:

```
IC.t= function(X, confianza=0.95){t.test(X, conf.level=confianza)$conf.int}
```

Experimento sobre la “confianza”

En segundo lugar, calculamos los 200 intervalos de confianza para nuestras 200 muestras usando la función `apply` de R:

```
ICs= apply(muestras,FUN=IC.t,MARGIN=2)
```

En tercer lugar, miramos cuántos de los intervalos anteriores contienen la media poblacional μ :

```
Aciertos=length(which((mu>=ICs[1,]) & (mu<=ICs[2,])))
Aciertos
```

```
[1] 195
```


Hemos acertado 195 veces, o sea, el 97.5% de las veces. Es una buena aproximación del valor 95%, que era el esperado.

Experimento sobre la “confianza”

Para visualizar mejor los aciertos, vamos a dibujar los intervalos apilados en un gráfico, donde aparecerán en azul claro los que aciertan y en rojo los que no aciertan.

```
plot(1,type="n",xlim=c(-0.8,0.8),ylim=c(0,200),xlab="Valores",
     ylab="Repeticiones",main="")
seg.int=function(i){
  color="light blue";
  if((mu<ICs[1,i]) | (mu>ICs[2,i])){color = "red"}
  segments(ICs[1,i],i,ICs[2,i],i,col=color,lwd=2)
}
sapply(1:200,FUN=seg.int);
abline(v=mu,lwd=2)
```

Experimento sobre la “confianza”



Lección 3

Intervalos de confianza para el parámetro p de una población de Bernoulli

Método “exacto” o de Clopper-Pearson

Consideremos la situación siguiente:

- X una v.a. Bernoulli con p desconocido.
- $X_1, \dots, X_n$ una m.a.s. de X , con número de éxitos x y por lo tanto la frecuencia relativa de éxitos es $\hat{p}_X = x/n$.

En este caso, la distribución de la variable Y = “número de éxitos en la muestra” es binomial de parámetros n y p , Y es $B(n, p)$

Método “exacto” o de Clopper-Pearson

Definición. Un intervalo de confianza (p_0, p_1) del $(1 - \alpha)100\%$ nivel de confianza para p de una población X de Bernoulli se obtiene encontrando el p_0 más grande y el p_1 más pequeño tales que

$$\sum_{k=x}^n \binom{n}{k} \cdot p_0^k \cdot (1 - p_0)^{n-k} \leq \frac{\alpha}{2}, \quad \sum_{k=0}^x \binom{n}{k} \cdot p_1^k \cdot (1 - p_1)^{n-k} \leq \frac{\alpha}{2}$$

Método “exacto” o de Clopper-Pearson

Para hallar un intervalo de confianza para la proporción poblacional en R según el método de Clopper-Pearson, hay que usar la función `binom.exact` del paquete `epitools`:

```
binom.exact(x,n,conf.level)
```

donde `x` y `n` representan, respectivamente, el número de éxitos y el tamaño de la muestra, y `conf.level` es $1 - \alpha$, el nivel de confianza en tanto por uno.

Ejemplo tabla de datos iris

Ejemplo

Halleemos un intervalo de confianza para la proporción de flores con especie “setosa” dada una muestra de 60 flores.

Sabemos que la proporción real p en este caso vale $p = \frac{50}{150} = \frac{1}{3} = 0.333$.

Primero hallamos la muestra de las 60 flores:

```
set.seed(1000)
flores.elegidas = sample(1:150,60,replace=TRUE)
```

Ejemplo tabla de datos iris

Las flores elegidas son: (sólo mostramos las 10 primeras)

```
muestra.flores.prop = iris[flores.elegidas,]
head(muestra.flores.prop,10)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
68	5.8	2.7	4.1	1.0	versicolor
43	4.4	3.2	1.3	0.2	setosa
51	7.0	3.2	4.7	1.4	versicolor
88	6.3	2.3	4.4	1.3	versicolor
29	5.2	3.4	1.4	0.2	setosa
99	5.1	2.5	3.0	1.1	versicolor
61	5.0	2.0	3.5	1.0	versicolor
146	6.7	3.0	5.2	2.3	virginica
150	5.9	3.0	5.1	1.8	virginica

Ejemplo tabla de datos iris

El número de flores de especie setosa será:

```
(numero.flores.setosa=table(muestra.flores.prop$Species=="setosa")[2])
```

TRUE

21

El intervalo de confianza para la proporción poblacional de flores de especie setosa al 95% de confianza será:

```
library(epitools)
binom.exact(numero.flores.setosa,60,conf.level=0.95)
```

	x	n	proportion	lower	upper	conf.level
TRUE	21	60	0.35	0.2313264	0.484028	0.95

Ejemplo tabla de datos iris

Según el método de Clopper-Pearson, con un 95% de confianza podemos decir que en la tabla de datos **iris** hay entre un 23.13% y 48.4% de flores de especie “setosa”.

Caso del tamaño n de la muestra grande

Consideremos la situación siguiente :

- X una v.a. Bernoulli con p desconocida.
- $X_1, \dots, X_n$ una m.a.s. de X , con n grande (por Ejemplo, $n \geq 40$) y frecuencia relativa de éxitos $\hat{p}_X$.

En estas condiciones (por el Teorema Central del Límite),

$$Z = \frac{\hat{p}_X - p}{\sqrt{\frac{p(1-p)}{n}}} \approx N(0, 1)$$

Caso del tamaño n de la muestra grande

Por lo tanto

$$P \left(-z_{1-\frac{\alpha}{2}} \leq \frac{\hat{p}_X - p}{\sqrt{\frac{p(1-p)}{n}}} \leq z_{1-\frac{\alpha}{2}} \right) = 1 - \alpha.$$

El problema es que no conocemos p ...

La literatura plantea entre otras soluciones:

- El método de Wilson
- La solución de Laplace (1812)

Método de Wilson

Definición. En estas condiciones, un intervalo de confianza del $(1 - \alpha) \cdot 100\%$ I.C. para p (donde $\hat{q}_X = 1 - \hat{p}_X$) es:

$$\left(\frac{\hat{p}_X + \frac{z_{1-\alpha/2}^2}{2n} - z_{1-\alpha/2} \sqrt{\frac{\hat{p}_X \hat{q}_X}{n} + \frac{z_{1-\alpha/2}^2}{4n^2}}}{1 + \frac{z_{1-\alpha/2}^2}{n}}, \frac{\hat{p}_X + \frac{z_{1-\alpha/2}^2}{2n} + z_{1-\alpha/2} \sqrt{\frac{\hat{p}_X \hat{q}_X}{n} + \frac{z_{1-\alpha/2}^2}{4n^2}}}{1 + \frac{z_{1-\alpha/2}^2}{n}} \right).$$

Para hallar un intervalo de confianza para la proporción poblacional en R según el método de Wilson, hay que usar la función `binom.wilson` del mismo paquete `epitools`:

```
binom.wilson(x,n,conf.level)
```

Ejemplo tabla de datos iris

Ejemplo

Usando el ejemplo anterior, hallemos un intervalo de confianza para la proporción de flores de especie “setosa” según el método de Wilson al 95% de confianza.

El intervalo será:

```
binom.wilson(número.flores.setosa,60,conf.level=0.95)
```

	x	n	proportion	lower	upper	conf.level
TRUE	21	60	0.35	0.2416777	0.4763738	0.95

Según el método de Wilson, con un 95% de confianza podemos decir que en la tabla de datos **iris** hay entre un 24.17% y 47.64% de flores de especie “setosa”.

Fórmula de Laplace.

Supongamos que la muestra aleatoria simple es considerablemente más grande que la usada en el método de **Wilson** y que, además, la proporción muestral de éxitos $\hat{p}_X$ está alejada de 0 y de 1.

- Es decir si, $n \geq 100$ y que $n \cdot \hat{p}_X \geq 10$ (10 o más éxitos) y $n \cdot (1 - \hat{p}_X) \geq 10$ (10 o más fracasos).
- En este caso, podemos usar la fórmula de **Laplace**:

$$\hat{p}_X \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}_X(1 - \hat{p}_X)}{n}}.$$

Fórmula de Laplace.

Para hallar un intervalo de confianza para la proporción poblacional en R según la fórmula de Laplace, hay que usar la función `binom.approx` del mismo paquete `epitools`:

```
binom.approx(x,n,conf.level)
```

Fórmula de Laplace. Ejemplo

Ejemplo

En una muestra aleatoria de 500 familias con niños en edad escolar se encontró que 340 introducían fruta de forma diaria en la dieta de sus hijos

Calculad un intervalo de confianza del 95% para conocida la proporción real de familias de esta ciudad con niños en edad escolar que incorporen fruta fresca de forma diaria en la dieta de sus hijos.

El tamaño de la muestra es $n = 500$ y la estimación de la proporción muestral,

$$\hat{p}_X = \frac{340}{500} = 0.68.$$

Como que $n = 500 \geq 100$, $n\hat{p}_X = 340 \geq 10$ y $n \cdot (1 - \hat{p}_X) = 160 \geq 10$, podemos utilizar la fórmula de Laplace.

Fórmula de Laplace. Ejemplo

Usando que $z_{1-\frac{\alpha}{2}} = z_{0.975} = 1.96$, el intervalo de confianza será:

$$\left(0.68 - 1.96 \cdot \sqrt{\frac{0.68 \cdot 0.32}{500}}, 0.68 + 1.96 \cdot \sqrt{\frac{0.68 \cdot 0.32}{500}} \right) = (0.639, 0.721).$$

Ejemplo tabla de datos iris

Ejemplo

Usando el ejemplo anterior, hallemos un intervalo de confianza para la proporción de flores de especie “setosa” según la fórmula de Laplace al 95% de confianza.

El intervalo será:

```
binom.approx(número.flores.setosa,60,conf.level=0.95)
```

	x	n	proportion	lower	upper	conf.level
TRUE	21	60	0.35	0.2293123	0.4706877	0.95

Según la fórmula de Laplace, con un 95% de confianza podemos decir que en la tabla de datos **iris** hay entre un 22.93% y 47.07% de flores de especie “setosa”.

Fórmula de Laplace. Amplitud

Problema: hallar el tamaño de la muestra fijada la amplitud del intervalo de confianza.

La **amplitud** del intervalo de confianza usando la fórmula de Laplace es

$$A = 2z_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_X(1 - \hat{p}_X)}{n}}.$$

No podemos determinar el tamaño de la muestra para que el intervalo de confianza tenga como máximo una cierta amplitud sin conocer $\hat{p}_X$.

Fórmula de Laplace. Amplitud

Vamos a considerar que estamos en el peor de los casos.


O sea, usando que $\hat{p}_X \in [0, 1]$, nos planteamos hallar el máximo de la expresión $\hat{p}_X(1 - \hat{p}_X)$ que aparece en la fórmula de la amplitud.

El máximo de la función anterior, para $\hat{p}_X \in [0, 1]$ se alcanza en $\hat{p}_X = \frac{1}{2}$ y dicho máximo vale $\frac{1}{4}$.

Ejercicio

Demostrar que el máximo de la función $f(p) = p(1 - p)$ se alcanza en $p = 1/2$ y vale $1/4$.

Fórmula de Laplace. Amplitud



Fórmula de Laplace. Amplitud

En resumen, calcularemos n para obtener una amplitud máxima A_0 suponiendo el peor de los casos ($\hat{p}_X = 0.5$):

$$A_0 \geq 2z_{1-\frac{\alpha}{2}} \sqrt{\frac{0.5^2}{n}} = \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \Rightarrow n \geq \left\lceil \frac{z_{1-\frac{\alpha}{2}}^2}{A_0^2} \right\rceil.$$

Fórmula de Laplace. Amplitud. Ejemplo

Ejemplo

Queremos estudiar qué fracción teléfonos móviles utilizan android para determinar esta proporción con un nivel de confianza del 95% y garantizar un error máximo de 0.05.

¿De qué tamaño ha de ser la muestra **en el peor de los casos**?

Usando la fórmula anterior, el valor de n tiene que verificar:

$$n \geq \left\lceil \frac{z_{1-\frac{\alpha}{2}}^2}{A^2} \right\rceil$$

donde $\frac{A}{2} = 0.05$, ($A = 0.1$) y $z_{1-\frac{\alpha}{2}} = z_{0.975} = 1.96$.

El tamaño de la muestra valdrá, como mínimo:

$$n \geq \left\lceil \frac{1.96^2}{0.1^2} \right\rceil = \lceil 384.146 \rceil = 385.$$

Lección 4

Intervalo de confianza para la varianza de una población normal

Intervalo de confianza para la varianza de una población normal

Consideremos la siguiente situación:

- Consideramos una X una v.a. normal con μ y σ desconocidas.
- Sea $X_1, \dots, X_n$ una m.a.s. de X y varianza muestral $\tilde{S}_X^2$.

En estas condiciones tenemos el siguiente:

Teorema.

La variable aleatoria $\frac{(n-1)\tilde{S}_X^2}{\sigma^2}$ se distribuye según una distribución χ_{n-1}^2 .

Intervalo de confianza para la varianza de una población normal

Teorema.

En las condiciones anteriores, un intervalo de confianza del $(1 - \alpha) \cdot 100\%$ para la varianza σ^2 de la población X es

$$\left(\frac{(n-1)\tilde{S}_X^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2}, \frac{(n-1)\tilde{S}_X^2}{\chi_{n-1, \frac{\alpha}{2}}^2} \right),$$

donde $\chi_{\nu, q}^2$ es el q -cuantil de la distribución χ_{ν}^2 .

Intervalo de confianza para la varianza de una población normal. Ejemplo

Ejemplo

Un algoritmo probabilístico depende de la semilla de aleatorización que se genera en cada paso. Para saber si la semilla influye mucho en el resultado se ejecuta el algoritmo varias veces hasta obtener un resultado similar y se estudia la varianza de su tiempo de ejecución.

Queremos ver si la desviación típica σ es ≤ 30 .

Se supone que la distribución del tiempo de ejecución del algoritmo es aproximadamente normal.

Se realizan 30 ejecuciones del algoritmo de las que se mide el tiempo de ejecución. Los resultados son:

```
tiempo=c(12, 13, 13, 14, 14, 14, 15, 15, 16, 17,  
         17, 18, 18, 19, 19, 25, 25, 26, 27, 30,  
         33, 34, 35, 40, 40, 51, 51, 58, 59, 83)
```

Intervalo de confianza para la varianza de una población normal. Ejemplo

En primer lugar calculamos la varianza muestral de nuestra muestra:

```
n=30  
(var.muestral.tiempo = var(tiempo))
```

```
[1] 301.5506
```

Intervalo de confianza para la varianza de una población normal. Ejemplo

En segundo lugar, calculamos los cuantiles que necesitamos:

```
alpha=0.05  
(cuantil.izquierda = qchisq(1-alpha/2,n-1))
```

```
[1] 45.72229
```

```
(cuantil.derecha = qchisq(alpha/2,n-1))
```

```
[1] 16.04707
```

Intervalo de confianza para la varianza de una población normal. Ejemplo

El intervalo de confianza para la varianza del tiempo de ejecución será:

```
(valor.izquierdo= (n-1)*var.muestral.tiempo/cuantil.izquierda)
```

```
[1] 191.2627
```

```
(valor.derecho= (n-1)*var.muestral.tiempo/cuantil.derecha)
```

```
[1] 544.9572
```

Intervalo de confianza para la varianza de una población normal. Ejemplo

El intervalo de confianza para la desviación típica σ del tiempo de ejecución será:

```
c(sqrt(valor.izquierdo),sqrt(valor.derecho))
```

```
[1] 13.82977 23.34432
```

Vemos que el valor 30 está a la derecha del intervalo de confianza.

Por tanto, podemos afirmar con un 95% de confianza que $\sigma \leq 30$.

Intervalo de confianza para la varianza de una población normal en R

Para hallar un intervalo de confianza para la varianza poblacional en R hay que usar la función `varTest` del paquete `EnvStats`:

```
varTest(X, conf.level)$conf.int
```

donde `X` es el vector que contiene la muestra y `conf.level` el nivel de confianza, que por defecto es igual a 0.95.

Intervalo de confianza para la varianza de una población normal en R

Ejemplo

Hallemos un intervalo de confianza para la varianza de la amplitud del sépalo de la tabla de datos **iris** a partir de la muestra anterior. Suponemos que dicha variable es normal. Veremos en temas posteriores cómo se puede comprobar la normalidad de una variable.

Hallemos los valores de la amplitud del sépalo para las flores de nuestra muestra:

```
(amplitud.sépalo.muestra = iris[flores.elegidas,]$Sepal.Width)
```

```
[1] 2.7 3.2 3.2 2.3 3.4 2.5 2.0 3.0 3.0 2.7 3.8 3.4 2.7 3.5 3.5 3.0 2.3 3.2 2.8
[20] 2.8 2.5 2.3 3.1 3.0 2.3 2.9 3.4 3.1 3.4 2.5 2.6 3.7 2.5 4.4 3.0 3.4 2.5 2.8
[39] 3.2 3.0 3.3 3.2 3.8 3.6 3.0 3.4 2.8 2.6 2.9 3.1 3.1 3.3 3.2 3.2 3.5 3.5 3.0
[58] 3.4 3.1 2.3
```

Intervalo de confianza para la varianza de una población normal en R

Un intervalo de confianza para la varianza de las amplitudes del sépalos para la tabla de datos **iris** al 95% de confianza será:

```
library(EnvStats)  
varTest(amplitud.sépalo.muestra,conf.level=0.95)$conf.int
```

```
      LCL      UCL  
0.1625640 0.3365786  
attr(,"conf.level")  
[1] 0.95
```

Lección 5

Bootstrap o remuestreo

Técnicas de remuestreo

Cuando no se satisfacen las condiciones teóricas que garantizan que el intervalo obtenido contiene el 95% de las veces el parámetro poblacional deseado, podemos recurrir a un método no paramétrico. El más utilizado es el **bootstrap**, que básicamente consiste en:

- 1 **Remuestrear** la muestra: tomar muchas muestras aleatorias simples de la muestra de la que disponemos, cada una de ellas del mismo tamaño que la muestra original (pero simples, es decir, con reposición).
- 2 Calcular el estimador sobre cada una de estas submuestras.
- 3 Organizar los resultados en un vector.
- 4 Usar este vector para calcular un intervalo de confianza.

Bootstrap: método de los percentiles

La manera más sencilla de llevar a cabo el cálculo final del intervalo de confianza es el llamado **método de los percentiles**, en el que se toman como extremos del intervalo de confianza del $(1 - \alpha) \cdot 100$ los cuantiles de orden $\frac{\alpha}{2}$ y $1 - \frac{\alpha}{2}$ del vector de estimadores.

Bootstrap: método de los percentiles. Ejemplo

Ejemplo

Como aplicación del **método de los percentiles** hallemos un intervalo de confianza para la varianza de la longitud del pétalo de la tabla de datos **iris**. No podemos usar la fórmula vista anteriormente ya que la variable considerada no puede considerarse normal.

Tomaremos la muestra de la tabla de datos **iris** que hemos calculado anteriormente en la sección de intervalo de confianza para proporciones. Usaremos la función `replicate` de R para calcular las varianzas de 1000 muestras “remuestradas” de nuestra muestra original:

```
set.seed(42)
X=replicate(1000,
            var(sample(iris[flores.elegidas,]$Petal.Length,
                      replace=TRUE)
            )
)
```

Bootstrap: método de los percentiles. Ejemplo

A continuación hallamos el intervalo de confianza al 95% ($1 - \alpha = 0.95$) calculando los cuantiles del método: (cuantiles de orden $\frac{\alpha}{2} = 0.025$ y $1 - \frac{\alpha}{2} = 0.975$)

```
alpha = 0.05  
IC.boot=c(quantile(X,alpha/2),quantile(X,1-alpha/2))  
round(IC.boot,2)
```

2.5% 97.5%

2.41 3.53

Bootstrap: método de los percentiles en R

Para aplicar el **método de los percentiles** en R, podemos usar la función `boot` del paquete `boot`:

```
boot(X,estadístico,R)
```

donde:

- X es el vector que forma la muestra de la que disponemos
- R es el número de muestras que queremos extraer de la muestra original
- El `estadístico` es la función que calcula el estadístico deseado de la submuestra, y tiene que tener dos parámetros: el primero representa la muestra original X y el segundo representa el vector de índices de una m.a.s. de X.

Bootstrap: método de los percentiles en R. Ejemplo

Ejemplo anterior

Vamos a aplicar la función `boot` al ejemplo anterior definiendo primero el estadístico a usar que sería la varianza en nuestro caso.

```
library(boot)
var.boot=function(X,índices){var(X[índices])}
simulación=boot(iris[flores.elegidas,]$Petal.Length,var.boot,1000)
```

El intervalo de confianza viene dado por la función `boot.ci`...

```
boot.ci(simulación)
```

Ejemplo

```
boot.ci(simulación)
```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 1000 bootstrap replicates

CALL :

```
boot.ci(boot.out = simulación)
```

Intervals :

Level	Normal	Basic
95%	(2.531, 3.567)	(2.529, 3.603)

Level	Percentile	BCa
95%	(2.409, 3.483)	(2.488, 3.535)

Bootstrap: método de los percentiles en R. Ejemplo

Obtenemos cuatro intervalos de confianza para σ^2 , calculados con cuatro métodos a partir de la simulación realizada.

El intervalo Percentile es el calculado con el método de los percentiles que hemos explicado antes, y se obtiene con el sufijo `$percent[4:5]`.

Vemos que los valores son parecidos a los obtenidos en la simulación *hecha a mano*.

Ejercicio

Mirando la documentación e investigando un poco, elaborad un pequeño resumen de cómo se obtienen y qué significan cada uno de los otros tres intervalos de confianza de la función `boot.ci`.

Guía rápida

- `t.test(X, conf.level=...)$conf.int` calcula el intervalo de confianza del $\text{conf.level} \times 100\%$ para la media poblacional usando la fórmula basada en la *t* de Student aplicada a la muestra *X*.
- `binom.exact(x,n,conf.level=...)` del paquete **epitools**, calcula el intervalo de confianza del $\text{conf.level} \times 100\%$ para la proporción poblacional aplicando el método de Clopper-Pearson a una muestra de tamaño *n* con *x* éxitos.
- `binom.wilson(x,n,conf.level=...)` del paquete **epitools**, calcula el intervalo de confianza del $\text{conf.level} \times 100\%$ para la proporción poblacional aplicando el método de Wilson a una muestra de tamaño *n* con *x* éxitos.
- `binom.approx(x,n,conf.level=...)` del paquete **epitools**, calcula el intervalo de confianza del $\text{conf.level} \times 100\%$ para la proporción poblacional aplicando la fórmula de Laplace a una muestra de tamaño *n* con *x* éxitos.

Guía rápida

- `varTest(X, conf.level=...)$conf.int` del paquete `EnvStats`, calcula el intervalo de confianza del $\text{conf.level} \times 100\%$ para la varianza poblacional usando la fórmula basada en la khi cuadrado aplicada a la muestra X .
- `boot(X, E, R)` del paquete `boot`, lleva a cabo una simulación *bootstrap*, tomando R submuestras del vector X y calculando sobre ellas el estadístico representado por la función E .
- `boot.ci` del paquete `boot`, aplicado al resultado de una función `boot`, calcula diversos intervalos de confianza a partir del resultado de la simulación efectuada con `boot`. El nivel de confianza se especifica con el parámetro `conf`.