

Tema 6 - Contrastes de independencia y homogeneidad

Parte 2: Inferencia estadística con R y python

2023-12-03

Lección 1

Contrastes de independencia

Introducción

Una de las aplicaciones más usadas del test de bondad de ajuste es contrastar si dos maneras de clasificar n objetos son **independientes** o no.

Veamos un ejemplo ilustrativo:

Ejemplo

En un estudio de una vacuna de hepatitis participan 1083 voluntarios. De éstos, se eligen aleatoriamente 549 y son vacunados. Los otros, 534, no son vacunados. Después de un cierto tiempo, se observa que 70 de los 534 no vacunados han contraído la hepatitis, mientras que sólo 11 de los 549 vacunados la han contraído.

Esquematicemos los resultados en lo que se llama una tabla de contingencia:

Introducción

¿Enfermó?/¿Vacunado?	Sí	No	Total
Sí	11	70	81
No	538	464	1002
Total	549	534	1083

¿Es el hecho de contraer hepatitis independiente de haber sido vacunado contra la dolencia?

En este ejemplo, contrastar si la manera de clasificar a los voluntarios entre vacunados y no vacunados y la manera de clasificarlos entre enfermos por hepatitis y no enfermos es equivalente a contrastar si la vacuna es efectiva contra la hepatitis.

Decir que la vacuna no es efectiva sería equivalente a decir que vacunar a un individuo es independiente de que contraiga la hepatitis.

Tablas de contingencia

La situación en general sería la siguiente:

Tenemos n individuos y los clasificamos según dos criterios: X e Y . Sean $x_1, \dots, x_I$ los distintos **niveles** del criterio X e $y_1, \dots, y_J$, los distintos **niveles** del criterio Y .

En el ejemplo anterior $I = J = 2$, X sería el criterio de clasificación por vacunación con x_1 :“vacunados” y x_2 :“no vacunados” e Y sería el criterio de clasificación por contracción de la hepatitis con y_1 :“enfermo de hepatitis” e y_2 :“no enfermo de hepatitis”.

Definimos n_{ij} como el número de individuos clasificados en el nivel x_i según el criterio X y clasificados en el nivel y_j según el criterio Y . A partir de dichos valores construimos la denominada **tabla de contingencia**:

Tablas de contingencia

X/Y	y_1	...	y_j	...	y_J	$n_{i\bullet}$
x_1	n_{11}	...	n_{1j}	...	n_{1J}	$n_{1\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	n_{i1}	...	n_{ij}	...	n_{iJ}	$n_{i\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_I	n_{I1}	...	n_{Ij}	...	n_{IJ}	$n_{I\bullet}$
$n_{\bullet j}$	$n_{\bullet 1}$	...	$n_{\bullet j}$	...	$n_{\bullet J}$	n

Tablas de contingencia

En la tabla anterior, $n_{i\bullet}$ sería el número total de individuos clasificados en el nivel x_i según el criterio X y $n_{\bullet j}$, el número total de individuos clasificados en el nivel y_j según el criterio Y .

El contraste que nos planteamos es el siguiente:

$$\left. \begin{array}{l} H_0 : \text{ Los criterios de clasificación } X \text{ e } Y \text{ son independientes,} \\ H_1 : \text{ Los criterios de clasificación } X \text{ y } Y \text{ no son independientes.} \end{array} \right\}$$

Para poder realizar el contraste anterior, lo plantearemos como un contraste de **bondad de ajuste**.

Contraste de independencia como un contraste de bondad de ajuste

Para poder modelar el contraste de independencia como un contraste de **bondad de ajuste**, en primer lugar necesitamos definir una variable “modelo”.

A partir de nuestros datos empíricos, contrastaremos si dichos datos siguen la variable “modelo” usando el test de la χ^2 de bondad de ajuste.

Nuestra variable “modelo” será una variable aleatoria discreta **bidimensional** (X, Y) con dominio $\{(x_1, y_1), \dots, (x_I, y_J)\}$, o, si se quiere $\{(x_i, y_j) \mid i = 1, \dots, I, j = 1, \dots, J\}$. Sería una variable con $I \cdot J$ valores.

Contraste de independencia como un contraste de bondad de ajuste

Para calcular la función de probabilidad de la variable (X, Y) , hay que suponer que la hipótesis nula H_0 es cierta o que los criterios X e Y son **independientes**. Por tanto:

$$P((X, Y) = (x_i, y_j)) = P(X = x_i) \cdot P(Y = y_j) = \frac{n_{i\bullet}}{n} \cdot \frac{n_{\bullet j}}{n} = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n^2},$$

$$i = 1, \dots, I, j = 1, \dots, J.$$

Los valores n_{ij} serían los **valores empíricos** con los que hay que contrastar si siguen la distribución de la variable (X, Y) .

Test χ^2 de independencia

Una vez planteado el contraste de independencia como un contraste de **bondad de ajuste**, recordemos que el **test** χ^2 asociado al contraste es:

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - n \cdot P((X, Y) = (x_i, y_j)))^2}{n \cdot P((X, Y) = (x_i, y_j))} = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - \frac{n_{i\cdot} \cdot n_{\cdot j}}{n})^2}{\frac{n_{i\cdot} \cdot n_{\cdot j}}{n}},$$

donde las frecuencias n_{ij} serían las **frecuencias observadas** y las frecuencias $\frac{n_{i\cdot} \cdot n_{\cdot j}}{n}$ serían las **frecuencias esperadas**.

Recordemos que si n es grande y cada frecuencia esperada $\frac{n_{i\cdot} \cdot n_{\cdot j}}{n}$ es ≥ 5 , este estadístico sigue aproximadamente una ley χ^2 con $(I - 1) \cdot (J - 1)$ **grados de libertad**.

Test χ^2 de independencia

Observación.

¿Por qué los **grados de libertad** del **estadístico de contraste** son $(I - 1) \cdot (J - 1)$?

La razón es la siguiente: recordemos que al realizar un **test de bondad de ajuste**, los **grados de libertad** del estadístico χ^2 era:

$g.l. = \text{número de clases} - \text{número de parámetros estimados} - 1.$

Fijémonos que en el contraste de independencia hemos estimado $I + J - 2$ **parámetros** que corresponden a las **medias de las variables** X e Y : $\frac{n_{i\bullet}}{n}$ y $\frac{n_{\bullet j}}{n}$, $i = 1, \dots, I$, $j = 1, \dots, J$.

En nuestro caso, nos queda:

$$g.l. = I \cdot J - (I + J - 2) - 1 = (I - 1) \cdot (J - 1).$$

Test χ^2 de independencia

Como siempre, sea χ_0 el valor que toma el **estadístico de contraste**. El **p-valor** del contraste es:

$$p = P(\chi^2_{(I-1) \cdot (J-1)} \geq \chi_0),$$

con el significado usual:

- si $p < 0.05$, concluimos que tenemos evidencias suficientes para rechazar la independencia de los criterios,
- si $p > 0.1$, concluimos que no tenemos evidencias suficientes para rechazar la independencia de los criterios y,
- si $0.05 \leq p \leq 0.1$, estamos en la zona de penumbra. Necesitamos más datos para tomar una decisión clara.

Ejemplo

Ejemplo del estudio de la vacuna de hepatitis

Recordemos que la tabla de contingencia de dicho estudio era:

¿Enfermó?/¿Vacunado?	Sí	No	Total
Sí	11	70	81
No	538	464	1002
Total	549	534	1083

Ejemplo

A continuación, calculemos la tabla de las frecuencias esperadas $\frac{n_{i\bullet} \cdot n_{\bullet j}}{n}$ a partir de las sumas de las filas y las columnas anteriores:

¿Enfermó?/¿Vacunado?	Sí	No	Total
Sí	$\frac{81 \cdot 549}{1083} = 41.061$	$\frac{81 \cdot 534}{1083} = 39.939$	81
No	$\frac{1002 \cdot 549}{1083} = 507.939$	$\frac{1002 \cdot 534}{1083} = 494.061$	1002
Total	549	534	1083

Ejemplo

El valor del estadístico de contraste será:

$$\chi_0 = \frac{(11 - 41.061)^2}{41.061} + \frac{(70 - 39.939)^2}{39.939} + \frac{(538 - 507.939)^2}{507.939} + \frac{(464 - 494.061)^2}{494.061} = 48.242.$$

El p-valor del contraste será:

$$p = P(\chi_1^2 > 48.242) = 0.$$

Como el p-valor es muy pequeño, de hecho despreciable, concluimos que tenemos suficientes evidencias para rechazar que la vacuna y la hepatitis son independientes. O sea, vacunarse afecta al hecho de contraer la enfermedad.

Ejemplo

Ejemplo

Un comercial quiere saber si el número de lotes de un producto que compra cada clientes es independiente de la zona donde viva. Para ello, considera las 3 zonas que tiene asignadas (X): $X_1 = \text{"Norte"}$, $X_2 = \text{"Centro"}$ y $X_3 = \text{"Sur"}$.

Además clasifica la compra de lotes (Y) en $Y_1 = \text{"Dos o menos"}$, $Y_2 = \text{"Entre tres y cinco"}$, $Y_3 = \text{"Entre seis y ocho"}$ y $Y_4 = \text{"Nueve o más"}$.

Queremos hacer el contraste:

$$\left. \begin{array}{l} H_0 : \text{El número de lotes por cliente es independiente de la zona,} \\ H_1 : \text{El número de lotes por cliente no es independiente de la zona.} \end{array} \right\}$$

Ejemplo

Toma una muestra de 200 clientes y obtiene la tabla siguiente:

X/Y	Y_1	Y_2	Y_3	Y_4	$n_{i\bullet}$
X_1	5	8	15	22	50
X_2	20	26	46	8	100
X_3	15	10	15	10	50
$n_{\bullet j}$	40	44	76	40	200

Ejemplo

Las frecuencias esperadas si las variables son independientes son:

X/Y	Y_1	Y_2	Y_3	Y_4	$n_{i\bullet}$
X_1	10	11	19	10	50
X_2	20	22	38	20	100
X_3	10	11	19	10	50
$n_{\bullet j}$	40	44	76	40	200

Ejemplo

El valor del estadístico de contraste es:

$$\chi_0 = \frac{(5-10)^2}{10} + \frac{(8-11)^2}{11} + \frac{(15-19)^2}{19} + \frac{(22-10)^2}{10} + \frac{(20-20)^2}{20} + \frac{(26-22)^2}{22} + \frac{(46-38)^2}{38} + \frac{(8-20)^2}{20} + \frac{(15-10)^2}{10} + \frac{(10-11)^2}{11} + \frac{(15-19)^2}{19} + \frac{(10-10)^2}{10} = 31.605.$$

El p-valor del contraste vale:

$$p = P(\chi_6^2 > 31.605) = 0.$$

Como el p-valor es muy pequeño, de hecho despreciable, concluimos que tenemos suficientes evidencias para rechazar que el número de lotes comprados y la zona donde residen los clientes son independientes.

Contraste de independencia en R

Para realizar un contraste de independencia en R hay que usar la función `chisq.test(tabla.contingencia,correct)` con los parámetros siguientes:

- `tabla.contingencia`: es la tabla de las frecuencias empíricas.
- `correct`: es un parámetro lógico. Si su valor es `FALSE`, hará los cálculos como hemos explicado. Si su valor es `TRUE`, aplica la corrección a la continuidad sólo para tablas de contingencia 2×2 . (Ver https://es.wikipedia.org/wiki/Correcci%C3%B3n_de_Yates)

Contraste de independencia en R

Ejemplo del estudio de la vacuna de hepatitis

Para realizar el contraste de independencia en R hacemos lo siguiente:

```
chisq.test(matrix(c(11,538,70,464),2,2),correct=FALSE)
```

Pearson's Chi-squared test

```
data:  matrix(c(11, 538, 70, 464), 2, 2)
X-squared = 48.242, df = 1, p-value = 3.768e-12
```

Observamos que obtenemos los mismos valores que en los cálculos hechos a mano.

Ejemplo

Ejemplo del estudio del número de lotes comprados por cliente y la zona donde vive

En este ejemplo, para realizar el contraste en R, basta hacer:

```
chisq.test(matrix(c(5,20,15,8,26,10,15,46,15,22,8,10),3,4))
```

Pearson's Chi-squared test

```
data:  matrix(c(5, 20, 15, 8, 26, 10, 15, 46, 15, 22, 8, 10), 3, 4)
X-squared = 31.605, df = 6, p-value = 1.942e-05
```

En este caso, también se obtienen los mismos valores que en los cálculos realizados anteriormente.

Contraste de independencia en R

Ejemplo

La tabla de datos WorldPhones de R nos da tabla de contingencia el número de teléfonos (en miles de unidades) que había en distintas regiones del mundo entre los años 1951 al 1961:

WorldPhones

	N.Amer	Europe	Asia	S.Amer	Oceania	Africa	Mid.Amer
1951	45939	21574	2876	1815	1646	89	555
1956	60423	29990	4708	2568	2366	1411	733
1957	64721	32510	5230	2695	2526	1546	773
1958	68484	35218	6662	2845	2691	1663	836
1959	71799	37598	6856	3000	2868	1769	911
1960	76036	40341	8220	3145	3054	1905	1008
1961	79831	43173	9053	3338	3224	2005	1076

Contraste de independencia en R

Para contrastar si año y región son independientes, necesitamos las distribuciones marginales de las variables de “Año” y “Región” se calculan con la función `addmargins`:

```
(Tabla.con.marginales = addmargins(WorldPhones))
```

	N.Amer	Europe	Asia	S.Amer	Oceania	Africa	Mid.Amer	Sum
1951	45939	21574	2876	1815	1646	89	555	74494
1956	60423	29990	4708	2568	2366	1411	733	102199
1957	64721	32510	5230	2695	2526	1546	773	110001
1958	68484	35218	6662	2845	2691	1663	836	118399
1959	71799	37598	6856	3000	2868	1769	911	124801
1960	76036	40341	8220	3145	3054	1905	1008	133709
1961	79831	43173	9053	3338	3224	2005	1076	141700
Sum	467233	240404	43605	19406	18375	10388	5892	805303

Contraste de independencia en R

La tabla de frecuencias esperadas es:

```
(tabla.frec.esperadas =  
  rowSums(WorldPhones)%*%t(colSums(WorldPhones)))/sum(WorldPhones)
```

	N.Amer	Europe	Asia	S.Amer	Oceania	Africa	Mid.Amer
[1,]	43221.07	22238.41	4033.651	1795.139	1699.767	960.9348	545.0354
[2,]	59295.38	30509.07	5533.802	2462.767	2331.926	1318.3152	747.7391
[3,]	63822.06	32838.17	5956.259	2650.778	2509.948	1418.9571	804.8224
[4,]	68694.54	35345.20	6410.989	2853.151	2701.569	1527.2870	866.2664
[5,]	72408.95	37256.36	6757.640	3007.425	2847.647	1609.8696	913.1066
[6,]	77577.33	39915.63	7239.984	3222.088	3050.905	1724.7782	978.2820
[7,]	82213.67	42301.15	7672.675	3414.653	3233.240	1827.8581	1036.7482

Contraste de independencia en R

Para realizar el contraste, usamos tal como hemos indicado la función `chisq.test`:

```
chisq.test(WorldPhones)
```

Pearson's Chi-squared test

```
data: WorldPhones
```

```
X-squared = 2194.4, df = 36, p-value < 2.2e-16
```

Vemos que el p-valor es depreciable. Concluimos que tenemos evidencias suficientes para rechazar que el año y la zona son independientes respecto del hecho de tener teléfono o no.

Caso en que las frecuencias esperadas son inferiores a 5

Si algunas frecuencias absolutas esperadas son inferiores a 5, la aproximación del p-valor por una distribución χ^2 podría no ser adecuada.

Si se da esta situación, lo mejor es recurrir a simular el p-valor usando el parámetro `simulate.p.value=TRUE`.

Veamos un ejemplo en el que se da esta situación:

Ejemplo

Consideremos la tabla de datos `iris`. Nos planteamos si la especie de la flor es independiente de la longitud del pétalo.

En primer lugar, hallamos la tabla de contingencia de las dos variables (especie y longitud del pétalo), agrupando en cuatro clases la variable continua “Longitud del pétalo”:

```
(tabla.contingencia =table(cut(iris$Petal.Length,4),iris$Species))
```

	setosa	versicolor	virginica
(0.994,2.48]	50	0	0
(2.48,3.95]	0	11	0
(3.95,5.43]	0	39	22
(5.43,6.91]	0	0	28

Ejemplo

Calculemos a continuación la tabla de frecuencias esperadas:

```
(tabla.frec.esperadas = rowSums(tabla.contingencia)%*%t(colSums(tabla.conti
/sum(tabla.contingencia))
```

```
      setosa versicolor virginica
[1,] 16.666667  16.666667 16.666667
[2,]  3.666667   3.666667  3.666667
[3,] 20.333333  20.333333 20.333333
[4,]  9.333333   9.333333  9.333333
```

¡Alerta! Observamos que hay frecuencias esperadas menores que 5.

Ejemplo

Veamos que pasa si usamos la función `chisq.test`:

```
chisq.test(tabla.contingencia)
```

Pearson's Chi-squared test

```
data:  tabla.contingencia
```

```
X-squared = 215.61, df = 6, p-value < 2.2e-16
```

R nos avisa que la aproximación puede ser incorrecta debido al hecho de que tenemos frecuencias esperadas menores que 5.

Ejemplo

Para resolver este inconveniente, simularemos el valor del p-valor reiniciando la semilla a NULL:

```
set.seed(NULL)
chisq.test(tabla.contingencia,simulate.p.value = TRUE, B=5000)
```

Pearson's Chi-squared test with simulated p-value (based on 5000 replicates)

```
data:  tabla.contingencia
X-squared = 215.61, df = NA, p-value = 2e-04
```

Ejemplo

El parámetro B indica el número de replicaciones que hemos de realizar en nuestra simulación.

Observamos que el p-valor es pequeño. Por tanto, concluimos que tenemos evidencias suficientes para rechazar que la longitud del pétalo y la especie sean independientes.

Diseño experimental en el contraste de independencia

En un **contraste de independencia** se toma una **muestra transversal** de la población, es decir, se selecciona al azar una cierta cantidad de individuos de la población, se observan las dos variables sobre cada uno de ellos, y se contrasta si las probabilidades conjuntas son iguales al producto de las probabilidades marginales de cada variable.

En el ejemplo de la vacuna y la hepatitis, seleccionamos una muestra de 1083 individuos de toda la población, y los clasificamos en 4 subgrupos: los que han sido vacunados y han contraído la enfermedad (ha habido 11), los que no han sido vacunados y han contraído la enfermedad (ha habido 70), los que han sido vacunados y no han contraído la enfermedad (ha habido 538) y, por último, los que no han sido vacunados y no han contraído la enfermedad (ha habido 534).

Lección 2

Contrastes de homogeneidad

Introducción

En un contraste de homogeneidad, tenemos dos variables discretas X e Y y nos planteamos si la distribución de la variable Y depende de los valores de la variable X .

El contraste planteado es el siguiente:

$$\left. \begin{array}{l} H_0 : \text{ La distribución de la variable condicional } Y|X = x \\ \text{ es la misma para cualquier valor de } x \text{ del dominio de la variable } X, \\ H_1 : \text{ La distribución de la variable condicional } Y|X = x \\ \text{ no es la misma para cualquier valor de } x. \end{array} \right\}$$

Tablas de contingencia

Para realizar un contraste de homogeneidad, tenemos al igual que en el contraste de independencia n individuos clasificados según la variables X e Y .

Recordemos que $x_1, \dots, x_I$ los distintos **valores** de la variable X e $y_1, \dots, y_J$, los distintos **valores** de la variable Y .

Recordemos también que n_{ij} es el número de individuos clasificados en valor x_i según la variable X y clasificados en el valor y_j según la variable Y . A partir de dichos valores construimos lo que hemos definido como la **tabla de contingencia**:

Tablas de contingencia

X/Y	y_1	...	y_j	...	y_J	$n_{i\bullet}$
x_1	n_{11}	...	n_{1j}	...	n_{1J}	$n_{1\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	n_{i1}	...	n_{ij}	...	n_{iJ}	$n_{i\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_I	n_{I1}	...	n_{Ij}	...	n_{IJ}	$n_{I\bullet}$
$n_{\bullet j}$	$n_{\bullet 1}$	...	$n_{\bullet j}$	...	$n_{\bullet J}$	n

Tablas de contingencia

En la tabla anterior, $n_{i\bullet}$ sería el número total de individuos clasificados en el nivel x_i según el criterio X y $n_{\bullet j}$, el número total de individuos clasificados en el nivel y_j según el criterio Y .

Contraste de homogeneidad como un contraste de bondad de ajuste

Para poder modelar el contraste de homogeneidad como un contraste de **bondad de ajuste**, en primer lugar necesitamos definir una variable “modelo”.

La fila i -ésima de la **tabla de contingencia** anterior representa la tabla de **frecuencias empíricas** de la variable $Y|X = x_i$:

$Y X = x_i$	y_1	...	y_j	...	y_J	Total
	n_{i1}	...	n_{ij}	...	n_{iJ}	$n_{i\bullet}$

Contraste de homogeneidad como un contraste de bondad de ajuste

Si la hipótesis nula es cierta, o, si la distribución de la variable condicionada $Y|X = x_i$ es la misma para cualquier x_i , significa que la distribución de cada fila “coincidirá” con la distribución de la última fila de la tabla de contingencia:

$Y X = x$	y_1	...	y_j	...	y_J	Total
	$n_{\bullet 1}$	...	$n_{\bullet j}$	...	$n_{\bullet J}$	n

Dicha variable será nuestra **variable “modelo”**. Nuestro problema será, pues, chequear si la distribución de las **frecuencias empíricas** (fila i -ésima de la **tabla de contingencia**) coincide con la distribución de las **frecuencias teóricas** (última fila de la **tabla de contingencia**). ¿Pero cómo podemos compararlas si, en principio tendrán tamaño diferente?

Contraste de homogeneidad como un contraste de bondad de ajuste

Antes de poder aplicar toda la maquinaria del contraste χ^2 de bondad de ajuste, necesitamos que la suma de las **frecuencias empíricas** coincida con la suma de las **frecuencias teóricas**.

La suma de las **frecuencias empíricas** vale $n_{i\bullet}$ y la suma de las **frecuencias teóricas**, n .

Contraste de homogeneidad como un contraste de bondad de ajuste

Para “forzar” que las dos sumas sean iguales, multiplicaremos las **frecuencias teóricas** por $\frac{n_{i\bullet}}{n}$. Así, la tabla de **frecuencias teóricas** quedará:

$Y X = x$	y_1	...	y_j	...	y_J	Total
	$\frac{n_{i\bullet}n_{\bullet 1}}{n}$	...	$\frac{n_{i\bullet}n_{\bullet j}}{n}$	...	$\frac{n_{i\bullet}n_{\bullet J}}{n}$	$n_{i\bullet}$

Contraste de homogeneidad como un contraste de bondad de ajuste

Si aplicamos el test χ^2 de bondad de ajuste, tenemos que el estadístico de contraste será:

$$\chi_i^2 = \sum_{j=1}^J \frac{(\text{frec. empíricas} - \text{frec. teóricas})^2}{\text{frec. teóricas}} = \sum_{j=1}^J \frac{\left(n_{ij} - \frac{n_{i\bullet} n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} n_{\bullet j}}{n}}.$$

Ahora bien, tenemos en total i filas. Por tanto, tenemos que sumar el estadístico anterior para todas las filas:

$$\chi^2 = \sum_{i=1}^I \chi_i^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{\left(n_{ij} - \frac{n_{i\bullet} n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} n_{\bullet j}}{n}}.$$

Contraste de homogeneidad como un contraste de bondad de ajuste

Observemos que nos queda la misma expresión que el **estadístico de contraste** que en el **contraste de independencia**.

Por tanto, desde el punto de vista de cómputo o de cálculo, realizar un **contraste de independencia** o de **homogeneidad** sería lo mismo.

Ahora bien, desde el punto de vista de diseño de experimentos, no.

Contraste de homogeneidad como un contraste de bondad de ajuste

Recordemos que en un **contraste de independencia** se toma una **muestra transversal** de la población. En cambio, en un **contraste de homogeneidad** se escoge una de las variables (para todo el estudio realizado, sería la variable X) y para cada uno de sus posibles valores se toma una muestra aleatoria, de tamaño prefijado, de individuos con ese valor para esa variable; su unión forma una **muestra estratificada** en el sentido que hemos visto en la sección de Muestreo.

Ejemplo

Ejemplo del estudio del número de lotes comprados por cliente y la zona donde vive

Recordemos que la tabla de contingencia en este ejemplo era:

X/Y	Y_1	Y_2	Y_3	Y_4	$n_{i\bullet}$
X_1	5	8	15	22	50
X_2	20	26	46	8	100
X_3	15	10	15	10	50
$n_{\bullet j}$	40	44	76	40	200

Ejemplo

Recordemos que la variable X representaba la zona donde reside el cliente y la variable Y , el número de lotes que compra.

Los valores de X eran: $X_1 = \text{"Norte"}$, $X_2 = \text{"Centro"}$ y $X_3 = \text{"Sur"}$.

Los valores de Y eran: $Y_1 = \text{"Dos o menos"}$, $Y_2 = \text{"Entre tres y cinco"}$, $Y_3 = \text{"Entre seis y ocho"}$ y $Y_4 = \text{"Nueve o más"}$.

El contraste de homogeneidad consiste en este caso en testear si la distribución de la variable Y , número de lotes comprados, es la misma para los tres valores de la variable X .

Ejemplo

Para que dicho estudio tenga sentido (desde el punto de vista de la homogeneidad), tendremos que **estratificar** primero la población de los clientes según los valores de la variable X . Tendremos que elegir un número prefijado de clientes que vivan en el norte, un número prefijado de clientes que vivan en el centro y un número prefijado de clientes que vivan en el sur.

Según los datos de la tabla anterior, se eligen aleatoriamente 50 clientes que viven en el norte, 100 clientes que viven en el centro y 50 clientes que viven en el sur. Fijaos que estos tres números se fijan antes de realizar los tres muestreos, cosa que no pasaba en el contraste de independencia. En dicho contraste, se fijaba un sólo número que sería el número total de clientes a clasificar.

Ejemplo

El contraste realizado en R era el siguiente:

```
chisq.test(matrix(c(5,20,15,8,26,10,15,46,15,22,8,10),3,4))
```

Pearson's Chi-squared test

```
data:  matrix(c(5, 20, 15, 8, 26, 10, 15, 46, 15, 22, 8, 10), 3, 4)
X-squared = 31.605, df = 6, p-value = 1.942e-05
```

Como el p-valor es muy pequeño, concluimos que tenemos indicios suficientes para rechazar que la distribución del número de lotes comprados por cliente es la misma para las tres zonas donde residen

Guía rápida

- `table` calcula tablas de contingencia de frecuencias absolutas.
- `prop.table` calcula tablas de contingencia de frecuencias relativas.
- `addmargins` sirve para añadir a una `table` una fila o una columna obtenidas aplicando una función a todas las columnas o a todas las filas de la tabla, respectivamente. Sus parámetros principales son:
 - `margin`: igualado a 1, se aplica la función por columnas, añadiendo una nueva fila; igualado a 2, se aplica la función por filas, añadiendo una nueva columna; igualado a `c(1,2)`, que es su valor por defecto, hace ambas cosas.
 - `FUN`: la función que se aplica a las filas o columnas; su valor por defecto es `sum`.

Guía rápida

- `colSums` calcula un vector con las sumas de las columnas de una matriz o una tabla.
- `rowSums` calcula un vector con las sumas de las filas de una matriz o una tabla.
- `chisq.test` sirve para realizar tests χ^2 de independencia y homogeneidad. El resultado es una `list` formada, entre otros, por los objetos siguientes: `statistic` (el valor del estadístico X^2), `parameter` (los grados de libertad) y `p.value` (el p-valor). Sus parámetros principales en el contexto de esta lección son:
 - `simulate.p.value`: igualado a `TRUE`, calcula el p-valor mediante simulaciones.
 - `B`: en este último caso, permite especificar el número de simulaciones.