

Tema 8: Regresión Lineal, Parte 1: Reg.Simple

Parte 2: Inferencia estadística con R y python

diciembre 2023

Lección 1

Regresión Lineal Simple

Introducción

El problema de **regresión** consiste en hallar la mejor **relación funcional** entre dos variables X e Y .

Más concretamente, dada una muestra de las dos variables X, Y , $(x_i, y_i)_{i=1,2,\dots,n}$, queremos estudiar cómo depende el valor de Y en función del valor de X .

La variable aleatoria Y es la variable **dependiente** o **de respuesta**.

La variable (no necesariamente aleatoria) X es la variable **de control**, **independiente** o **de regresión**. Pensemos por ejemplo, en un experimento donde la variable X es la que controla el experimentador y la variable Y es el valor que se obtiene del experimento.

Introducción

El problema de **regresión** es encontrar la mejor **relación funcional** que explique la variable Y conocidas las observaciones de la variable X .

Si dicha **relación funcional** es una recta, $Y = \beta_0 + \beta_1 x$, la **regresión** se denomina **regresión lineal**.

En la **regresión lineal**, se hace la suposición siguiente:

$$\mu_{Y|x} = \beta_0 + \beta_1 x,$$

dónde $\mu_{Y|x}$ es el valor esperado de la variable aleatoria Y cuando la variable X vale x . Dicho valor esperado es una función lineal de X con **término independiente** β_0 y **pendiente** β_1 . Dichos valores son dos parámetros que tendremos que estimar.

Introducción

Las estimaciones de β_0 y β_1 se llaman b_0 y b_1 , respectivamente y se tienen que realizar a partir de la muestra $(x_i, y_i)_{i=1,2,\dots,n}$.

Una vez halladas las estimaciones b_0 y b_1 , obtendremos la **recta de regresión** para nuestra muestra:

$$\hat{y} = b_0 + b_1x,$$

que dado un valor x_0 de X , estimará el valor $\hat{y}_0 = b_0 + b_1x_0$ de la variable Y .

Mínimos cuadrados

Vamos a explicar el método para hallar las estimaciones b_0 y b_1 .

Dicho método se denomina **método de los mínimos cuadrados**.

Dada una observación cualquiera de la muestra, (x_i, y_i) , podremos separar la componente y_i como la suma de su **valor predicho por el modelo** y el error cometido:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \Rightarrow \varepsilon_i = y_i - (\beta_0 + \beta_1 x_i).$$

Llamamos **error cuadrático teórico** de este modelo a la suma al cuadrado de todos los errores cometidos por los valores de la muestra:

$$SS_{\varepsilon} = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Mínimos cuadrados

La **regresión lineal por mínimos cuadrados** consiste en hallar los estimadores b_0 y b_1 de β_0 y β_1 que minimicen dicho **error cuadrático teórico** SS_ϵ .

Observación: }** los errores cometidos pueden ser positivos o negativos. Entonces, para asegurarse de penalizar siempre los errores, se elevan éstos al cuadrado y de esta forma, siempre se suman y no pueden anularse.

Para hallar el mínimo del **error cuadrático teórico**, (b_0, b_1) , hay que derivar respecto las variables β_0 y β_1 e igualar a 0 dichas derivadas:

$$\begin{aligned}\frac{\partial SS_\epsilon}{\partial \beta_0} \Big|_{\beta_0=b_0, \beta_1=b_1} &= -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0, \\ \frac{\partial SS_\epsilon}{\partial \beta_1} \Big|_{\beta_0=b_0, \beta_1=b_1} &= -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) x_i = 0.\end{aligned}$$

Mínimos cuadrados

La solución del sistema anterior es:

$$b_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2},$$
$$b_0 = \frac{\sum_{i=1}^n y_i - b_1 \sum_{i=1}^n x_i}{n}.$$

Mínimos cuadrados

Vamos a escribir las estimaciones b_0 y b_1 obtenidas anteriormente en función de las medias, varianzas y covarianza de la muestra de valores (x_i, y_i) .

Sean entonces

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$

las medias de las componentes x e y de los valores de la muestra y sean

Mínimos cuadrados

$$\begin{aligned}\tilde{s}_x^2 &= \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} \left(\frac{1}{n} \left(\sum_{i=1}^n x_i^2 \right) - \bar{x}^2 \right), \\ \tilde{s}_y^2 &= \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{n}{n-1} \left(\frac{1}{n} \left(\sum_{i=1}^n y_i^2 \right) - \bar{y}^2 \right), \\ \tilde{s}_{xy} &= \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{n}{n-1} \left(\frac{1}{n} \left(\sum_{i=1}^n x_i y_i \right) - \bar{x} \cdot \bar{y} \right),\end{aligned}$$

las varianzas y la covarianza de la muestra (x_i, y_i) , $i = 1, \dots, n$.

Mínimos cuadrados

Las estimaciones b_0 y b_1 se pueden reescribir de la forma siguiente:

Teorema. Los estimadores b_0 y b_1 de β_0 y β_1 , respectivamente, hallados por el **método de los mínimos cuadrados** son los siguientes: $b_1 = \frac{\tilde{s}_{xy}}{\tilde{s}_x^2}$, $b_0 = \bar{y} - b_1\bar{x}$.

Ejercicio

Se deja como ejercicio la demostración del teorema anterior a partir de la expresión hallada anteriormente.

Dado un valor x de la variable X , llamaremos $\hat{y}$ a la expresión $\hat{y} = b_0 + b_1x$ al **valor estimado** de Y cuando $X = x$.

Dada una observación (x_i, y_i) , llamaremos **error** de la observación e_i a la expresión $e_i = y_i - \hat{y}_i = y_i - b_0 - b_1x_i$.

Ejemplo

Ejemplo

En un experimento donde se quería estudiar la asociación entre de el nivel analógico (de 1 a 5) de un termostato de un sistema de aire acondicionado de una *data center* y la temperatura media en grados Fahrenheit del procesador. Se tomaron las siguientes medidas resultados fueron los siguientes:

X (nivel)	Y (Temperatura en F)
1.8	100
2.2	98
3.5	110
4.0	110
4.3	112
5.0	120

Ejemplo

Vamos a hallar la **recta de regresión lineal por mínimos cuadrados** de Y en función de X .

En primer lugar calculamos las medias, varianzas y covarianza de la muestra de datos:

```
nivel=c(1.8,2.2,3.5,4.0,4.3,5.0)
temperatura=c(100,98,110,110,112,120)
(media.nivel = mean(nivel))
```

```
[1] 3.466667
```

```
(media.temperatura = mean(temperatura))
```

```
[1] 108.3333
```

Ejemplo

```
(var.nivel = var(nivel))
```

```
[1] 1.542667
```

```
(var.temperatura = var(temperatura))
```

```
[1] 66.26667
```

```
(cov.nivel.temperatura = cov(nivel,temperatura))
```

```
[1] 9.773333
```

Ejemplo

Los estimadores b_0 y b_1 serán:

```
(b1 = cov.nivel.temperatura/var.nivel)
```

```
[1] 6.33535
```

```
(b0 = media.temperatura-b1*media.nivel)
```

```
[1] 86.37079
```

La recta de regresión será, en este caso: $\hat{y} = 86.3707865 + 6.33535 \cdot x$.

Recta de regresión en R

Para hallar la recta de regresión en R hay que usar la función `lm`:

```
lm(temperatura ~ nivel)
```

Call:

```
lm(formula = temperatura ~ nivel)
```

Coefficients:

(Intercept)	nivel
86.371	6.335

Propiedades de la recta de regresión

La **recta de regresión** hallada por el **método de los mínimos cuadrados** verifica las propiedades siguientes:

- La **recta de regresión** pasa por el vector medio $(\bar{x}, \bar{y})$ de nuestra muestra de datos (x_i, y_i) , $i = 1, \dots, n$:

$$\bar{y} = b_0 + b_1 \bar{x}.$$

- La media de los valores estimados a partir de la **recta de regresión** es igual a la media de los observados y_i , $\bar{y}$. Es decir:

$$\bar{\hat{y}} = \frac{1}{n} \sum_{i=1}^n \hat{y}_i = \frac{1}{n} \sum_{i=1}^n (b_0 + b_1 x_i) = b_0 + b_1 \bar{x} = \bar{y}.$$

Propiedades de la recta de regresión

- Los errores $(e_i)_{i=1,\dots,n}$ tienen media 0:

$$\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i = \frac{1}{n} \sum_{i=1}^n (y_i - b_0 - b_1 x) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i) = 0.$$

Llamaremos **suma de cuadrados de los errores** a la cantidad siguiente: $SS_E = \sum_{i=1}^n e_i^2$.

Usando que los errores $(e_i)_{i=1,\dots,n}$ tienen media 0, su varianza será:

$$s_e^2 = \frac{1}{n} \left(\sum_{i=1}^n e_i^2 \right) - \bar{e}^2 = \frac{SS_E}{n} - 0 = \frac{SS_E}{n}.$$

Propiedades de la recta de regresión

Definimos las variables aleatorias E_{x_i} como $E_{x_i} = y_i - b_0 - b_1 \cdot x_i$ donde (x_i, y_i) es un valor de la muestra y b_0 y b_1 son los estimadores obtenidos por el **método de los mínimos cuadrados**. Entonces,

Teorema. Si las variables aleatorias error E_{x_i} tienen todas media 0 y la misma varianza σ_E^2 y, dos a dos, tienen covarianza 0, entonces

- b_0 y b_1 son los estimadores lineales no sesgados óptimos (más eficientes) de β_0 y β_1 , respectivamente.

y un **estimador no sesgado de σ_E^2** es el siguiente: $S^2 = \frac{SS_E}{n-2}$.

Si, además, las variables aleatorias error E_{x_i} son **normales**, entonces b_0 y b_1 son los estimadores máximo verosímiles de β_0 y β_1 , respectivamente.

Ejemplo

Comprobemos las propiedades para los datos del ejemplo anterior:

- La **recta de regresión** pasa por el vector medio $(\bar{x}, \bar{y})$:

```
(round(media.temperatura-b0-b1*media.nivel,6))
```

```
[1] 0
```

- La media de los valores estimados a partir de la **recta de regresión** es igual a la media de los observados y_i , $\bar{y}$.

```
temperatura.estimada = b0+b1*nivel  
(mean(temperatura.estimada)-mean(temperatura))
```

```
[1] 0
```

Ejemplo

La estimación de la varianza para los datos del ejemplo anterior es la siguiente:

```
errores=temperatura.estimada-temperatura
SSE = sum(errores^2)
n=length(nivel)
(estimación.varianza = SSE/(n-2))
```

```
[1] 5.436474
```

Entonces tenemos que el valor aproximado o estimado de σ_E^2 es 5.4364736.

Coeficiente de determinación

Llegados a este punto, nos preguntamos lo efectiva que es la **recta de regresión**.

Es decir, cómo medir si la aproximación hallada $\hat{y} = b_0 + b_1x$ a la nube de puntos (x_i, y_i) , $i = 1, \dots, n$ ha sido suficientemente buena.

Una forma de realizar dicha medición es a través del **coeficiente de determinación** R^2 que estima cuánta **variabilidad** de los valores y_i heredan los valores estimados $\hat{y}_i$.

Para ver su definición, necesitamos introducir las **variabilidades** siguientes:

Coeficiente de determinación

- **Variabilidad total** o suma total de cuadrados: $SS_T = \sum_{i=1}^n (y_i - \bar{y})^2 = (n - 1) \cdot \tilde{s}_y^2$.
- **Variabilidad de la regresión** o suma de cuadrados de la regresión:
$$SS_R = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = (n - 1) \cdot \tilde{s}_{\hat{y}}^2$$
- **Variabilidad del error** o suma de cuadrados del error:
$$SS_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = (n - 1) \cdot \tilde{s}_e^2$$

El teorema siguiente nos relaciona las variabilidades anteriores:

Coeficiente de determinación

Teorema. En una regresión lineal usando el método de los mínimos cuadrados, se cumple la siguiente relación entre las **variabilidades**:

$$SS_T = SS_R + SS_E,$$

o equivalentemente,

$$\tilde{s}_y^2 = \tilde{s}_{\hat{y}}^2 + \tilde{s}_e^2.$$

Entonces, cuántas más “próximas” estén las **variabilidades** SS_T y SS_R , o, si se quiere, $\tilde{s}_y^2$ y $\tilde{s}_{\hat{y}}^2$, más efectiva habrá sido la regresión, ya que la regresión habrá heredado mucha variabilidad de los datos y_i , $i = 1, \dots, n$ y la variabilidad del error, SS_E será pequeña.

Coeficiente de determinación

El comentario anterior motiva la definición siguiente del **coeficiente de determinación** para medir la efectividad de la recta de regresión:

Definición: se define el **coeficiente de determinación** R^2 en la regresión por el método de los mínimos cuadrados como: $R^2 = \frac{SS_R}{SS_T} = \frac{\tilde{s}_{\hat{y}}^2}{\tilde{s}_y^2}$.

Observación: el **coeficiente de determinación** R^2 es la fracción de la variabilidad de las componentes y que queda explicada por la variabilidad de las estimaciones correspondientes $\hat{y}$.

Propiedades del coeficiente de determinación

- El **coeficiente de determinación** es una cantidad entre 0 y 1: $0 \leq R^2 \leq 1$. Entonces, cuánto más próximo a 1 esté dicho coeficiente, más precisa será la recta de regresión.
- El **coeficiente de determinación** se puede expresar en función de la **variabilidad del error** de la forma siguiente:

$$R^2 = \frac{SS_T - SS_E}{SS_T} = 1 - \frac{SS_E}{SS_T} = 1 - \frac{\tilde{s}_e^2}{\tilde{s}_y^2}.$$

- Se define el **coeficiente de correlación lineal** r_{xy} como $r_{xy} = \frac{\tilde{s}_{xy}}{\tilde{s}_x \cdot \tilde{s}_y}$. Entonces, el **coeficiente de determinación** R^2 es el cuadrado del **coeficiente de correlación lineal**:
 $R^2 = r_{xy}^2.$

Propiedades del coeficiente de determinación

Veamos la demostración de la última propiedad:

$$\begin{aligned}
 R^2 &= \frac{SS_R}{SS_T} = \frac{\sum_{i=1}^n (b_1 x_i + b_0 - \bar{y})^2}{(n-1)\tilde{s}_y^2} = \frac{\sum_{i=1}^n \left(\frac{\tilde{s}_{xy}}{\tilde{s}_x^2} x_i - \frac{\tilde{s}_{xy}}{\tilde{s}_x^2} \bar{x} \right)^2}{(n-1)\tilde{s}_y^2} \\
 &= \frac{\frac{\tilde{s}_{xy}^2}{\tilde{s}_x^4} \sum_{i=1}^n (x_i - \bar{x})^2}{(n-1)\tilde{s}_y^2} = \frac{\tilde{s}_{xy}^2}{\tilde{s}_x^4} \cdot \frac{\tilde{s}_x^2}{\tilde{s}_y^2} = \frac{\tilde{s}_{xy}^2}{\tilde{s}_x^2 \cdot \tilde{s}_y^2} = r_{xy}^2
 \end{aligned}$$

Ejemplo

Calculemos las variabilidades anteriores y el **coeficiente de determinación** para los datos de nuestro ejemplo:

- **Variabilidad total:**

```
(SST = sum((temperatura-media.temperatura)^2))
```

```
[1] 331.3333
```

- **Variabilidad de la regresión:**

```
(SSR = sum((temperatura.estimada-media.temperatura)^2))
```

```
[1] 309.5874
```

Ejemplo

- **Variabilidad del error:**

```
(SSE = sum((temperatura-temperatura.estimada)^2))
```

```
[1] 21.74589
```

Comprobemos que se cumple $SST = SSR + SSE$:

```
(round(SST-SSR-SSE,6))
```

```
[1] 0
```

Ejemplo

El coeficiente de determinación R^2 será:

$$(R^2 = SSR / SST)$$

```
[1] 0.9343685
```

Otra manera de calcularlo es:

$$(R^2 = \text{var}(\text{temperatura.estimada}) / \text{var}(\text{temperatura}))$$

```
[1] 0.9343685
```

En este caso, la regresión explica un 93.44% de la variabilidad de los datos.

Coeficiente de determinación en R

Para hallar el **coeficiente de determinación** en R hemos de usar las funciones `lm` y `summary` junto con el parámetro `r.squared`:

```
summary(lm(y ~ x))$r.squared
```

Si aplicamos las funciones anteriores a los datos de nuestro ejemplo, obtenemos:

```
summary(lm(temperatura ~ nivel))$r.squared
```

```
[1] 0.9343685
```

Coeficiente de determinación

Usar solamente el **coeficiente de determinación** para medir la calidad de la regresión es un error.

Tenemos que observar más información para poder afirmar que la regresión obtenida es adecuada y se ajusta bien a nuestros datos.

En R existe una tabla de datos denominada `anscombe` que pone de manifiesto este hecho. Vamos a echarle un vistazo:

Coeficiente de determinación

```
data(anscombe)
str(anscombe)
```

```
'data.frame':  11 obs. of  8 variables:
 $ x1: num  10 8 13 9 11 14 6 4 12 7 ...
 $ x2: num  10 8 13 9 11 14 6 4 12 7 ...
 $ x3: num  10 8 13 9 11 14 6 4 12 7 ...
 $ x4: num   8 8 8 8 8 8 8 19 8 8 ...
 $ y1: num  8.04 6.95 7.58 8.81 8.33 ...
 $ y2: num  9.14 8.14 8.74 8.77 9.26 8.1 6.13 3.1 9.13 7.26 ...
 $ y3: num  7.46 6.77 12.74 7.11 7.81 ...
 $ y4: num  6.58 5.76 7.71 8.84 8.47 7.04 5.25 12.5 5.56 7.91 ...
```

Vemos que tiene 4 parejas de valores (x_i, y_i) de tamaño 11:

Coeficiente de determinación

anscombe

	x1	x2	x3	x4	y1	y2	y3	y4
1	10	10	10	8	8.04	9.14	7.46	6.58
2	8	8	8	8	6.95	8.14	6.77	5.76
3	13	13	13	8	7.58	8.74	12.74	7.71
4	9	9	9	8	8.81	8.77	7.11	8.84
5	11	11	11	8	8.33	9.26	7.81	8.47
6	14	14	14	8	9.96	8.10	8.84	7.04
7	6	6	6	8	7.24	6.13	6.08	5.25
8	4	4	4	19	4.26	3.10	5.39	12.50
9	12	12	12	8	10.84	9.13	8.15	5.56
10	7	7	7	8	4.82	7.26	6.42	7.91
11	5	5	5	8	5.68	4.74	5.73	6.89

Coeficiente de determinación

Si calculamos los **coeficientes de determinación** para las 4 parejas, obtenemos un resultado similar:

```
summary(lm(y1~x1,data=anscombe))$r.squared
```

```
[1] 0.6665425
```

```
summary(lm(y2~x2,data=anscombe))$r.squared
```

```
[1] 0.666242
```

Coeficiente de determinación

```
summary(lm(y3~x3,data=anscombe))$r.squared
```

```
[1] 0.666324
```

```
summary(lm(y4~x4,data=anscombe))$r.squared
```





```
[1] 0.6667073
```

En cambio, si vemos su representación gráfica, su aspecto es muy distinto:

Coeficiente de determinación

```
par(mfrow=c(2,2))  
plot(y1~x1,data=anscombe)  
abline(lm(y1~x1,data=anscombe),col=2)  
plot(y2~x2,data=anscombe)  
abline(lm(y2~x2,data=anscombe),col=2)  
plot(y3~x3,data=anscombe)  
abline(lm(y3~x3,data=anscombe),col=2)  
plot(y4~x4,data=anscombe)  
abline(lm(y4~x4,data=anscombe),col=2)
```

Coeficiente de determinación



Coeficiente de determinación

Observamos que en el caso de la tabla de datos (x_3, y_3) , la recta de regresión ha sido efectiva pero en los demás hemos obtenido un error considerable donde el peor caso es el de la tabla de datos (x_4, y_4) .

Por tanto, considerar sólo el valor del **coeficiente de determinación** para medir el ajuste de la recta de regresión a nuestros datos no es conveniente.

Intervalos de confianza

Para poder hallar los intervalos de confianza al $100 \cdot (1 - \alpha)\%$ de confianza sobre los parámetros β_0 y β_1 , necesitamos el supuesto siguiente:

Para cada valor x_i de la variable X , las variables aleatorias E_{x_i} sigue una distribución normal con media $\mu_{E_{x_i}} = 0$ y varianza σ_E^2 constante independiente del valor x_i . También supondremos que dados x_i y x_j dos valores distintos de la variable X , la covarianza entre las variables E_{x_i} y E_{x_j} es nula: $\sigma(E_{x_i}, E_{x_j}) = 0$.

Ejemplo

Comprobemos para los datos de nuestro ejemplo si los errores siguen una distribución normal usando el test de **Kolmogorov-Smirnov-Lilliefors**:

```
library(nortest)
lillie.testerrores)
```

Lilliefors (Kolmogorov-Smirnov) normality test

```
data: errores
D = 0.28034, p-value = 0.1468
```

Como el p-valor es grande, podemos concluir que no tenemos evidencias suficientes para rechazar que los errores siguen una distribución normal.

Intervalos de confianza

Bajo las hipótesis anteriores tenemos los dos resultados siguientes:

Teorema. Los errores estándar de los estimadores b_1 y b_0 son, respectivamente,

$$\frac{\sigma_E}{\tilde{s}_x \sqrt{n-1}} \quad \text{y} \quad \sigma_E \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{(n-1)\tilde{s}_x^2}},$$

donde recordemos que para estimar σ_E , usamos el estimador $S = \sqrt{S^2}$.

Intervalos de confianza

Teorema. Las variables aleatorias

$$\frac{b_1 - \beta_1}{\frac{S}{\tilde{s}_x \sqrt{n-1}}} \quad \text{y} \quad \frac{b_0 - \beta_0}{S \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{(n-1)\tilde{s}_x^2}}},$$

siguen leyes t de Student con $n - 2$ grados de libertad.

Intervalos de confianza

Entonces bajo el supuesto anterior, los intervalos de confianza para los parámetros β_1 y β_0 al $100 \cdot (1 - \alpha)\%$ de confianza son los siguientes:

- β_1 : $\left[b_1 - t_{n-2, 1-\frac{\alpha}{2}} \frac{S}{\tilde{s}_x \sqrt{n-1}}, b_1 + t_{n-2, 1-\frac{\alpha}{2}} \frac{S}{\tilde{s}_x \sqrt{n-1}} \right]$. Lo escribiremos para simplificar de la forma siguiente: $\beta_1 = b_1 \pm t_{n-2, 1-\frac{\alpha}{2}} \frac{S}{\tilde{s}_x \sqrt{n-1}}$.
- β_0 : $b_0 \pm t_{n-2, 1-\frac{\alpha}{2}} S \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{(n-1)\tilde{s}_x^2}}$.

Ejemplo

Hallemos los intervalos de confianza para el 95% de confianza para los parámetros β_1 y β_0 usando los datos del ejemplo que hemos ido desarrollando. Intervalo confianza para β_1 :

```
alpha=0.05
S=sqrt(estimación.varianza)
extremo.izquierda.b1 = b1-qt(1-alpha/2,n-2)*S/(sd(nivel)*sqrt(n-1))
extremo.derecha.b1 = b1+qt(1-alpha/2,n-2)*S/(sd(nivel)*sqrt(n-1))
c(extremo.izquierda.b1,extremo.derecha.b1)
```

```
[1] 4.004434 8.666266
```

Ejemplo

Intervalo confianza para β_0 :

```
extremo.izquierda.b0 = b0-qt(1-alpha/2,n-2)*S*  
  sqrt(1/n+media.nivel^2/((n-1)*var(nivel)))  
extremo.derecha.b0 = b0+qt(1-alpha/2,n-2)*S*  
  sqrt(1/n+media.nivel^2/((n-1)*var(nivel)))  
c(extremo.izquierda.b0,extremo.derecha.b0)
```

```
[1] 77.86906 94.87251
```

Intervalos de confianza en R

Para hallar los intervalos de confianza de los parámetros β_1 y β_0 en R hay que aplicar la función `confint` al objeto `lm(...)`. El parámetro `level` nos da el nivel de confianza cuyo valor por defecto es 0.95.

Para los datos de nuestro ejemplo, los intervalos de confianza para los parámetros β_0 y β_1 serían los siguientes en R :

```
confint(lm(temperatura~nivel),level=0.95)
```

	2.5 %	97.5 %
(Intercept)	77.869064	94.872509
nivel	4.004434	8.666266

Intervalos de confianza

Fijado un valor x_0 de la variable X , podemos considerar dos parámetros a estudiar: el valor medio de la variable aleatoria $Y|x_0$, $\mu_{Y|x_0}$ y el valor estimado y_0 por la recta de regresión.

Dichos intervalos nos ayudan a estudiar cómo se comporta la regresión cuando el valor de la variable X vale un determinado valor x_0 .

El estimador de los parámetros anteriores, $\mu_{Y|x_0}$ y y_0 es el mismo: $\hat{y}_0 = b_0 + b_1 \cdot x_0$ pero los errores estándares cambian dependiendo del parámetro que consideremos como indican los dos resultados siguientes:

Intervalos de confianza

Bajo el supuesto anterior, sea x_0 un valor concreto de la variable X . Entonces:

Teorema. El error estándar del estimador $\hat{y}_0$ del parámetro $\mu_{Y|x_0}$ es el siguiente:

$$\sigma_E \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{(n-1)\tilde{s}_x^2}}.$$

Usando el resultado anterior, se tiene que la variable aleatoria: $\frac{\hat{y}_0 - \mu_{Y|x_0}}{S \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{(n-1)\tilde{s}_x^2}}}$ sigue una ley t de Student con $n - 2$ grados de libertad.

Intervalos de confianza

Teorema. El error estándar del estimador $\hat{y}_0$ del parámetro y_0 es el siguiente:

$$\sigma_E \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{(n-1)\tilde{s}_x^2}}.$$

Usando el resultado anterior, se tiene que la variable aleatoria: $\frac{\hat{y}_0 - y_0}{S \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{(n-1)\tilde{s}_x^2}}}$ sigue una ley t de Student con $n - 2$ grados de libertad.

Intervalos de confianza

A partir de los teoremas anteriores, hallamos los intervalos de confianza para los parámetros $\mu_{Y|x_0}$ y y_0 al $100 \cdot (1 - \alpha)\%$ de confianza:

- $\mu_{Y|x_0}: \hat{y}_0 \pm t_{n-2, 1-\frac{\alpha}{2}} S \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{(n-1)\tilde{s}_x^2}}.$
- $y_0: \hat{y}_0 \pm t_{n-2, 1-\frac{\alpha}{2}} S \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{(n-1)\tilde{s}_x^2}}.$

Ejemplo

Hallemos un intervalo de confianza para un nivel de nivel de $x_0 = 4.5$ g. para los parámetros $\mu_{Y|4.5}$ y y_0 al 95% de confianza:

```
alpha=0.05;x0=4.5;y0.estimado = b0+b1*x0
extremo.izquierda.mu.x0 = y0.estimado-qt(1-alpha/2,n-2)*S*
  sqrt(1/n+(x0-media.nivel)^2/((n-1)*var(nivel)))
extremo.derecha.mu.x0 = y0.estimado+qt(1-alpha/2,n-2)*S*
  sqrt(1/n+(x0-media.nivel)^2/((n-1)*var(nivel)))
c(extremo.izquierda.mu.x0,extremo.derecha.mu.x0)
```

```
[1] 111.3041 118.4556
```

Ejemplo

```
extremo.izquierda.y0 = y0.estimado-qt(1-alpha/2,n-2)*S*
  sqrt(1+1/n+(x0-media.nivel)^2/((n-1)*var(nivel)))
extremo.derecha.y0 = y0.estimado+qt(1-alpha/2,n-2)*S*
  sqrt(1+1/n+(x0-media.nivel)^2/((n-1)*var(nivel)))
print(paste("Intervalo de confianza para y0 para x0=",x0))
```

```
[1] "Intervalo de confianza para y0 para x0= 4.5"
```

```
print(c(extremo.izquierda.y0,extremo.derecha.y0))
```

```
[1] 107.4843 122.2754
```

Intervalos de confianza en R

Para hallar el intervalo de confianza para el parámetros $\mu_{Y|x_0}$ al $100 \cdot (1 - \alpha)\%$ de confianza hay que usar la función `predict.lm` de la forma siguiente:

```
newdata=data.frame(x=x0)
predict.lm(lm(y~x),newdata,interval="confidence",level= nivel.confianza)
```

Para el parámetro y_0 hay que usar la misma función anterior pero cambiando el parámetro `interval` al valor `prediction`:

```
newdata=data.frame(x=x0)
predict.lm(lm(y~x),newdata,interval="prediction",level= nivel.confianza)
```

Ejemplo

Hallemos los intervalos de confianza para los parámetros $\mu_{Y|4.5}$ y y_0 al 95% de confianza usando R :

```
newdata=data.frame(nivel=4.5)
predict.lm(lm(temperatura~nivel),newdata,interval="confidence",level= 0.95)
```

	fit	lwr	upr
1	114.8799	111.3041	118.4556

```
predict.lm(lm(temperatura~nivel),newdata,interval="prediction",level= 0.95)
```

	fit	lwr	upr
1	114.8799	107.4843	122.2754

Contraste de hipótesis sobre la pendiente de la recta β_1

Cuando nos planteamos hacer una regresión de la variable Y sobre la variable X , estamos suponiendo que la variable X influye en la variable Y . Es decir, que si cambiamos el valor de la variable X , habrá un cambio en la variable Y .

Decir que la variable X influye en la variable Y en el contexto de la **regresión lineal** es equivalente a decir que $\beta_1 \neq 0$ ya que si $\beta_1 = 0$, tendríamos que la variación de la variable Y sólo se debería a fluctuaciones aleatorias.

Contraste de hipótesis sobre la pendiente de la recta β_1

Por tanto, es interesante plantearse el **contraste de hipótesis** siguiente sobre el parámetro **pendiente de la recta de regresión**: β_1 :

$$\begin{cases} H_0 : \beta_1 = 0, \\ H_1 : \beta_1 \neq 0. \end{cases}$$

En el supuesto de que las variables aleatorias E_{x_i} son normales $N(0, \sigma_E^2)$, el **estadístico de contraste** para realizar el contraste anterior es el siguiente: $T = \frac{b_1}{\frac{s}{\tilde{s}_x \sqrt{n-1}}}$, que, suponiendo que la hipótesis nula es cierta, se distribuye según una t de Student con $n - 2$ grados de libertad.

Contraste de hipótesis sobre la pendiente de la recta β_1

Si t_0 es el valor del estadístico de contraste para los valores de nuestra muestra, el p-valor del contraste anterior es el siguiente:

$$p = 2 \cdot P(t_{n-2} > |t_0|),$$

con el significado usual:

Contraste de hipótesis sobre la pendiente de la recta β_1

- si $p < 0.05$, concluimos que tenemos evidencias suficientes para rechazar la hipótesis nula y, por tanto, tiene sentido la regresión al no rechazar que $\beta_1 \neq 0$,
- si $p > 0.1$, concluimos que no tenemos evidencias suficientes para rechazar la hipótesis nula. En este caso, la regresión no tendría sentido al no rechazar que $\beta_1 = 0$ y,
- si $0.05 \leq p \leq 0.1$, estamos en la zona de penumbra. Necesitamos más datos para tomar una decisión clara.

Contraste de hipótesis sobre la pendiente de la recta β_1

Otra forma de realizar el contraste anterior es observar el intervalo de confianza para β_1 y ver si contiene el valor 0.

En caso de contener el valor 0, la regresión no tendría sentido para el nivel de confianza de $100 \cdot (1 - \alpha)\%$ ya que no rechazamos que $\beta_1 = 0$ y en caso de no contener el valor 0, la regresión sí tendría sentido al nivel de confianza anterior.

Ejemplo

Realicemos el contraste anterior para los datos de nuestro ejemplo. El valor del estadístico de contraste será:

```
(t0 = b1/(S/(sd(nivel)*sqrt(n-1))))
```

```
[1] 7.546282
```

y el p-valor vale:

```
(p=2*pt(abs(t0),n-2,lower.tail = FALSE))
```

```
[1] 0.001652012
```

Como el p-valor es pequeño, podemos concluir que la regresión tiene sentido en este caso.

Contraste para la pendiente β_1 en R

Para realizar el contraste anterior en R , hay que estudiar la salida de la función `summary` aplicada a la función `lm`:

```
summary(lm(y~x))
```

La salida anterior para los datos de nuestro ejemplo es la siguiente:

```
summary(lm(temperatura ~ nivel))
```

Ejemplo

Call:

```
lm(formula = temperatura ~ nivel)
```

Residuals:

1	2	3	4	5	6
2.226	-2.309	1.455	-1.712	-1.613	1.952

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	86.3708	3.0621	28.206	9.4e-06 ***
nivel	6.3354	0.8395	7.546	0.00165 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.332 on 4 degrees of freedom

Multiple R-squared: 0.9344, Adjusted R-squared: 0.918

F-statistic: 56.95 on 1 and 4 DF, p-value: 0.001652

Ejemplo

En primer lugar R nos da los errores de los datos cometidos al estimar los valores y_i por $\hat{y}_i$.

A continuación, en una tabla, nos da las estimaciones de los parámetros β_0 y β_1 , b_0 y b_1 , en la columna Estimate, los errores estándar de dichos estimadores en la columna Std. Error y el valor del estadístico t en la columna t value. En la última columna nos da el p-valor para el contraste anterior.

Observamos que hay dos valores de los estadísticos de contraste, uno corresponde al contraste para β_1 (la segunda fila) y otro corresponde al contraste para β_0 que no tiene ningún interés para ver si la regresión tiene sentido. Pensemos que el hecho de que el parámetro β_0 sea nulo no contradice el hecho de que la variable X tenga efecto en la variable Y .

Por último, en el último párrafo de la salida, nos da el valor del error residual o la estimación de S , el valor del coeficiente de determinación R^2 , el Multiple R-squared, y el valor de R^2 ajustado del que hablaremos más adelante.

Ejemplo

En la última fila, nos habla del estadístico F que es otra manera de realizar el contraste sobre el parámetro β_1 que hemos explicado anteriormente pero en lugar de usar el estadístico T , se usa el estadístico T^2 que, si la hipótesis nula es cierta, se distribuye según una F de Fisher con 1 y $n - 2 = 4$ grados de libertad. Podéis comprobar por ejemplo que t_0^2 vale el valor del F-statistic:

```
t0^2
```

```
[1] 56.94637
```

Otros modelos de regresión: potencial y exponencial

Otros tipo de modelos de regresión son el modelo **potencial**

$$Y = \beta_0 \cdot X^{\beta_1}$$

Que, si Y y X son positivas se puede transformar tomando logaritmo en ambos lados de la ecuación como

$$\log_{10}(Y) = \log_{10}(\beta_0 \cdot X^{\beta_1})$$

que operando es

$$\log_{10}(Y) = \log_{10}(\beta_0) + \beta_1 \cdot \log_{10}(X)$$

Otros modelos de regresión

Modelo **exponencial**

$$Y = \beta_0 \cdot \beta_1^X$$

Que, si Y y X son positivas se puede transformar tomando logaritmo en ambos lados de la ecuación como

$$\log_{10}(Y) = \log_{10}(\beta_0 \cdot \beta_1^X)$$

que operando es

$$\log_{10}(Y) = \log_{10}(\beta_0) + \log_{10}(\beta_1) \cdot X.$$

Ejemplo regresión potencial

Creemos un ejemplo sintético los valores de x son la serie 1:20 mientras que la variable $y = 11 \cdot x^2$ una relación aproximadamente potencial a la que añadimos un error normal

```
set.seed(2024)
x=c(1:20)
head(x)
```

```
[1] 1 2 3 4 5 6
```

```
y=11*x^2+rnorm(20,0,2)# a la serie le añadimos un error aleatorio
head(y)
```

```
[1] 12.96394 44.93743 98.78406 175.57424 277.31620 398.58471
```


```
y_modelo=11*x^2
head(y_modelo)
```

```
[1] 11 44 99 176 275 396
```

Ejemplo regresión potencial

```
library(latex2exp)
plot(x,y,pch=21,bg="blue",ylab=TeX(r'($y=11\cdot x^2$)'),cex.lab=0.8,
      xlim=c(0,21),main="Gráfico x-y")
lines(x,y=y_modelo,col="black",type="l",lwd=1.5)
legend("topleft",
      legend=c("Valores observados",
               TeX(r'(Valores modelo potencial $y=11\cdot x^2$)')),
      pch=c(21,NA),lty=c(NA,1),lwd=c(NA,1.5), pt.bg=c("blue",NA))
```

Ejemplo regresión potencial




Ejemplo regresión potencial

Con coordenadas log-log

$$\log_{10}(y) = \log_{10}(0.1) + 2 \cdot \log_{10}(x)$$

```
plot(log10(x),log10(y),pch=21,bg="blue",
     ylab=TeX(r'($\log_{10}(y)$)'),cex.lab=0.8,xlim=c(0,log10(21)),
     main="Gráfico log-log")
lines(log10(1:21),log10(11*(1:21)^2),col="black",type="l",lwd=1.5)
legend("topleft",legend=c("Valores observados",
                          TeX(r'(Valores modelo potencial $y=0.1 \cdot x^2$)')),
      pch=c(21,NA),lty=c(NA,1),lwd=c(NA,1.5), pt.bg=c("blue",NA))
```

Ejemplo regresión potencial




Ejemplo regresión potencial

La propia función `plot` puede dibujar el gráfico log-log o semi-log con el parámetro `log="xy"` o `log="y"`

```
plot(x,y,pch=21,bg="blue",cex.lab=0.8,log ="xy",  
      main="Gráfico log-log")  
regresion=lm(log10(y)~log10(x)+1)  
abline(regresion)  
legend("topleft",legend=c("Valores observados",  
                           "Valores modelo potencial estimado por lm"),  
       pch=c(21,NA),lty=c(NA,1),lwd=c(NA,1.5), pt.bg=c("blue",NA))
```

Ejemplo regresión potencial



Ejemplo regresión potencial estimada por `lm`

El modelo potencial $y = \beta_0 \cdot x^{\beta_1}$ se transforma en lineal con coordenadas logarítmicas en ambas variables:

$$\log_{10}(y) = \log_{10}(\beta_0) + \beta_1 \cdot \log_{10}(x)$$

Ahora, como tenemos un modelo lineal estimamos $\log_{10}(\beta_0)$ y β_1 con la función `lm`

Así si la estimación de los coeficientes de la regresión lineal son b_0 y b_1 respectivamente tenemos que

$$\log_{10}(\beta_0) = b_0 \text{ luego } \beta_0 = 10^{b_0} \text{ y } \beta_1 = b_1.$$

Ejemplo regresión potencial estimada por lm

```
regresion=lm(log10(y)~log10(x))
summary(regresion)
```

Call:

```
lm(formula = log10(y) ~ log10(x))
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.018549	-0.005492	-0.000159	0.004768	0.039132

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.073605	0.007747	138.6	<2e-16 ***
log10(x)	1.969375	0.007892	249.5	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01214 on 18 degrees of freedom

Multiple R-squared: 0.9997, Adjusted R-squared: 0.9997

F-statistic: 6.227e+04 on 1 and 18 DF, p-value: < 2.2e-16

Ejemplo regresión potencial estimada por lm

```
(b0=regresion$coefficients[1])
```

```
(Intercept)  
1.073605
```

```
(b1=regresion$coefficients[2])
```

```
log10(x)  
1.969375
```

Ejemplo regresión potencial estimada por lm

```
(beta_0_est=10^b0)
```

```
(Intercept)  
11.84691
```

```
(beta_1_est=b1)
```


```
log10(x)  
1.969375
```

Valores cercanos a 11 y 2 del modelos teórico que ha generado los datos.

Ejemplo regresión potencial estimada por lm

```
plot(x,y,pch=21,bg="blue",ylab=TeX(r'($y=11\cdot x^2$)'),
     cex.lab=0.8,xlim=c(0,21),
     main="Gráfico x-y")
lines(x,y=y_model,col="black",type="l",lwd=1.5,lty=2)
lines(x,y=beta_0_est*x^beta_1_est,col="red",type="l",lty=3,lwd=1.5)
legend("topleft",
      legend=c("Valores observados",
               "Valores modelo potencial teorico",
               "Valores del modelo potencial estimados por lm"),
      pch=c(21,NA,NA),lty=c(NA,1,2),
      lwd=c(NA,1.5,1.5), pt.bg=c("blue",NA,NA),
      col=c(NA,"black","red"))
```

Ejemplo regresión potencial estimada por lm



Estimación del modelo exponencial mediante un modelo lineal

El modelo exponencial es $y = \beta_0 \cdot \beta_1^x$ con $\beta_0 > 0$ y $\beta_1 > 0$.

Si aplicamos $\log_{10}$ tenemos que

$$\log_{10}(y) = \log_{10}(\beta_0) + \log_{10}(\beta_1) \cdot x,$$

luego tenemos un cambio de coordenadas semi-logarítmico sólo hacemos coordenadas logarítmicas en la variable y , siendo las unidades de x las mismas.

Si hacemos ahora el modelo lineal $\text{lm}(\log_{10}(y) \sim x + 1)$ las estimaciones b_0 y b_1 nos sirven para obtener $\beta_0 = 10^{b_0}$ y $\beta_1 = 10^{b_1}$.

Ejemplo regresión exponencial

Creemos un ejemplo sintético los valores de x es serie que va de 0.1 a 2 con incremento de 0.1 mientras que la variable $y = 3 \cdot 2^x$ es una relación exponencial, a la que le añadimos un error normal en las observaciones.

```
set.seed(2024)
x=seq(0.1,2,by=0.1)
head(x)
```

```
[1] 0.1 0.2 0.3 0.4 0.5 0.6
```

```
y=3*2^x+rnorm(20,0,1)# y observado añadimos error normal
head(y)
```

```
[1] 4.197290 3.914810 3.585462 3.745646 5.400739 5.839505
```


```
y_modelo=3*2^{x}
head(y_modelo)
```

```
[1] 3.215320 3.446095 3.693433 3.958524 4.242641 4.547150
```

Ejemplo regresión exponencial

```
plot(x,y,pch=21,bg="blue",ylab=TeX(r'($y=3\cdot 2^x$)'),  
     cex.lab=0.8,xlim=c(0,2.1),  
     main="Gráfico x-y")  
lines(x,y=y_modelo,col="black",type="l",lwd=1.5)  
  
legend("topleft",  
      legend=c("Valores observados",  
               TeX(r'(Valores modelo exponencial $y=3\cdot 2^x$)')),  
      pch=c(21,NA),lty=c(NA,1),lwd=c(NA,1.5), pt.bg=c("blue",NA))
```

Ejemplo regresión exponencial



Ejemplo regresión exponencial cálculo desde lm

```
regresion=lm(log10(y)~x+1)
summary(regresion)
```

Call:

```
lm(formula = log10(y) ~ x + 1)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.16816	-0.05380	0.01125	0.05480	0.08963

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.53786	0.03545	15.171	1.07e-11 ***
x	0.23148	0.02960	7.821	3.38e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.07632 on 18 degrees of freedom

Multiple R-squared: 0.7726, Adjusted R-squared: 0.76

F-statistic: 61.17 on 1 and 18 DF, p-value: 3.376e-07

Ejemplo regresión exponencial cálculo desde lm

```
regresion=lm(log10(y)~x+1)
b0=regresion$coefficients[1]
b1=regresion$coefficients[2]
```

```
beta_0_est=10^b0
beta_0_est
```

```
(Intercept)
3.450329
```

```
beta_1_est=10^b1
beta_1_est
```

```
x
1.704037
```

Ejemplo regresión exponencial estimada con lm

```
plot(x,y,pch=21,bg="blue",ylab=TeX(r'($y=3\cdot 2^x$)'),
     cex.lab=0.8,xlim=c(0,2.1),
     main="Gráfico x-y")
lines(x,y=y_modelo,col="black",type="l",lwd=1.5,lty=2)
lines(x,y=beta_0_est*beta_1_est^x,col="red",type="l",lty=3,lwd=1.5)

legend("topleft",
      legend=c("Valores observados",
               "Valores modelo exponencial teorico",
               "Valores del modelo exponencial estimados por lm"),
      pch=c(21,NA,NA),lty=c(NA,1,2),
      lwd=c(NA,1.5,1.5),pt.bg=c("blue",NA,NA),
      col=c(NA,"black","red"))
```

Ejemplo regresión exponencial estimada con lm

